



Facultad de Ciencias Económicas y Empresariales  
ICADE

# **EVOLUCIÓN DE LAS ESTRATEGIAS DE GESTIÓN DE CARTERAS: COMPARATIVA ENTRE ENFOQUES TRADICIONALES Y AVANZADOS**

Autor: Santiago Collazo Fontes  
Director: Lourdes Fernández Rodríguez

## **Resumen**

El objetivo principal de este Trabajo Fin de Grado es analizar y contrastar las estrategias de gestión de carteras, comparando los enfoques tradicionales—representados por el Modelo de Media-Varianza de Markowitz y el CAPM—con metodologías avanzadas, representadas por la Volatilidad Estocástica y la Optimización Bayesiana. A partir de un exhaustivo análisis de la evolución teórica de estos modelos y de una revisión crítica de la literatura académica y profesional, se identifican las principales fortalezas y limitaciones de cada enfoque.

Este estudio permite evidenciar cómo, a pesar de la relevancia histórica de los modelos clásicos, las propuestas innovadoras ofrecen herramientas más flexibles y precisas para gestionar el riesgo y optimizar los rendimientos en contextos de alta incertidumbre. Finalmente, se plantean recomendaciones para la integración de ambas perspectivas en la toma de decisiones de inversión, con el fin de mejorar la eficiencia de la gestión de carteras en mercados dinámicos y globalizados.

**Conceptos y palabras clave:** Gestión de carteras, Modelo de Media-Varianza, CAPM, Volatilidad Estocástica, Optimización Bayesiana

## **Abstract**

The main objective of this Final Degree Project is to analyze and compare portfolio management strategies, contrasting traditional approaches—represented by the Mean-Variance Model of Markowitz and the CAPM—with advanced methodologies, such as Stochastic Volatility and Bayesian Optimization. Based on a thorough analysis of the theoretical evolution of these models and a critical review of academic and professional literature, the study identifies the key strengths and limitations of each approach.

The findings reveal that, despite the historical relevance of classical models, innovative methods provide more flexible and accurate tools for managing risk and optimizing returns in highly uncertain market conditions. Finally, recommendations are proposed for integrating both perspectives into the investment decision-making process, aiming to enhance portfolio management efficiency in dynamic and globalized financial environments.

**Concepts and keywords:** Portfolio management, Mean-Variance Model, CAPM, Stochastic Volatility, Bayesian Optimization

## Índice de contenido

<b>1. Introducción.....</b>	<b>7</b>
1.1. Motivación .....	7
1.2. Objetivo del trabajo.....	7
1.3. Importancia de la gestión y optimización de carteras en el contexto financiero actual .....	8
1.4. Metodología y estructura del trabajo.....	8
<b>2. Gestión de carteras tradicional: modelos y limitaciones .....</b>	<b>10</b>
2.1. Modelo de Media-Varianza de Markowitz .....	10
2.2. Principios del CAPM y su aplicación en la selección de carteras .....	14
2.3. Limitaciones de los enfoques tradicionales en mercados modernos.....	18
<b>3. Enfoques avanzados en la gestión de carteras .....</b>	<b>19</b>
3.1. Volatilidad Estocástica en la gestión de carteras .....	19
3.2. Optimización Bayesiana .....	22
<b>4. Comparativa entre los enfoques tradicionales y avanzados.....</b>	<b>28</b>
4.1. Análisis crítico de los enfoques tradicionales .....	28
4.2. Análisis crítico de los enfoques avanzados .....	30
<b>5. Conclusiones.....</b>	<b>33</b>
5.1. Resumen de los hallazgos .....	33
5.2. Limitaciones del trabajo .....	34
5.3. Recomendaciones para futuras investigaciones .....	34
5.4. Conclusión final .....	35
<b>6. Declaración de Uso de Herramientas de Inteligencia Artificial Generativa en Trabajos Fin de Grado .....</b>	<b>37</b>
<b>7. Bibliografía.....</b>	<b>38</b>

## Índice de figuras

1. Frontera Eficiente para el Modelo de Media-Varianza para las acciones de Inditex, Banco Santander, Telefónica, BBVA y Repsol durante el año 2024. ....	13
2. Frontera Eficiente y Línea de Mercado de Capitales (CML) para las acciones de Inditex, Banco Santander, Telefónica, BBVA y Repsol durante el año 2024. ....	16
3. Diagrama de flujo de la Optimización Bayesiana aplicada a la gestión de carteras.	24
4. Funcionamiento gráfico del ciclo iterativo de la Optimización Bayesiana basado en Procesos Gaussianos. ....	27

## **Índice de tablas**

1. Tabla resumen de las propiedades de los modelos GARCH y Volatilidad Estocástica de Heston .....	22
--	----

## **1. Introducción**

### **1.1. Motivación**

Durante mis estudios de doble grado en ADE y *Business Analytics* he tenido la oportunidad de cursar asignaturas relacionadas con el *Machine Learning*, el procesamiento de datos masivos (*Big Data*) y técnicas más recientes como la Optimización Bayesiana o el aprendizaje por refuerzo profundo (*Deep Reinforcement Learning*), que están revolucionando no solo el ámbito financiero, sino también nuestra manera de entender y afrontar nuestros retos personales y profesionales.

Al principio, estas técnicas captaron mi interés por su carácter innovador, pero fue durante unas prácticas como analista de fondos, donde descubrí de primera mano el mundo de la gestión activa de carteras y comprendí el verdadero valor de la aplicación práctica de los conceptos aprendidos.

En particular, la asignatura de Trading Algorítmico supuso un punto de inflexión tanto en mi formación académica como en mi desarrollo personal. A través de ella, adquirí conocimientos sobre el diseño e implementación de estrategias de inversión automatizadas, lo que aumentó y consolidó mi interés personal y profesional en este campo.

Por tanto, con este trabajo pretendo ampliar mi conocimiento teórico en el ámbito de la gestión de carteras y el análisis financiero, así como generar interés en el desarrollo de propuestas prácticas que mejoren la eficiencia en la toma de decisiones financieras. A nivel personal, representa una oportunidad única para seguir desarrollándome en un área que me apasiona y motiva.

### **1.2. Objetivo del trabajo**

El presente Trabajo Fin de Grado (TFG) tiene como objetivo analizar y contrastar distintas estrategias de gestión de carteras a través de una revisión detallada de la literatura académica y profesional en esta materia. Se analizan distintos métodos tradicionales y modernos de gestión de carteras, para evaluar, de forma teórica y descriptiva las aportaciones y limitaciones de los distintos enfoques en el contexto de su aplicación en los mercados financieros actuales.

El propósito es ofrecer una visión crítica y objetiva que facilite una comprensión más profunda de las diversas metodologías de gestión de carteras, de manera que permita al inversor evaluar y comparar las diferentes aproximaciones existentes, sin proponer una solución integradora única.

### **1.3. Importancia de la gestión y optimización de carteras en el contexto financiero actual**

El entorno financiero actual se distingue por su gran volatilidad, una creciente globalización y continuas transformaciones en los mercados. En este escenario, la gestión y optimización de carteras adquiere una relevancia fundamental. Los avances tecnológicos en la accesibilidad y disponibilidad de datos, así como en las herramientas de análisis de los mismos, permiten a las instituciones financieras e inversores maximizar sus rendimientos ajustados al riesgo gestionando entornos cada vez más inciertos.

Las teorías tradicionales de gestión de carteras, cuyos principales exponentes son el Modelo de Media-Varianza de Markowitz y el *Capital Asset Pricing Model* (CAPM, por sus siglas en inglés), sientan las bases para la construcción de carteras diversificadas con el objetivo de lograr un equilibrio entre riesgo y rendimiento. No obstante, en los mercados actuales, donde la volatilidad y los continuos cambios en las condiciones económicas requieren estrategias más flexibles y dinámicas, estos modelos tradicionales presentan limitaciones y resultan insuficientes.

En respuesta a estos desafíos, han surgido enfoques avanzados e innovadores en la gestión de carteras que ofrecen una rápida capacidad de respuesta a las fluctuaciones de los mercados, protegiendo el capital y aprovechando oportunidades de inversión en tiempos de incertidumbre. Por ello, una gestión de carteras eficiente y optimizada es esencial para enfrentar con éxito los retos que presenta el sistema financiero actual.

### **1.4. Metodología y estructura del trabajo**

La metodología de este trabajo se basa en dos ejes principales. En primer lugar, se realiza una revisión exhaustiva de estudios y publicaciones disponibles sobre la gestión de carteras. Para ello, se han consultado bases de datos académicas como *Google Scholar*, *JSTOR* y *ScienceDirect*, así como revistas especializadas en finanzas como el *Journal of Portfolio Management*, o el *Journal of Finance*. Esta revisión permite analizar y sintetizar



las aportaciones teóricas y prácticas más importantes de los métodos tradicionales y de las propuestas más actuales e innovadoras. El objetivo de esta revisión es comprender el desarrollo de estos enfoques e identificar, a través de su estudio, sus principales contribuciones y limitaciones en el contexto de los mercados actuales.

El segundo eje de este trabajo consiste en recopilar y contrastar los resultados y las conclusiones más relevantes de dichos estudios, de manera que se puedan comparar las ventajas y limitaciones de cada metodología. Este enfoque comparativo se lleva a cabo de forma descriptiva, sin la realización de un análisis empírico propio, con el objetivo de ofrecer una visión global sobre cómo cada aproximación o método opera en entornos financieros dinámicos y volátiles.

La estructura del trabajo se organiza en cinco apartados principales. En este primer apartado, ya se ha explicado la motivación del trabajo, el contexto, y los objetivos. A continuación, se plantea la relevancia de la gestión y optimización de carteras en el entorno financiero actual, para justificar la metodología propuesta. En el segundo apartado se abordan los fundamentos y limitaciones de los métodos tradicionales, mientras que el tercero se dedica a explorar los enfoques avanzados que han surgido para responder a las exigencias de mercados dinámicos. El cuarto apartado presenta una comparativa detallada entre ambas aproximaciones, resaltando las aportaciones y carencias de cada una. Finalmente, el quinto apartado recoge las conclusiones del estudio, junto con las limitaciones del trabajo y las recomendaciones para futuras investigaciones.

## 2. Gestión de carteras tradicional: modelos y limitaciones

En este TFG se analizan específicamente el Modelo de Media-Varianza de Markowitz y el *Capital Asset Pricing Model* de Sharpe, ya que constituyen los pilares fundamentales de la teoría de gestión de carteras y continúan teniendo un impacto significativo en el ámbito financiero. Estos modelos se consideran “tradicionales” porque fueron los primeros en formalizar matemáticamente la teoría de inversión. Antes de su desarrollo, la gestión de carteras se realizaba de manera intuitiva, sin tomar en consideración un marco cuantitativo que guiara la toma de decisiones y demostrara empíricamente las ventajas de la diversificación.

Aunque existen otros enfoques tradicionales como el Modelo de Índice Único de Sharpe, la Teoría de Precios por Arbitraje (APT, por sus siglas en inglés) de Ross o el Modelo de Factores de Fama y French, en este TFG, se ha optado por analizar los dos modelos fundamentales anteriormente mencionados, ya que son los que han servido de base para el desarrollo de la Teoría Moderna de Carteras.

Markowitz (1952) introdujo por primera vez el concepto de optimización de carteras basado en la relación riesgo-rendimiento. Posteriormente, Sharpe (1964) amplió este concepto con el CAPM, incorporando el concepto de riesgo sistemático y su efecto en la valoración de activos. Este tipo de riesgo hace referencia a las fluctuaciones que afectan al mercado – tales como los cambios en los tipos de interés, el crecimiento económico o las crisis financieras – y no puede eliminarse mediante diversificación.

Sin embargo, a pesar de su relevancia, ambos modelos presentan limitaciones significativas en los mercados modernos, caracterizados, como se ha señalado anteriormente, por una gran volatilidad, continuos cambios estructurales y una disponibilidad masiva de datos que exige métodos más específicos y dinámicos. A continuación, se analizan en detalle estos modelos y las limitaciones que presentan en el contexto actual.

### 2.1. Modelo de Media-Varianza de Markowitz

El Modelo de Media-Varianza de Markowitz, también conocido como la Teoría Moderna de Carteras (*Modern Portfolio Theory*, MPT, por sus siglas en inglés), constituye la base del marco teórico de la gestión y optimización de carteras. Propuesto

por Harry Markowitz en 1952, el objetivo del modelo es construir carteras eficientes mediante la optimización simultánea de dos factores clave: el rendimiento esperado y la varianza de los rendimientos de los activos (utilizada como medida del riesgo de la cartera).

Antes de la publicación de este modelo, la diversificación en las inversiones era una práctica habitual, pero se realizaba de una manera intuitiva, distribuyendo el capital entre distintos activos para reducir el riesgo específico que presenta cada uno de ellos (denominado idiosincrático). En dicho contexto, Markowitz (1952) formalizó el concepto de diversificación eficiente, que permitió, por primera vez, identificar las combinaciones de activos que ofrecen el mejor equilibrio entre riesgo y rendimiento, lo que denominó “Frontera Eficiente”.

Esta Frontera Eficiente representa el conjunto de todas las carteras que, para un nivel de riesgo determinado, ofrecen el máximo rendimiento posible, o que, para un rendimiento esperado específico, minimizan el riesgo (Markowitz, 1952). Esto demostró, por primera vez, que la diversificación podría reducir el riesgo total de una cartera, especialmente cuando los activos no están perfectamente correlacionados entre sí.

Para comprender el funcionamiento del modelo, es fundamental definir sus componentes. A modo de ejemplo, se considera una cartera formada por  $n$  activos, y las siguientes variables:

- Vector de rendimientos esperados:  $\mu = (\mu_1, \dots, \mu_n)'$ , donde  $\mu_i$  representa el rendimiento esperado del activo  $i$ . En el contexto del modelo de Markowitz, este rendimiento esperado se suele estimar como la media aritmética de los rendimientos históricos del activo. El símbolo ' indica que el vector está expresado en forma traspuesta, es decir, como un vector columna.
- Matriz de covarianzas  $C = (\sigma_{ij})$ , donde  $\sigma_{ij}$  representa la covarianza entre los rendimientos de los activos  $i$  y  $j$ . La covarianza mide cómo varían conjuntamente dos activos: si tienden a subir o bajar al mismo tiempo será positiva, mientras que si se mueven en direcciones opuestas será negativa.
- Vector de pesos de la cartera:  $X = (X_1, \dots, X_n)'$ , donde  $X_i$  representa la proporción del capital invertido en el activo  $i$ .

El rendimiento esperado de la cartera ( $E$ ) se calcula como la combinación lineal de los rendimientos esperados de los activos ponderados por sus respectivos pesos en la cartera:

$$E = \mu'X = \sum_{i=1}^n \mu_i X_i$$

El riesgo de la cartera, definido como la varianza de los rendimientos de la cartera ( $V$ ) se determina teniendo en cuenta tanto las varianzas individuales de los activos como las covarianzas entre ellos:

$$V = X'CX = \sum_{i=1}^n \sum_{j=1}^n X_i X_j \sigma_{ij}$$

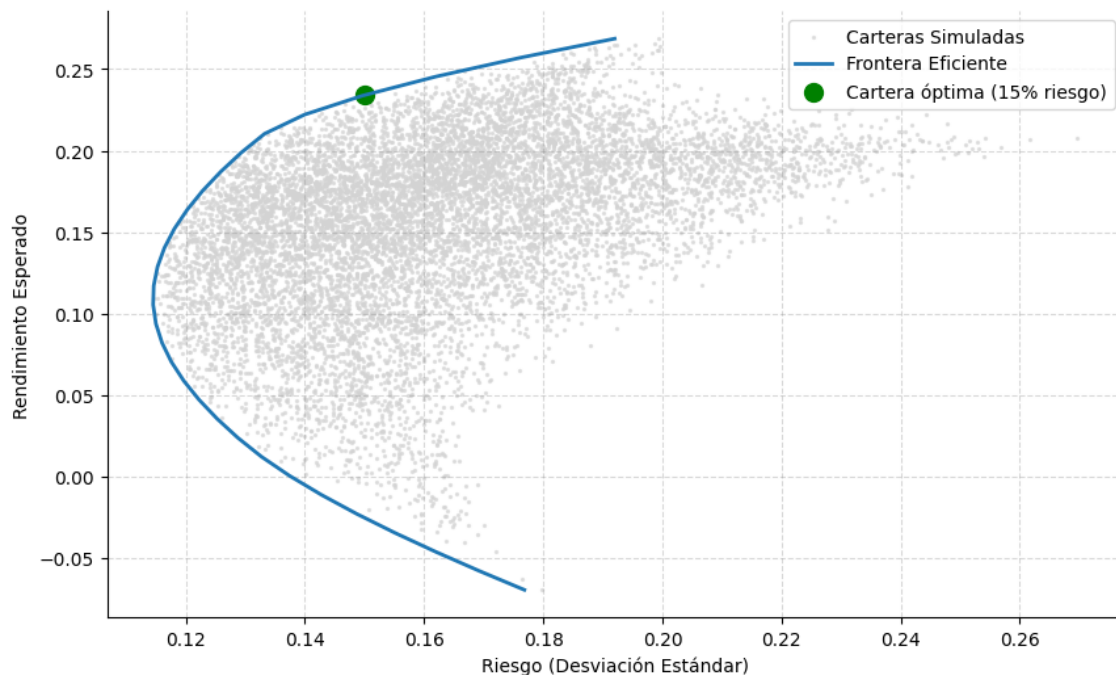
Donde  $i$  y  $j$  representan los distintos activos considerados en la cartera, variando desde 1 hasta  $n$ . Esta expresión está sujeta a las siguientes restricciones:

$$AX = b, X \geq 0$$

En esta ecuación,  $A$  es una matriz de restricciones de dimensión  $m \times n$ , donde  $m$  representa el número total de restricciones impuestas al modelo, y  $n$  el número de activos incluidos en la cartera. Dichas restricciones pueden definir condiciones como el capital disponible o límites de pesos individuales para cada activo. El vector  $b$  es de dimensión  $m \times 1$  e indica los valores específicos que dichas restricciones deben cumplir. La condición  $X \geq 0$  implica que los pesos deben ser no negativos, es decir, no se permiten posiciones cortas en los activos.

Como se ha explicado anteriormente, la Frontera Eficiente representa el conjunto de todas las carteras óptimas que ofrecen la mejor combinación de riesgo y rendimiento. En otras palabras, para cada nivel de riesgo asumido, la Frontera Eficiente muestra la cartera que proporciona el mayor rendimiento posible.

Figura 1: Frontera Eficiente para el Modelo de Media-Varianza para las acciones de Inditex, Banco Santander, Telefónica, BBVA y Repsol durante el año 2024.



Fuente: Elaboración propia con datos extraídos de *Yahoo Finance*

Markowitz representó la Frontera Eficiente de manera geométrica, como se muestra en la Figura 1. En este gráfico, el eje horizontal representa el riesgo (medido como la desviación típica o estándar), mientras que el eje vertical muestra el rendimiento esperado. Las carteras que se encuentran en el borde superior de este conjunto de posibles combinaciones componen la Frontera Eficiente, que define el área donde los inversores racionales deberían situarse, dependiendo de sus preferencias de riesgo. Gráficamente, las carteras ineficientes se encuentran por debajo de la Frontera Eficiente, ya que ofrecen un menor rendimiento para el mismo nivel de riesgo o un mayor riesgo para el mismo nivel de rendimiento.

Para la construcción del gráfico, primero se han obtenido los datos históricos de precios de cierre de las acciones de Inditex, Banco Santander, Telefónica, BBVA y Repsol correspondientes al año 2024, utilizando Yahoo Finance como fuente de información. A partir de estos datos, se han calculado los rendimientos diarios y su matriz de covarianzas. Posteriormente, se simulan 10.000 carteras, asignando pesos aleatorios a cada activo y se evalúan sus rendimientos esperados y desviaciones estándar. Con este

conjunto de carteras, se optimiza la Frontera Eficiente minimizando el riesgo para distintos niveles de rendimiento objetivo, asegurando que la suma de los pesos de la cartera sea igual a 1. Finalmente, se representan gráficamente los resultados: las carteras simuladas aparecen en color gris, mientras que la Frontera Eficiente se muestra en color azul.

Además, se han obtenido los resultados correspondientes a una cartera eficiente asumiendo un nivel de riesgo del 15%, lo que implica que el inversor acepta una volatilidad anual del 15% en los rendimientos esperados. Esta cartera, representada en la gráfica mediante un punto verde, ha sido construida de forma que maximiza la rentabilidad esperado bajo dicha restricción de riesgo.

Según los resultados del modelo, la asignación óptima consiste en destinar un 56,85% de la inversión a Banco Santander, un 37,72% a Repsol y un 5,42% a BBVA, mientras que Inditex y Telefónica no forman parte de la cartera, al no contribuir a mejorar la relación entre rentabilidad y riesgo en este contexto. El rendimiento esperado anualizado de esta combinación óptima es del 23,41%, situándose sobre la Frontera Eficiente y confirmando que, para el nivel de riesgo asumido, no existe una mejor alternativa en términos de rentabilidad esperada.

## **2.2. Principios del CAPM y su aplicación en la selección de carteras**

Markowitz sentó las bases para la selección óptima de carteras mediante la diversificación eficiente, pero el modelo CAPM, desarrollado por William F. Sharpe en 1964, fue un paso más allá al relacionar sistemáticamente el riesgo de mercado y el rendimiento esperado. En su artículo *“Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk”*, Sharpe (1964) explica que, en un mercado en equilibrio, la oferta y la demanda de activos financieros se igualan, de modo que los precios de los activos reflejan toda la información disponible, incluyendo la tasa libre de riesgo, y una prima adicional que compense al inversor por asumir el riesgo sistemático.

Mientras que Markowitz demostró que una cartera óptima minimiza la varianza para un nivel dado de rendimiento esperado, el CAPM establece que, en equilibrio, solo el riesgo sistemático es relevante para la valoración de activos, ya que el riesgo propio de cada activo (idiosincrático) puede eliminarse mediante diversificación.

Una de las contribuciones clave del CAPM es la introducción del coeficiente *beta* ( $\beta$ ), el cual mide la sensibilidad del rendimiento de un activo  $i$  frente a las variaciones del mercado. Este coeficiente se calcula como:

$$\beta_i = \frac{Cov(R_i, R_M)}{Var(R_M)}$$

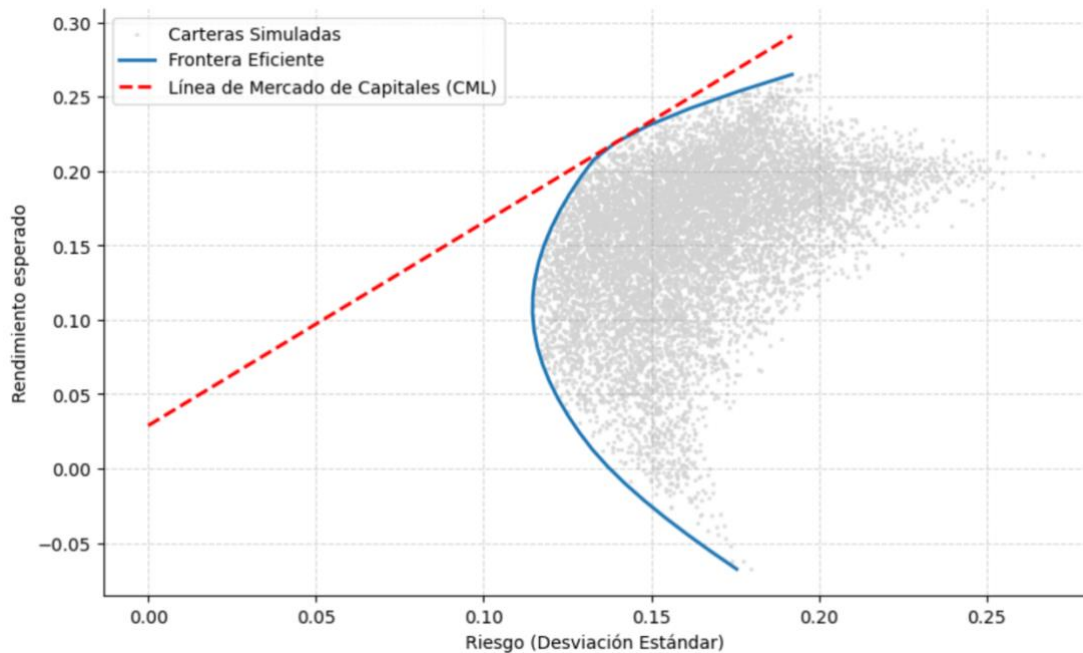
donde:

- $Cov(R_i, R_M)$  es la covarianza entre el rendimiento del activo  $i$  y el del mercado ( $R_M$ ), y mide cómo varían conjuntamente los rendimientos de dos activos.
- $Var(R_M)$  representa la varianza del rendimiento del mercado, y mide cuánto se desvían los rendimientos del mercado respecto a su media, indicando así la volatilidad o el riesgo general del mercado.

El valor de  $\beta$  indica el nivel de riesgo sistemático que el inversor asume al incluir el activo en la cartera. De este modo, un activo con  $\beta > 1$  es más sensible a las variaciones del mercado, presentando mayor volatilidad (por ejemplo, acciones de empresas tecnológicas), y, por tanto, un mayor riesgo. En cambio, un activo con  $\beta < 1$  tiene menor sensibilidad y, por tanto, menor volatilidad respecto al mercado (por ejemplo, acciones de servicios públicos). Finalmente, un activo con  $\beta = 1$  varía acorde con el mercado, es decir, cuando el mercado sube o baja, el rendimiento del activo lo hace en la misma proporción.

Además, Sharpe (1964) introdujo el concepto de la “línea del mercado de capitales” (*Capital Market Line* o CML, por sus siglas en inglés), que representa gráficamente la relación entre el riesgo y el rendimiento esperado en equilibrio. La Figura 2, mostrada a continuación, expone cómo el rendimiento de una cartera diversificada puede situarse en cualquier punto de la CML, dependiendo del nivel de riesgo sistemático asumido.

Figura 2: Frontera Eficiente y Línea de Mercado de Capitales (CML) para las acciones de Inditex, Banco Santander, Telefónica, BBVA y Repsol durante el año 2024.



Fuente: Elaboración propia con datos extraídos de *Yahoo Finance*

En la Figura 2, se representa de nuevo la Frontera Eficiente calculada en la Figura 1. La novedad en este gráfico es la incorporación de la CML, representada por la línea roja discontinua. Para trazar la CML, se ha asumido una tasa libre de riesgo del 2,89% anual. Esta estimación se basa en los rendimientos de las obligaciones a 10 años según la "Síntesis de Indicadores" del Banco de España (2025). La CML se obtiene al trazar una línea recta que parte del activo libre de riesgo y es tangente a la Frontera Eficiente. El punto de tangencia representa la cartera de mercado óptima, es decir, es la cartera más eficiente de las disponibles antes de incluir el activo libre de riesgo.

- Para inversores conservadores, cualquier combinación entre el activo libre de riesgo y la cartera de mercado será óptima dentro de la CML, ya que ofrece el mejor rendimiento ajustado al riesgo.
- Para inversores más arriesgados, es posible apalancarse (tomar prestado a la tasa libre de riesgo) y situarse por encima de la cartera de mercado en la CML.



A través de este marco conceptual, Sharpe logró cuantificar la compensación que el mercado exige por asumir riesgo, estableciendo las bases matemáticas del CAPM para la toma de decisiones de inversión. Su teoría fue formalizada y extendida por economistas como John Lintner (1965) y Jan Mossin (1966), quienes profundizaron en los fundamentos teóricos y consolidaron su aplicabilidad práctica. El CAPM se expresa mediante la siguiente ecuación:

$$E(R_i) = R_f + \beta_i(E(R_M) - R_f)$$

donde:

- $E(R_i)$  es el rendimiento esperado de un activo.
- $R_f$  es la tasa libre de riesgo, que representa el rendimiento mínimo esperado sin asumir riesgo (por ejemplo, obligaciones a 10 años).
- $E(R_M)$  es el rendimiento esperado del mercado.
- $E(R_M) - R_f$  es la prima de riesgo del mercado, que representa el rendimiento adicional esperado por asumir riesgo sistemático.
- $\beta_i$  es el coeficiente de sensibilidad del activo respecto al mercado.

La formalización del CAPM permite a los inversores evaluar si el rendimiento esperado de un activo es adecuado en función de su riesgo sistemático. Según el modelo, en un mercado eficiente, los activos deben ofrecer un rendimiento proporcional a su *beta*, es decir, un activo con mayor *beta* debe generar un rendimiento esperado más alto para compensar el mayor riesgo que asume el inversor.

En un mercado eficiente, los precios de los activos reflejan toda la información disponible, por lo que no es posible obtener rendimientos extraordinarios de forma consistente aprovechando dicha información. Es por ello que, si un activo presenta un rendimiento inferior al esperado según el CAPM, se considera sobrevalorado, y si es superior al esperado, se considera infravalorado y potencialmente atractivo para su inclusión en la cartera.

El CAPM, por tanto, no solo sirve para establecer un criterio de valoración de activos, sino también como guía para la construcción de carteras diversificadas. Los gestores de

carteras pueden utilizar la CML como referencia para seleccionar activos que maximicen el rendimiento ajustado al riesgo, ayudando a construir una cartera eficiente según las preferencias de riesgo del inversor (Sharpe, 1964).

### **2.3. Limitaciones de los enfoques tradicionales en mercados modernos**

A pesar de su importancia, el Modelo de Media-Varianza de Markowitz y el CAPM presentan deficiencias cuando se aplican en mercados volátiles y complejos. Estas limitaciones surgen de las suposiciones simplificadas de las que parten dichos enfoques tradicionales, ya que no reflejan la realidad de los mercados. Varios autores han señalado estas limitaciones, destacando las que se exponen a continuación, que se desarrollan con mayor detalle en el apartado 4.1.

Una de las principales críticas al modelo de Markowitz es su alta sensibilidad a las estimaciones de los parámetros de entrada, como los rendimientos esperados y las covarianzas. Dado que estos parámetros se calculan a partir de datos históricos, cualquier error o pequeña variación en las estimaciones puede generar carteras óptimas muy diferentes, afectando a la estabilidad y fiabilidad del modelo, lo que dificulta su aplicación práctica en escenarios reales de inversión (Michaud, 1989).

El CAPM, en particular, parte de la asunción de que los mercados son eficientes y racionales (es decir, que los precios reflejan toda la información disponible y los inversores toman decisiones lógicas y coherentes), por lo que ignora comportamientos irracionales, como los sesgos cognitivos y la aversión a las pérdidas (Kahneman & Tversky, 1979). Además, la evidencia empírica de Fama y French (2004) demuestra que la relación entre la *beta* y el rendimiento es más débil de lo que predice el modelo, lo que sugiere que la *beta* no explica completamente las diferencias en los rendimientos esperados entre activos, poniendo en duda su aplicabilidad. Otra limitación es la inestabilidad de la *beta* en el CAPM, cuya sensibilidad al mercado cambia en condiciones de alta volatilidad, reduciendo su capacidad predictiva (Jagannathan & Wang, 1996).

Finalmente, ambos modelos asumen un horizonte temporal fijo y una aversión al riesgo constante, cuando en realidad los inversores adaptan sus estrategias y tolerancia al riesgo según las condiciones del mercado (Barberis, 2000).

### **3. Enfoques avanzados en la gestión de carteras**

Los métodos avanzados en la gestión de carteras surgen como respuesta a las limitaciones y deficiencias de los métodos tradicionales. Estos métodos, que presentan nuevas estrategias de aproximación al análisis de la gestión de carteras, incorporan técnicas y métodos de optimización que permiten representar de forma más realista la dinámica de los mercados. A diferencia de los enfoques tradicionales, que presuponen una volatilidad constante y supuestos poco realistas, los métodos avanzados ofrecen una mayor capacidad de adaptación ante cambios bruscos y la incertidumbre en el mercado.

Se analizan dos métodos avanzados: la Volatilidad Estocástica y la Optimización Bayesiana. La Volatilidad Estocástica permite analizar con mayor precisión la naturaleza cambiante del riesgo en los mercados (Heston, 1993). Por otro lado, la Optimización Bayesiana facilita la exploración eficiente de un amplio espacio de soluciones y el ajuste dinámico de los parámetros del modelo (Shahriari et al., 2016).

Cabe destacar que, además de estos métodos, existen otros enfoques avanzados, como el aprendizaje reforzado mediante inteligencia artificial, las redes neuronales recurrentes y los algoritmos evolutivos, que también han sido propuestos para la gestión de carteras. Sin embargo, no se analizan debido a su elevada complejidad, ya que los límites de este TFG impedirían ofrecer una explicación rigurosa y adecuada. La elección de los métodos de Volatilidad Estocástica y Optimización Bayesiana se basa en su solidez teórica y en su evidencia empírica, que respalda su capacidad para mejorar la eficiencia y la adaptabilidad de las estrategias de inversión en entornos financieros complejos.

#### **3.1. Volatilidad Estocástica en la gestión de carteras**

La Volatilidad Estocástica es un concepto que ha ganado importancia en el ámbito de la gestión de carteras debido a su capacidad para representar de manera más realista las variaciones de precios en los mercados. A diferencia de los modelos tradicionales, que presuponen una volatilidad constante, los modelos de Volatilidad Estocástica permiten que esta varíe de manera aleatoria y no lineal en el tiempo. Esto significa que la volatilidad no sigue un patrón estable o proporcional al paso del tiempo, sino que puede experimentar cambios impredecibles en respuesta a las condiciones del mercado. De esta manera, estos modelos se ajustan mejor a la realidad de los mercados financieros, donde los precios de los activos presentan variaciones significativas e impredecibles (Ghysels et al., 1996).

Para comprender mejor las ventajas de los modelos de Volatilidad Estocástica, resulta útil contrastarlos con modelos de Volatilidad Determinista, como los modelos ARCH (por sus siglas en inglés, *Autoregressive Conditional Heteroskedasticity*) y su extensión GARCH (por sus siglas en inglés, *Generalized Autoregressive Conditional Heteroskedasticity*), que se utilizan para predecir la volatilidad en los rendimientos de los activos financieros. Estos modelos se consideran de probabilidad determinista porque la volatilidad futura se calcula directamente a partir de valores pasados, sin incorporar aleatoriedad en su evolución.

El modelo ARCH, desarrollado por Engle (1982), permite simular la volatilidad de los activos financieros en función de sus variaciones históricas. Sin embargo, su estructura puede volverse ineficiente en periodos largos, ya que requiere un gran número de parámetros para representar la volatilidad de forma precisa. Para solucionar esto, Bollerslev (1986) desarrolló el modelo GARCH, que mejora la estabilidad al captar de manera más eficiente la persistencia de la volatilidad, es decir, su tendencia a permanecer alta o baja durante ciertos periodos, sin necesidad de estimar demasiados parámetros. En estos modelos deterministas, la volatilidad depende de una relación matemática con valores pasados, lo que permite identificar patrones históricos y hacer estimaciones sobre su evolución.

Una característica importante del modelo GARCH es su capacidad para captar la "persistencia" de la volatilidad, lo que significa que, tras un periodo de alta volatilidad, es probable que esta siga siendo alta, y lo mismo ocurre en periodos de baja volatilidad (Bollerslev et al., 1992). Sin embargo, GARCH sigue una estructura condicional basada en observaciones previas, lo que limita su capacidad para anticipar cambios inesperados (Poon & Granger, 2003).

Diversos estudios han analizado el desempeño de estos modelos en distintos mercados financieros. Por ejemplo, un análisis reciente realizado por Abril y Abril (2025), publicado en la *South American Research Journal*, analiza la comparación entre los modelos ARCH-GARCH y los modelos de Volatilidad Estocástica en la estimación de la volatilidad en mercados financieros. El estudio compara ambos enfoques aplicándolos a un pequeño mercado de valores, y analiza su capacidad para reflejar la evolución del riesgo financiero. Los resultados muestran que los modelos GARCH proporcionan

estimaciones más estables y precisas en contextos de volatilidad moderada y con estructuras de correlación persistente. Sin embargo, en escenarios de alta incertidumbre y cambios abruptos en el mercado, los modelos de Volatilidad Estocástica son más eficaces para representar las fluctuaciones repentinas, ya que permiten capturar variaciones bruscas sin depender exclusivamente de datos históricos.

En contraste, los modelos de Volatilidad Estocástica, como el propuesto por Steven Heston en 1993, ofrecen la ventaja significativa de tratar la volatilidad como un proceso independiente del precio del activo. En estos modelos, la volatilidad no es un valor fijo, sino que sigue su propio proceso aleatorio (Heston, 1993).

La principal ventaja del modelo de Heston es que describe la volatilidad como un proceso de reversión a la media, lo que significa que la volatilidad tiende a regresar a un valor promedio a largo plazo, incluso si fluctúa significativamente en el corto plazo. Este proceso está controlado por tres parámetros: la tasa de reversión a la media, el nivel promedio al cual la volatilidad tiende a regresar, y la volatilidad de la volatilidad. Esta última mide cuánto varía la volatilidad de un activo; a mayor volatilidad de la volatilidad, mayor inestabilidad y riesgo, ya que los cambios en el mercado son más impredecibles (Andersen et al., 2003).

Por ejemplo, durante una crisis financiera, el modelo de Heston puede reflejar un incremento rápido en la volatilidad, que luego tiende a estabilizarse una vez que las condiciones del mercado se normalizan. Al capturar estas variaciones, el modelo es capaz de describir mejor las características reales de los mercados, ofreciendo una descripción más realista de cómo la incertidumbre y el riesgo evolucionan con el tiempo (Christoffersen et al., 2010).

En la gestión de carteras, el uso de modelos de Volatilidad Estocástica, como el modelo que se acaba de describir, permite a los gestores y analistas medir de forma más precisa el riesgo y adaptar las estrategias de inversión a las condiciones del mercado. Al anticipar cambios en la dinámica del mercado, estos modelos ayudan a establecer límites de riesgo, ajustar los pesos de los activos y realizar coberturas más eficientes en tiempos de alta incertidumbre. Esto proporciona una ventaja significativa en la toma de decisiones, permitiendo optimizar el rendimiento ajustado al riesgo y proteger el capital en condiciones de mercado adversas (Chernov et al., 2003).

A continuación, se compara el modelo determinista de GARCH con el modelo de Volatilidad Estocástica de Heston, destacando sus diferencias clave y su aplicabilidad en distintos escenarios de mercado:

Tabla 1: Tabla resumen de las propiedades de los modelos GARCH y Volatilidad Estocástica de Heston

<b>Criterio</b>	<b>GARCH (Bollerslev, 1986)</b>	<b>Heston (Heston, 1993)</b>
<b>Naturaleza de la volatilidad</b>	Determinista (condicionada a datos históricos)	Estocástica (proceso aleatorio propio)
<b>Dependencia del pasado</b>	Alta	Baja
<b>Fuentes de incertidumbre</b>	Una (rentabilidades)	Dos (rentabilidades y volatilidad)
<b>Flexibilidad ante variaciones abruptas</b>	Limitada	Alta
<b>Uso en la gestión de carteras</b>	Eficiente en condiciones normales	Eficiente en condiciones de alta incertidumbre

Fuente: Elaboración propia

### 3.2. Optimización Bayesiana

La Optimización Bayesiana es una técnica de optimización utilizada para encontrar el mejor resultado en funciones complejas y costosas de valorar, especialmente cuando se cuenta con un número limitado de estimaciones de la función objetivo (Frazier, 2018). A diferencia de los métodos de optimización tradicionales, que requieren probar exhaustivamente todas las combinaciones posibles (Bergstra & Bengio, 2012), la Optimización Bayesiana utiliza un enfoque probabilístico que permite recorrer de manera eficiente un amplio espacio de búsqueda, entendido como el conjunto de todas las combinaciones posibles de variables de la función objetivo.

Para ello, combina dos estrategias clave: la explotación, que profundiza en las combinaciones que han demostrado obtener buenos resultados, y la exploración, que

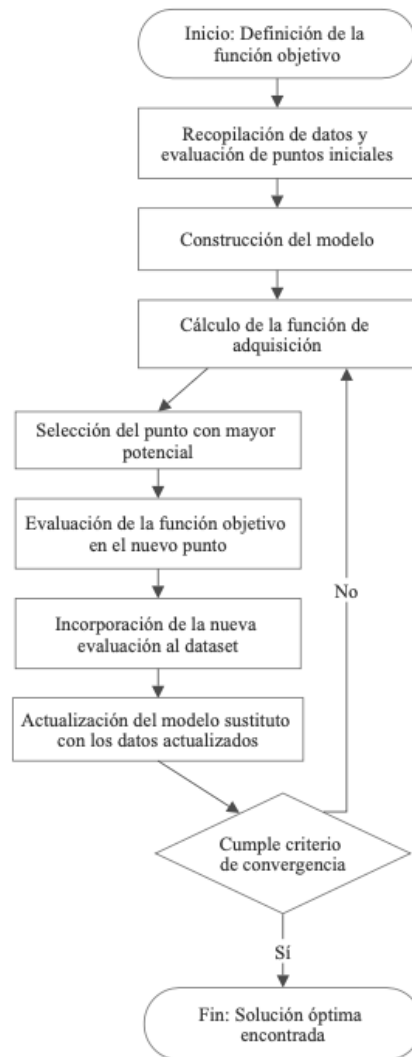
investiga regiones del espacio, que aún no han sido examinadas, pero que presentan potencial prometedor (Shahriari et al., 2016).

Un enfoque clave dentro de esta técnica son los Procesos Gaussianos (GP, por sus siglas en inglés), que son modelos estadísticos capaces de descubrir funciones desconocidas. En los Procesos Gaussianos se asume que cada punto del espacio de búsqueda, es decir, cada combinación de variables de la función objetivo pertenece a una distribución gaussiana multivariante. Esto significa que, en lugar de estimar cada punto de manera independiente, se asume que los valores de la función en diferentes puntos están correlacionados (Rasmussen & Williams, 2006).

Así, al observar distintos puntos, se puede predecir de forma probabilística el comportamiento en otros, incluyendo tanto el valor estimado como la incertidumbre asociada a la predicción (Shahriari et al., 2016). Los Procesos Gaussianos son ampliamente utilizados en la Optimización Bayesiana debido a su capacidad para identificar patrones complejos y su flexibilidad para adaptarse a diferentes estructuras de datos (Frazier, 2018; Rasmussen & Williams, 2006).

A continuación, se presenta el diagrama de flujo que ilustra el proceso de Optimización Bayesiana aplicado a la optimización de carteras:

Figura 3: Diagrama de flujo de la Optimización Bayesiana aplicada a la gestión de carteras.



Fuente: Elaboración propia

El proceso, ilustrado en la figura 3, comienza con la definición de una función objetivo, es decir, la métrica que se desea optimizar. En el ámbito de la gestión de carteras, lo habitual es maximizar el Ratio de Sharpe o minimizar la volatilidad, dependiendo del equilibrio que se busque entre riesgo y rendimiento (Elton et al., 2014). Esta función objetivo guía todo el proceso, por eso es fundamental que se alinee con los intereses y restricciones del inversor.

El Ratio de Sharpe mide los rendimientos ajustados al riesgo de una cartera. Se calcula dividiendo el exceso de rendimientos de la cartera (rendimiento por encima de la tasa libre de riesgo) entre su volatilidad, representada por la desviación estándar de los



rendimientos. Si el Ratio presenta un valor elevado, indica una compensación favorable entre riesgo y rentabilidad. En concreto, si es superior a 1, por cada unidad de riesgo asumido se obtiene más de una unidad de rendimiento adicional, lo que convierte la inversión en una opción muy atractiva para el inversor (Sharpe, 1994).

El proceso continúa con la recopilación de datos y evaluación de puntos iniciales. Estos puntos corresponden a combinaciones de parámetros sobre las que se calcula directamente la función objetivo. En la optimización de carteras, los parámetros típicos son los pesos iniciales de cada activo, que suelen asignarse mediante estrategias como la asignación uniforme (pesos iguales) o la cartera de mínima varianza (Maillard, Roncalli, & Teiletche, 2010).

Con la información inicial obtenida, se construye un “modelo sustituto” o *Surrogate Model*, que estima la función objetivo para predecir su comportamiento en regiones no exploradas, es decir, aquellas donde la función aún no ha sido evaluada (Snoek et al., 2012).

A partir de este modelo sustituto, la optimización sigue un ciclo iterativo (Frazier, 2018). En cada iteración, el modelo probabilístico sugiere una nueva combinación de parámetros, basándose en una “función de adquisición”, cuyo propósito es identificar las combinaciones de parámetros con mayor probabilidad de mejorar la función objetivo. Algunas de las funciones más utilizadas son la *Expected Improvement* (Mejora Esperada), que prioriza los puntos con mayor probabilidad de superar la mejor solución encontrada hasta el momento; o la *Upper Confidence Bound* (Límite Superior de Confianza), que equilibra exploración y explotación, favoreciendo aquellos puntos con mayor potencial o alta incertidumbre (Snoek et al., 2012).

En el caso de los Procesos Gaussianos, en cada punto se estima tanto el valor esperado como la desviación estándar, lo que permite determinar si un punto ofrece suficiente promesa de mejora (Brochu, Cora, & de Freitas, 2010). Una vez seleccionada la nueva combinación de parámetros (por ejemplo, una determinada asignación de pesos), se evalúa la función objetivo y se incorporan los resultados a la base de datos de observaciones. Con esta nueva información, se reentrena el modelo sustituto, actualizando las predicciones de media e incertidumbre en todo el espacio de búsqueda.

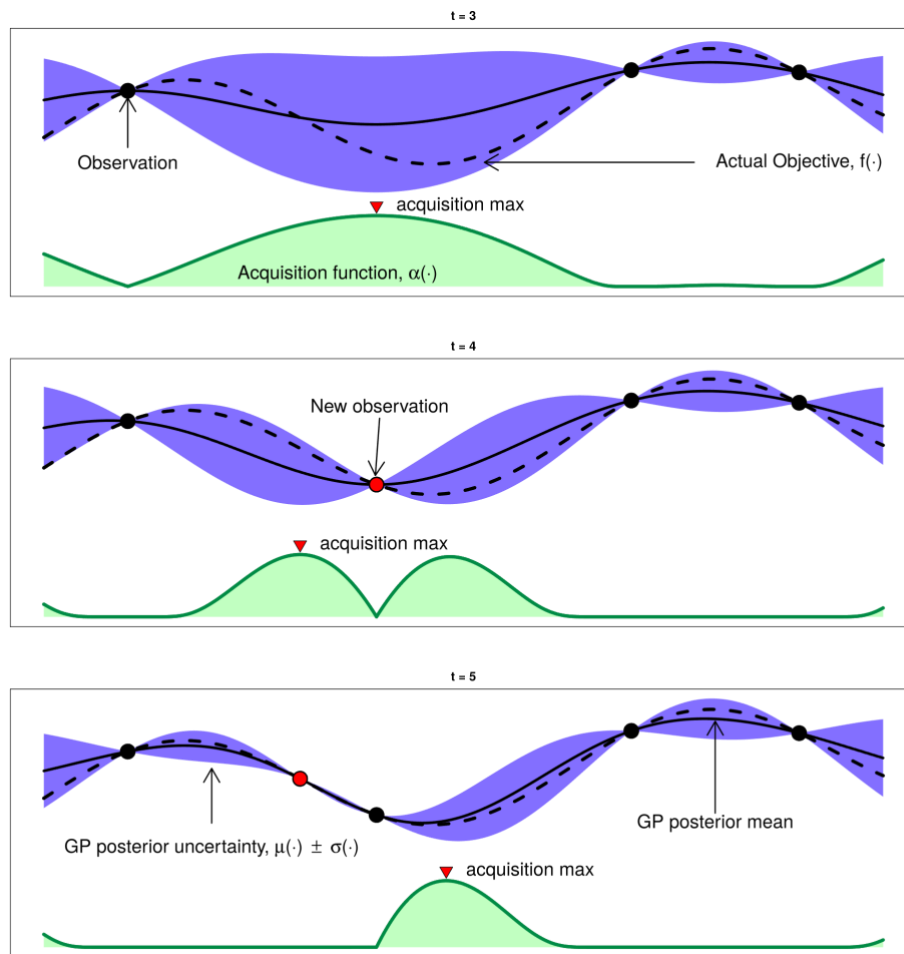
Este proceso ayuda a construir carteras que no sólo maximizan el rendimiento en las condiciones actuales del mercado, sino que también se adaptan a posibles cambios, ofreciendo una ventaja competitiva significativa en entornos volátiles (Shahriari et al., 2016).

El ciclo iterativo se repite hasta que se cumple un criterio de convergencia, que puede ser alcanzar un número máximo de iteraciones, o bien detectar que la mejora en las últimas iteraciones es insignificante, lo que hace innecesario seguir buscando (Frazier, 2018; Shahriari et al., 2016). Una vez satisfecho dicho criterio, se asume que se ha encontrado la solución óptima, o al menos la mejor posible bajo las restricciones establecidas (Jones et al., 1998). En gestión de carteras, esto se traduce en determinar la combinación de pesos que optimiza la función objetivo de forma efectiva.

La figura 4, presentada a continuación, muestra de forma gráfica y simplificada el funcionamiento del ciclo iterativo descrito anteriormente. En primer lugar, se parte de una serie de configuraciones previamente evaluadas (puntos negros), a partir de las cuales el modelo gaussiano genera una predicción probabilística de la función objetivo desconocida. Esta predicción se representa mediante la curva azul sombreada, que refleja tanto la estimación del valor esperado como su incertidumbre.

A partir de esta información, se construye una función de adquisición (línea verde) que determina qué punto ofrece un mejor equilibrio entre exploración y explotación. El punto que maximiza esta función de adquisición es seleccionado como el siguiente a evaluar (punto rojo), guiando así de forma eficiente la búsqueda del óptimo de la función (Garrido Merchán, 2023). Esta lógica es especialmente útil en la gestión de carteras, donde cada evaluación representa una nueva combinación de pesos de activos que puede mejorar el rendimiento ajustado al riesgo.

Figura 4: Funcionamiento gráfico del ciclo iterativo de la Optimización Bayesiana basado en Procesos Gaussianos.



Fuente: Tomado de Garrido Merchán, E.C. (2023)

En definitiva, la Optimización Bayesiana, especialmente cuando se apoya en Procesos Gaussianos, permite estimar el rendimiento esperado de distintas combinaciones de activos y cuantificar la incertidumbre de estas predicciones, lo que reduce el riesgo de sobreajuste (cuando un modelo se adapta demasiado a los datos históricos y pierde capacidad de generalización en nuevos escenarios) y fomenta la construcción de carteras más flexibles y resilientes (Frazier, 2018; Brochu, Cora, & de Freitas, 2010). Gracias a este enfoque, es posible ajustar los pesos de los activos de manera más informada, creando estrategias de inversión dinámicas que se adaptan mejor a los cambios de mercado (Das, Chakraborty, & Mitra, 2024).

## 4. Comparativa entre los enfoques tradicionales y avanzados

A pesar de la relevancia de los enfoques analizados anteriormente, hasta la fecha no hay ningún estudio académico que realice una comparación sistemática entre los métodos estudiados en este TFG. Por ello, este apartado tiene como objetivo profundizar en las diferencias entre ambos enfoques. Se presentan datos cuantitativos y resultados empíricos extraídos de diversas investigaciones que permiten una comparativa sistemática de ambas aproximaciones. En conjunto, estos estudios destacan varios puntos débiles que comprometen la utilidad práctica de los modelos tradicionales en contextos reales.

### 4.1. Análisis crítico de los enfoques tradicionales

Como se indicó previamente en el apartado de limitaciones de los enfoques tradicionales, si bien el Modelo de Media-Varianza y el CAPM han sido pilares fundamentales en la teoría financiera y la gestión de carteras durante décadas, al fundamentarse en supuestos como la racionalidad de los inversores, la eficiencia de los mercados y la estabilidad de la volatilidad, muestran limitaciones significativas al aplicarse en entornos complejos, dinámicos y volátiles. En este apartado se contrastan dichos supuestos teóricos con la evidencia empírica disponible, mediante el análisis de estudios que evalúan la eficacia del enfoque de Media-Varianza, el impacto de la estimación de parámetros y las limitaciones prácticas del CAPM en diversos contextos de mercado.

Michaud (1989), en su artículo *“The Markowitz Optimization Enigma: Is ‘Optimized’ Optimal?”*, investiga la robustez del proceso de optimización de carteras basado en la teoría de la Media-Varianza de Markowitz. En este trabajo, analiza en profundidad cómo pequeñas imprecisiones en la estimación de los rendimientos esperados o en la construcción de la matriz de covarianzas pueden afectar de forma significativa a la asignación final de activos. Para demostrar esta sensibilidad, combina un análisis teórico con simulaciones empíricas que reproducen escenarios de mercado reales, lo que le permite evaluar si la cartera "optimizada" mediante este método se mantiene verdaderamente óptima frente a las condiciones y variaciones del mercado.

Las conclusiones de Michaud demostraron que la solución óptima es altamente sensible a los datos utilizados, lo que significa que incluso ligeras desviaciones en las estimaciones pueden desestabilizar por completo la composición de la cartera. Además,

advierte que la precisión matemática del modelo puede dar una falsa sensación de seguridad, ya que los resultados dependen en gran medida de datos que pueden contener errores o fluctuaciones aleatorias, lo que compromete su fiabilidad. También destaca que este tipo de optimización tiende a ajustarse demasiado a los datos históricos, haciendo que las carteras funcionen bien en el pasado, pero no necesariamente bajo nuevas condiciones de mercado.

Por otra parte, Fama y French (2004), en su artículo “*The Capital Asset Pricing Model: Theory and Evidence*”, evaluaron empíricamente el desempeño del CAPM. En su análisis, se centraron en estudiar la relación entre el coeficiente *beta* y los rendimientos observados a lo largo del tiempo, utilizando técnicas cuantitativas sobre distintos conjuntos de datos del mercado para comprobar si la *beta* realmente permite interpretar y anticipar las variaciones en los rendimientos de los activos. Además, investigaron la presencia de otros factores que pudieran influir en la rentabilidad y que el CAPM no contempla.

Los autores concluyeron que, aunque el CAPM ofrece un marco teórico atractivo por su simplicidad, la *beta* por sí sola resulta insuficiente para explicar las diferencias observadas en las rentabilidades de los activos. Los resultados sugieren que variables adicionales, como el tamaño de la empresa o la relación *book-to-market* (que compara el valor contable con el valor de mercado de una compañía), desempeñan un papel importante, lo que limita la capacidad explicativa del CAPM en escenarios reales. A partir de estos hallazgos, los autores plantean la necesidad de utilizar modelos multifactoriales que integren estas variables y reflejen mejor el comportamiento de los mercados.

Adicionalmente, Jagannathan y Wang (1996), en su artículo “*The Conditional CAPM and the Cross-Section of Expected Returns*”, investigan la inestabilidad del coeficiente *beta* a lo largo del tiempo. En este estudio, los autores introducen una versión condicional del CAPM, incorporando información del estado del mercado para ajustar dinámicamente la estimación de la *beta*, especialmente en contextos de alta volatilidad. Este enfoque les permite analizar cómo varía el riesgo sistemático según las condiciones del entorno y cómo dicha variación influye en la capacidad del modelo para predecir los rendimientos esperados.

En sus conclusiones, los autores subrayan que el supuesto de una *beta* constante es poco realista, ya que el riesgo sistemático varía significativamente según el contexto del mercado. Esta inestabilidad limita la efectividad del CAPM para la valoración de activos y la construcción de carteras, y evidencia que los modelos tradicionales no consiguen representar con precisión la naturaleza cambiante del riesgo en escenarios reales. Además, muestran que al incorporar información macroeconómica, como el salario medio o la tasa de desempleo, su versión condicional del modelo mejora la capacidad explicativa respecto al CAPM estándar, ofreciendo estimaciones más ajustadas de los rendimientos esperados.

#### **4.2. Análisis crítico de los enfoques avanzados**

Una vez expuestas las limitaciones de los modelos tradicionales, los enfoques avanzados se presentan como alternativas que buscan superar dichas debilidades. En este subapartado se exploran dos líneas de trabajo: por un lado la incorporación de Volatilidad Estocástica, que permite capturar de forma más realista la variabilidad del riesgo; y por otro, la aplicación de técnicas bayesianas, que permite actualizar continuamente las estimaciones y ajustar las estrategias de inversión en función de nueva información. Ambos métodos se analizan a través de estudios empíricos que demuestran su capacidad para adaptarse a diversos contextos y mejorar la eficiencia en la gestión de carteras.

En primer lugar, Fung, Demir y Zhou (2014), en su artículo académico “*Capital Asset Pricing Model and Stochastic Volatility: A Case Study of India*” analizan cómo la incorporación de volatilidades condicionales, estimadas mediante modelos GARCH y de Volatilidad Estocástica, puede mejorar la capacidad explicativa del modelo CAPM en el mercado financiero indio. A diferencia del CAPM tradicional, que asume una prima constante, es decir, que el exceso de rentabilidad exigido por los inversores no varía a lo largo del tiempo, el modelo de Bansal y Yaron (2004), introduce una prima de riesgo que varía en función de la incertidumbre presente en la economía. En concreto, esta prima depende tanto de la volatilidad del consumo (la variabilidad en el crecimiento del consumo de los hogares) como de la volatilidad del mercado (la variabilidad en las rentabilidades del mercado financiero).

Los resultados obtenidos por Fung, Demir y Zhou indican que el CAPM clásico tiene dificultades para explicar las diferencias de rentabilidad observadas entre distintas

carteras, es decir, no logra relacionar bien el riesgo de cada cartera con su rentabilidad observada. Esto se debe a que, al usar modelos GARCH simples, las volatilidades estimadas no resultan estadísticamente significativas, lo que significa que no tienen un impacto claro ni consistente en los resultados del modelo. En cambio, al aplicar modelos de Volatilidad Estocástica, el modelo de Bansal y Yaron consigue establecer una relación más clara entre el riesgo y la rentabilidad, especialmente en carteras formadas por empresas pequeñas. Esto sugiere que medir el riesgo de una manera más flexible y ajustada a la realidad permite explicar mejor las variaciones en las rentabilidades de los activos.

En segundo lugar, el uso de técnicas bayesianas ha permitido desarrollar modelos que abordan la incertidumbre en la estimación de parámetros y se adaptan mejor a las condiciones del mercado. En *“Comparison of Selected Portfolio Approaches with Benchmark”*, David Neděla (2020), compara distintos enfoques de optimización de carteras, entre ellos el modelo clásico de Markowitz y un modelo basado en Optimización Bayesiana. El análisis se aplica sobre tres índices bursátiles: el NASDAQ-100, que agrupa a las 100 mayores empresas tecnológicas no financieras de Estados Unidos; el Hang Seng, uno de los indicadores más representativos de la bolsa de Hong Kong y de la economía china; y el FTSE 100, que incluye a las 100 empresas con mayor capitalización bursátil del Reino Unido. El estudio considera dos periodos económicos: 2006-2010 (crisis) y 2015-2019 (expansión). Cada modelo se evalúa mediante métricas como el rendimiento esperado, la volatilidad, el Ratio de Sharpe y otros indicadores de riesgo, lo que permite comparar su comportamiento bajo distintas condiciones de mercado.

Los resultados del estudio indican que ningún modelo es claramente superior en todos los escenarios analizados. Tal como indica el autor, la elección del modelo más adecuado dependerá del comportamiento y perfil del inversor, así como del contexto económico. Sin embargo, el análisis sugiere que, en general, el modelo bayesiano presenta un perfil de riesgo más bajo que el de Markowitz, y en muchos casos logra mejores resultados en métricas como el Ratio de Sharpe. De esta manera, aunque ambos modelos tratan de optimizar la relación entre riesgo y rendimiento mediante una función similar, la versión bayesiana tiende a ser menos volátil, es decir, más “estable”.

Finalmente, De Franco, Nicolle y Pham (2018) en su artículo de investigación “*Bayesian learning for the Markowitz portfolio selection problem*”, reformulan el modelo clásico de Markowitz desde una perspectiva bayesiana dinámica, asumiendo que los rendimientos esperados son desconocidos y deben actualizarse a medida que se observa nueva información del mercado. A través de un enfoque dinámico, desarrollan una estrategia de inversión que ajusta las decisiones en tiempo real según la evolución de las expectativas del inversor.

Los resultados de este enfoque dinámico muestran que esta estrategia con aprendizaje bayesiano supera de forma sistemática a la versión tradicional, especialmente en contextos con alta incertidumbre sobre los rendimientos esperados. Esta mejora de rendimiento, a la que los autores denominan “valor de la información”, demuestra que el enfoque bayesiano no solo aporta mayor flexibilidad, sino que también mejora la eficiencia de la cartera.



## 5. Conclusiones

### 5.1. Resumen de los hallazgos

En el presente apartado se exponen los principales resultados derivados del análisis comparativo entre los métodos tradicionales y avanzados de gestión de carteras. A través de una revisión exhaustiva de la literatura académica y profesional, se han identificado las fortalezas y debilidades de cada enfoque, proporcionando una visión crítica que contribuye a una comprensión más profunda de su aplicabilidad en los mercados financieros actuales.

Por un lado, se ha demostrado que los modelos clásicos, representados por el Modelo de Media-Varianza de Markowitz y el CAPM, han establecido conceptos fundamentales (por ejemplo, la Frontera Eficiente y la Línea de Mercado de Capitales) que han servido de base para el desarrollo de la teoría financiera. Sin embargo, el análisis crítico realizado revela que estos métodos presentan importantes limitaciones en contextos de alta volatilidad y cambios estructurales. Estudios como los de Michaud, Fama y French y Jagannathan y Wang evidencian la alta sensibilidad a la estimación de parámetros, la limitada capacidad predictiva del coeficiente *beta* y la rigidez de sus supuestos, aspectos que no se ajustan a la realidad de los mercados modernos y subrayan la necesidad de adoptar modelos más flexibles y adaptativos.

Por otro lado, los enfoques avanzados analizados en este trabajo, basados en técnicas de Volatilidad Estocástica y Optimización Bayesiana, han demostrado una notable capacidad para superar las deficiencias de los métodos tradicionales. En este sentido, se ha evidenciado que, al permitir la actualización continua de las estimaciones y capturar de forma más precisa la incertidumbre del mercado, estas metodologías ofrecen una mejor adaptación en condiciones de alta volatilidad y cambios estructurales, características propias de los mercados modernos. Por ejemplo, los estudios de Fung, Demir y Zhou muestran que al incorporar modelos de Volatilidad Estocástica se logra establecer una relación más clara entre riesgo y rentabilidad.

Asimismo, la aplicación de técnicas de Optimización Bayesiana, tal como se destaca en la investigación de David Neděla, permite obtener un perfil de riesgo más estable, mejorando métricas clave como el Ratio de Sharpe en diversos escenarios económicos. De manera complementaria, el estudio de De Franco, Nicolle y Pham aporta evidencia de

que la actualización dinámica de las expectativas de rentabilidad a través de un aprendizaje bayesiano mejora sistemáticamente el rendimiento del modelo de Markowitz, aprovechando el “valor de la información” y adaptándose en tiempo real a las condiciones cambiantes del mercado.

En definitiva, la evidencia recopilada indica que los métodos tradicionales siguen siendo útiles y que no deben descartarse por completo.

## **5.2. Limitaciones del trabajo**

Es importante destacar que este TFG se basa únicamente en la revisión y comparación de estudios previos, y no incluye un análisis empírico o numérico propio que contraste directamente las ventajas y limitaciones de cada método en situaciones reales. Por ello, las conclusiones se apoyan en la información de la literatura existente, que puede variar en cuanto a supuestos, metodologías y escenarios de aplicación. Esta diversidad en los enfoques y la ausencia de un análisis numérico propio impiden ofrecer recomendaciones empíricas, por lo que los resultados deben interpretarse dentro de un análisis descriptivo y comparativo.

Adicionalmente, cabe señalar que, debido al volumen de información disponible y las restricciones propias de este trabajo, no ha sido posible incluir todos los estudios y enfoques relacionados con la optimización de carteras. Aunque se han consultado fuentes representativas, el campo se encuentra en constante evolución y existen numerosas propuestas que no han sido incluidas en este análisis. Por ello, el presente TFG se basa en una selección de la literatura disponible de los métodos que se han considerado representativos, sin pretender cubrir la totalidad de las investigaciones.

Finalmente, se debe tener en cuenta que otra limitación encontrada ha sido tratar de sintetizar y explicar de forma accesible conceptos y fórmulas matemáticas de alta complejidad. La simplificación de estos elementos técnicos puede haber ocasionado la omisión de ciertos detalles relevantes que, en un análisis más especializado, ofrecerían una visión más completa del funcionamiento de estos modelos.

## **5.3. Recomendaciones para futuras investigaciones**

A la luz de lo expuesto, se recomienda que futuras investigaciones traten de desarrollar estudios empíricos que permitan evaluar cuantitativamente el desempeño de

los métodos tradicionales y avanzados en la gestión de carteras. Sería interesante llevar a cabo simulaciones o aplicaciones prácticas en diferentes mercados y periodos, para contrastar la robustez y la capacidad de adaptación de cada enfoque en escenarios reales.

Además, se recomienda explorar otras líneas de investigación no abordadas en este trabajo, como la incorporación de técnicas de aprendizaje profundo (*Deep Learning*) y aprendizaje por refuerzo profundo (*Deep Reinforcement Learning*). Estos enfoques, en constante desarrollo, basados en redes neuronales artificiales, permiten capturar patrones complejos y adaptarse dinámicamente a las condiciones cambiantes del mercado. Sin embargo, debido a la complejidad técnica y conceptual que implican, así como al análisis exhaustivo que requieren para explicar adecuadamente sus fundamentos, no se han incluido en este estudio. Por ello, futuras investigaciones podrían analizar estos métodos de manera individualizada y contrastar directamente su desempeño con los enfoques tradicionales y avanzados estudiados aquí.

Finalmente, se recomienda profundizar en la integración de técnicas tradicionales y avanzadas, combinando la solidez teórica de las primeras con la flexibilidad de las segundas, para desarrollar estrategias de inversión que optimicen la relación entre riesgo y rendimiento. También se sugiere considerar aspectos prácticos, como los costes de transacción y otras restricciones operativas, lo que aportaría una visión más completa del desempeño de los modelos estudiados.

## **5.4. Conclusión final**

El presente Trabajo Fin de Grado ha permitido describir a nivel teórico las limitaciones de los métodos tradicionales de gestión de carteras, así como analizar cómo los enfoques avanzados pueden superar dichas deficiencias. Para ello, se ha recopilado y analizado la información disponible de carácter académico y profesional sobre los métodos de gestión de carteras considerados más representativos, distinguiendo entre los enfoques tradicionales y los métodos avanzados.

En primer lugar, se han descrito las características y el funcionamiento de estos métodos para realizar una comparación sistemática. Este estudio evidencia que, aunque los modelos tradicionales aportan una base teórica estable, las técnicas modernas se

adaptan de forma más efectiva a entornos de alta volatilidad, favoreciendo una mayor estabilidad y eficiencia en la toma de decisiones.

En definitiva, tras realizar este TFG se concluye que la elección del enfoque no es absoluta, sino que depende en gran medida del contexto específico del mercado y a las condiciones particulares de cada inversor. Los métodos tradicionales siguen siendo útiles y no deben descartarse por completo, sino que el reto es combinarlos con los nuevos métodos que, además, están en constante mejora debido a las nuevas tecnologías.

De esta manera, la integración de ambos enfoques se presenta como la estrategia más adecuada para optimizar la gestión de carteras en el entorno financiero actual. Este trabajo invita a continuar profundizando en el desarrollo de modelos híbridos que combinen la solidez de los métodos tradicionales con la capacidad de adaptación de las técnicas avanzadas, estableciendo así un marco que responda eficazmente a los desafíos actuales y futuros del mercado.

## 6. Declaración de uso de herramientas de inteligencia artificial generativa en Trabajos Fin de Grado

Por la presente, yo, Santiago Collazo Fontes, estudiante de Doble Grado en Administración y Dirección de Empresas y Business Analytics (E-2 + Analytics) de la Universidad Pontificia Comillas al presentar mi Trabajo Fin de Grado titulado “Evolución de las estrategias de Gestión de Carteras: Comparativa entre enfoques tradicionales y avanzados”, declaro que he utilizado la herramienta de Inteligencia Artificial Generativa *ChatGPT* u otras similares de IAG de código sólo en el contexto de las actividades descritas a continuación:

1. **Brainstorming de ideas de investigación:** Utilizado para idear y esbozar posibles áreas de investigación.
2. **Referencias:** Usado conjuntamente con otras herramientas, como Science, para identificar referencias preliminares que luego he contrastado y validado.
3. **Corrector de estilo literario y de lenguaje:** Para mejorar la calidad lingüística y estilística del texto.
4. **Sintetizador y divulgador de libros complicados:** Para resumir y comprender literatura compleja.
5. **Revisor:** Para recibir sugerencias sobre cómo mejorar y perfeccionar el trabajo con diferentes niveles de exigencia.
6. **Traductor:** Para traducir textos de un lenguaje a otro.

Afirmo que toda la información y contenido presentados en este trabajo son producto de mi investigación y esfuerzo individual, excepto donde se ha indicado lo contrario y se han dado los créditos correspondientes (he incluido las referencias adecuadas en el TFG y he explicitado para que se ha usado *ChatGPT* u otras herramientas similares). Soy consciente de las implicaciones académicas y éticas de presentar un trabajo no original y acepto las consecuencias de cualquier violación a esta declaración.

Fecha: 04/04/2025

Firma: Santiago Collazo Fontes

## 7. Bibliografía

- Abril, J. C., & Abril, M. de las M. (2025). Comparison of ARCH-GARCH and stochastic approaches for estimating volatility: Application to a small stock market. *South American Research Journal*, 4(2), 25-44.
- Andersen, T. G., Bollerslev, T., Diebold, F. X., & Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71, 579-625.
- Banco de España. (2025). *España. Indicadores Financieros. Series Diarias* (Síntesis de indicadores, 1.2).  
[https://www.bde.es/webbe/es/estadisticas/compartido/datos/pdf/si\\_1\\_2.pdf](https://www.bde.es/webbe/es/estadisticas/compartido/datos/pdf/si_1_2.pdf)
- Bansal, R., & Yaron, A. (2004). Risks for the long run: A potential resolution of asset pricing puzzles. *The Journal of Finance*, 59, 1481-1509.
- Barberis, N. (2000). Investing for the long run when returns are predictable. *The Journal of Finance*, 55(1), 225-264.
- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281-305.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327.
- Bollerslev, T., Chou, R. Y., & Kroner, K. F. (1992). ARCH modeling in finance: A review of the theory and empirical evidence. *Journal of Econometrics*, 52(1-2), 5-59.
- Brochu, E., Cora, V. M., & de Freitas, N. (2010). *A tutorial on Bayesian optimization of expensive cost functions, with application to active user modeling and hierarchical reinforcement learning*. [Preprint]. arXiv:1012.2599.
- Chernov, M., Gallant, A. R., Ghysels, E., & Tauchen, G. (2003). Alternative models for stock price dynamics. *Journal of Econometrics*, 116, 225-257.
- Christoffersen, P., Jacobs, K., & Mimouni, K. (2010). Volatility dynamics for the S&P 500: Evidence from realized volatility, daily returns and option prices. *The Review of Financial Studies*, 23(8), 3141-3189.
- Das, S., Chakraborty, D., & Mitra, P. (2024). An adaptive portfolio allocation through Bayesian optimization. [Preprint]. SSRN 4916439.
- Franco, C.D., Nicolle, J., & Pham, H. (2018). Bayesian learning for the Markowitz portfolio selection problem. *International Journal of Theoretical and Applied Finance*, 22(07), 1950037.
- Elton, E. J., Gruber, M. J., Brown, S. J., & Goetzmann, W. N. (2014). *Modern portfolio theory and investment analysis* (9 ed.). Wiley.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987-1007.

- Fama, E. F., & French, K. R. (2004). The capital asset pricing model: Theory and evidence. *Journal of Economic Perspectives*, 18(3), 25-46.
- Frazier, P. I. (2018). *A tutorial on Bayesian optimization*. [Preprint]. arXiv:1807.02811.
- Fung, K. W., Demir, E., & Zhou, L. (2016). Capital asset pricing model and stochastic volatility: A case study of India. *Emerging Markets Finance and Trade*, 52(1), 52-65.
- Garrido Merchán, E. C. (2023). La evolución de la gestión de carteras: Del modelo de Markowitz al deep reinforcement learning y la optimización bayesiana. *Ex Post*. <https://expost.comillas.edu/la-evolucion-de-la-gestion-de-carteras-del-modelo-de-markowitz-al-deep-reinforcement-learning-y-la-optimizacion-bayesiana/>
- Ghysels, E., Harvey, A. C., & Renault, E. (1996). Stochastic volatility. En G. S. Maddala, & C. R. Rao (Eds.), *Handbook of Statistics* (Vol. 14, pp. 119-191). Elsevier.
- Heston, S. L. (1993). A closed-form solution for options with stochastic volatility with applications to bond and currency options. *The Review of Financial Studies*, 6(2), 327-343.
- Jagannathan, R., & Wang, Z. (1996). The conditional CAPM and the cross-section of expected returns. *The Journal of Finance*, 51(1), 3-53.
- Jones, D. R., Schonlau, M., & Welch, W. J. (1998). Efficient global optimization of expensive black-box functions. *Journal of Global Optimization*, 13, 455-492.
- Kahneman, D., & Tversky, A. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2), 263-292.
- Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *The Review of Economics and Statistics*, 47(1), 13-37.
- Maillard, S., Roncalli, T., & Teiletche, J. (2010). The properties of equally weighted risk contribution portfolios. *The Journal of Portfolio Management*, 36, 60-70.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77-91.
- Michaud, R. O. (1989). The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal*, 45(1), 31-42.
- Mossin, J. (1966). Equilibrium in a capital asset market. *Econometrica*, 34(4), 768-783.
- Neděla, D. (2020). Comparison of selected portfolio approaches with benchmark. En S. Kapouněk & H. Vránová (Eds.), *38th International Conference on Mathematical Methods in Economics* (MME 2020). Actas de la Conferencia (pp. 389–395). Brno: Universidad Mendel en Brno.
- Poon, S.H., & Granger, C. W. J. (2003). Forecasting volatility in financial markets: A review. *Journal of Economic Literature*, 41(2), 478-539.

- Rasmussen, C. E., & Williams, C. K. (2006). Gaussian processes for machine learning. *MIT Press*.
- Shahriari, B., Swersky, K., Wang, Z., Prescott, R. A., & de Freitas, N. (2016). Taking the human out of the loop: A review of Bayesian optimization. *Proceedings of the IEEE*, 104(1), 148-175.
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425-442.
- Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21, 49-58.
- Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian optimization of machine learning algorithms. *Advances in Neural Information Processing Systems*, 25, 2951-2959.