



COMILLAS

UNIVERSIDAD PONTIFICIA



ICADE – Facultad de Ciencias Económicas y
Empresariales

**COMPARATIVA DE MODELOS DE
OPTIMIZACIÓN DE CARTERAS
APLICADOS AL IBEX-35:
IMPLEMENTACIÓN EN PYTHON**

Clave: 202007327

MADRID | JUNIO 2025

I. Resumen

El presente Trabajo Fin de Grado analiza comparativamente cuatro enfoques de optimización de carteras: Media-Varianza, CAPM, Volatilidad Estocástica y Optimización Bayesiana. A partir de una implementación práctica en Python, se evalúa su rendimiento sobre el IBEX-35 en el periodo 2011–2023 bajo tres escenarios distintos: sin restricciones, con límites UCITS 5/10/40 y con la normativa RIC 25/50. Para cada caso, se examinan los resultados esperados y reales, con especial atención al *alfa* generado y a la coherencia entre la Ratio de Sharpe estimada y observada.

Los resultados evidencian que todos los enfoques logran superar al índice en valor acumulado, aunque con diferencias relevantes en cuanto a estabilidad, sensibilidad y capacidad de adaptación. El análisis permite comprobar empíricamente muchas de las conclusiones teóricas presentes en la literatura, y proporciona una visión integrada sobre las fortalezas y limitaciones de cada enfoque en un entorno de inversión realista.

II. Palabras Clave

Optimización de carteras, Media-Varianza, CAPM, Volatilidad Estocástica, Optimización Bayesiana, IBEX-35, Python

III. Abstract

This Final Degree Project offers a comparative analysis of four portfolio optimization approaches: Mean-Variance, CAPM, Stochastic Volatility, and Bayesian Optimization. Based on a practical implementation in Python, their performance is evaluated on the IBEX-35 index over the 2011–2023 period under three different scenarios: without restrictions, with UCITS 5/10/40 constraints, and under the RIC 25/50 regulatory framework. For each case, both expected and realized results are examined, with particular attention to the *alpha* generated and the consistency between the estimated and observed Sharpe Ratios.

The findings show that all models outperform the benchmark index in terms of accumulated value, though with notable differences in stability, sensitivity, and adaptability. The analysis provides empirical evidence for many theoretical conclusions found in the literature and offers an integrated view of the strengths and limitations of each approach in a realistic investment context.

IV. Key words

Portfolio optimization, Mean-Variance, CAPM, Stochastic Volatility, Bayesian Optimization, IBEX-35, Python

Índice

I. Resumen	2
II. Palabras Clave	2
III. Abstract	3
IV. Key words.....	3
1. Introducción	8
1.1. Motivación	8
1.2. Objetivos del trabajo	8
1.3. Importancia de la gestión y optimización de carteras en el contexto financiero actual	9
1.4. Metodología y estructura del trabajo.....	9
2. Marco teórico	11
2.1. Fundamentos de la optimización de carteras	11
2.2. Modelo de Media-Varianza.....	12
2.3. CAPM	13
2.4. Volatilidad Estocástica.....	14
2.5. Optimización Bayesiana	16
3. Implementación del Modelo	19
3.1. Dataset.....	19
3.2. Preparación de los datos.....	19
3.3. Métricas de rendimiento y riesgo	20
3.4. Escenarios de restricciones	21
3.5. Flujo general de la optimización	23
3.5.1. Eje I – Análisis individual por enfoque.....	25
3.5.2. Eje II – Comparativa de escenarios.....	26
3.5.3. Parámetros y decisiones comunes.....	28
3.6. Implementación de cada enfoque.....	28
3.6.1. Modelo de Media-Varianza.....	28
3.6.2. CAPM	29
3.6.3. Volatilidad Estocástica.....	31
3.6.4. Optimización Bayesiana.....	33
4. Resultados	36
4.1. Escenario 1: Sin límites.....	36
4.2. Escenario 2: UCITS 5/10/40	40
4.3. Escenario 3: RIC 25/50	44
4.4. Comparativa global de métodos	46
5. Conclusiones.....	49
5.1. Resumen de los hallazgos	49
5.2. Limitaciones del trabajo.....	50

5.3.	Recomendaciones para futuros trabajos e investigaciones	50
5.4.	Conclusión final	51
6.	Declaración de uso de herramientas de inteligencia artificial generativa en Trabajos Fin de Grado	52
7.	Bibliografía.....	53
8.	Apéndice	55
8.1.	Apéndice A: Pesos de las carteras optimizadas en el Escenario 1	55
8.2.	Apéndice B: Pesos de las carteras optimizadas en el Escenario 2	57
8.3.	Apéndice C: Pesos de las carteras optimizadas en el Escenario 3	61
8.4.	Apéndice D: Resultados <i>ex ante</i> por enfoque	65
8.5.	Apéndice E: Resultados <i>ex post</i> por enfoque.....	66
8.6.	Apéndice F: Modelo.....	67

Índice de figuras

Figura 1: Funcionamiento gráfico del ciclo iterativo de la Optimización Bayesiana basado en Procesos Gaussianos	17
Figura 2: Diagrama de flujo general de optimización	24
Figura 3: Evolución del valor objetivo durante la Optimización Bayesiana (2022, Escenario 1)	34
Figura 4: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 1).....	39
Figura 5: Evolución acumulada del valor de las carteras (Escenario 1).....	40
Figura 6: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 2).....	43
Figura 7: Evolución acumulada del valor de las carteras (Escenario 2).....	43
Figura 8: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 3).....	45
Figura 9: Evolución acumulada del valor de las carteras (Escenario 3).....	46

Índice de tablas

Tabla 1: Escenarios de restricciones de pesos	22
Tabla 2: Distribución óptima de pesos según el Modelo de Media-Varianza (2022, Escenario 1)	29
Tabla 3: Estimación de <i>betas</i> del IBEX-35 a cierre de 2022 (datos de 2018-2022)	30
Tabla 4: Distribución óptima de pesos según el Modelo de Heston (2022, Escenario 1)	33
Tabla 5: Distribución óptima de pesos según el Modelo de Optimización Bayesiana (2022, Escenario 1)	35
Tabla 6: Comparativa <i>ex post</i> : <i>alfa</i> y desviación de la Ratio de Sharpe (Escenario 1) ..	36
Tabla 7: Comparativa <i>ex post</i> : <i>alfa</i> y desviación de la Ratio de Sharpe (Escenario 2) ..	41
Tabla 8: Comparativa <i>ex post</i> : <i>alfa</i> y desviación de la Ratio de Sharpe (Escenario 3) ..	44

1. Introducción

1.1. Motivación

A lo largo de mis estudios, han sido las asignaturas del grado de Business Analytics las que más me han atraído, especialmente aquellas que integraban programación y modelización con contenidos financieros. Gracias a estas materias, he podido comprender el potencial de las herramientas de análisis de datos y su aplicación directa en la toma de decisiones financieras.

Este interés inicial se vio reforzado durante mis prácticas en Tressis, donde pude experimentar de manera personal el sector de la gestión de activos. Aquella experiencia supuso un punto de inflexión, ya que fue la primera vez que vi una conexión real entre los conocimientos adquiridos en clase y su aplicación directa en el entorno profesional.

Finalmente, la asignatura de Trading Algorítmico terminó de consolidar mi interés. Su combinación entre teoría e implementación práctica no solo profundizó mi comprensión, sino que también reforzó mi motivación por seguir explorando este ámbito. Por todo ello, este Trabajo Fin de Grado representa una oportunidad para aplicar los conocimientos adquiridos durante la carrera, al mismo tiempo que me permite seguir profundizando y desarrollarme en un campo que me resulta especialmente atractivo para mi futuro profesional.

1.2. Objetivos del trabajo

El presente Trabajo Fin de Grado (TFG) retoma el análisis teórico realizado en mi TFG de ADE, en el que se lleva a cabo una revisión exhaustiva de la literatura académica y profesional sobre distintas estrategias de gestión de carteras. En aquel primer trabajo, profundicé en dos enfoques clásicos —el Modelo de Media-Varianza de Markowitz y el Capital Asset Pricing Model (CAPM)— y en dos metodologías avanzadas —el modelo de Volatilidad Estocástica de Heston y la Optimización Bayesiana—, describiendo sus fundamentos, aportaciones y limitaciones teóricas.

Como continuación de ese estudio puramente descriptivo, en este trabajo se realiza una comparación empírica de los resultados obtenidos al aplicar cada uno de estos cuatro métodos para optimizar carteras. Por lo tanto, el propósito de este trabajo es evaluar de manera crítica y objetiva cada enfoque, permitiendo al lector y, en su caso, al inversor, contrastar su rendimiento práctico en términos de rentabilidad ajustada al riesgo, y

analizar cómo los avances tecnológicos han ido modificando las técnicas de optimización a lo largo del tiempo.

1.3. Importancia de la gestión y optimización de carteras en el contexto financiero actual

En un entorno de mercados cada vez más volátiles y complejos, la optimización de carteras se ha convertido en una herramienta clave para la gestión del riesgo y la toma de decisiones de inversión. En este contexto, donde los inversores demandan mayor transparencia y control sobre sus posiciones, asignar el capital con criterios claros y objetivos es más importante que nunca.

La creciente disponibilidad de datos y el desarrollo de herramientas estadísticas y computacionales han reforzado el papel de los modelos cuantitativos en este proceso. Estos permiten construir carteras de forma sistemática, respaldando cada decisión con una base analítica sólida, y adaptada tanto a los objetivos del inversor como a un entorno cambiante.

1.4. Metodología y estructura del trabajo

El estudio combina una revisión teórica con una implementación práctica en Python. Para ello, la estructura sigue un orden lógico diseñado para comprender, aplicar y evaluar cada enfoque.

El primer bloque corresponde al marco teórico, donde se presentan de forma introductoria los cuatro métodos analizados: Media-Varianza, CAPM, Volatilidad Estocástica y Optimización Bayesiana. No se busca una revisión exhaustiva, sino comprender de forma clara cómo funciona cada uno y cuál es su base conceptual, como paso previo a su implementación.

A continuación, el apartado de implementación describe la construcción del modelo paso a paso. Se detalla la preparación de los datos, la definición de las funciones en Python y las métricas empleadas para evaluar las carteras (rentabilidad, volatilidad y Ratio de Sharpe). Además, se definen tres escenarios de restricciones que permiten simular distintos marcos de inversión.

A partir de esta base, se presentan los resultados, que recogen tanto el rendimiento esperado (*ex ante*) como el real (*ex post*) de las carteras optimizadas, y permiten analizar

la estabilidad, coherencia y capacidad de cada modelo para generar valor en distintos contextos.

El trabajo finaliza con un bloque de conclusiones, donde se resumen los hallazgos más relevantes, se identifican las limitaciones del estudio y se proponen posibles líneas futuras de investigación.

2. Marco teórico

2.1. Fundamentos de la optimización de carteras

La optimización de carteras tiene como objetivo asignar de forma eficiente los recursos entre diferentes activos financieros, equilibrando el rendimiento esperado y el riesgo asumido. Este proceso se plantea como un problema matemático, en el que una función objetivo representa el criterio a maximizar o minimizar según las preferencias del inversor. De este modo, los métodos de optimización permiten tomar decisiones financieras de forma objetiva, integrando los fundamentos teóricos con su aplicación práctica.

En la práctica, el proceso comienza con la recopilación y preparación de datos históricos de precios, a partir de los cuales se calculan los rendimientos y medidas de riesgo. Con esta base, se estiman los parámetros necesarios para definir tanto la función objetivo como las restricciones del modelo. Posteriormente, el problema se resuelve mediante herramientas computacionales, lo que permite obtener una asignación óptima de pesos entre activos en línea con los objetivos establecidos.

Si bien la asignación uniforme del capital puede parecer una forma intuitiva de diversificación, diversos estudios han demostrado su ineficiencia frente a enfoques de optimización más sofisticados (DeMiguel et al., 2009). En el contexto del IBEX-35, Adame-García et al. (2015) confirman estos resultados tanto antes como después de la crisis financiera. En la misma línea, distintos trabajos de Amenc y colaboradores señalan que este tipo de estrategias de diversificación ingenua no garantiza mejoras reales en el desempeño de la cartera y puede generar combinaciones subóptimas entre riesgo y rentabilidad (Amenc & Martellini, 2011; Amenc et al., 2012).

Finalmente, las carteras resultantes se evalúan mediante métricas que permiten valorar su eficiencia y estabilidad. Entre ellas destaca la Ratio de Sharpe, que cuantifica la rentabilidad ajustada al riesgo. Además, la incorporación de restricciones permite adaptar el modelo a marcos regulatorios o preferencias específicas del inversor.

De este modo, la optimización de carteras constituye un marco estructurado para tomar decisiones financieras de manera objetiva. Al integrar datos históricos, métricas de rendimiento y restricciones personalizadas, permite construir carteras que se ajustan tanto a los objetivos del inversor como a las condiciones reales del mercado. Este planteamiento sirve como base para los diferentes modelos que se analizan a continuación, cada uno con

su propia forma de estimar los parámetros clave y abordar la relación entre riesgo y rentabilidad.

2.2. Modelo de Media-Varianza

Previo a 1952, la diversificación de carteras se realizaba de forma intuitiva, ya que los inversores repartían el capital entre distintos activos con el objetivo de reducir el riesgo específico asociado a cada uno (denominado idiosincrático). No existía un criterio cuantitativo que permitiera evaluar de forma objetiva qué combinación de activos ofrecía la mejor relación rentabilidad-riesgo.

El Modelo de Media-Varianza, introducido por Harry Markowitz en 1952, constituye el punto de partida de la Teoría Moderna de Carteras (*Modern Portfolio Theory*, MPT, por sus siglas en inglés). Su objetivo es identificar la combinación de activos que optimiza la relación entre la rentabilidad esperada y el riesgo. En este contexto, el riesgo se define como la varianza (o desviación típica) de los rendimientos, mientras que la rentabilidad esperada se calcula como el promedio histórico de los rendimientos individuales.

A partir de los rendimientos históricos de un conjunto de activos, el modelo obtiene tres elementos fundamentales:

- a) Un vector de pesos (X) que determina la asignación del capital entre el número de activos.
- b) Un vector de rendimientos esperados (μ) que representa la expectativa de rentabilidad de cada activo.
- c) Una matriz de covarianzas (C) que cuantifica cómo varían conjuntamente los rendimientos de los activos. Una covarianza positiva indica que los activos tienden a moverse en la misma dirección, mientras que una negativa sugiere comportamientos opuestos. Este componente es clave para estimar el riesgo total de la cartera, ya que permite capturar y observar las relaciones entre los activos.

Mediante la combinación de estas tres variables, el modelo es capaz, de forma analítica, de determinar qué pesos o combinaciones de activos maximizan el rendimiento o minimizan la varianza según el objetivo del inversor.

Al resolver el problema para distintos niveles de riesgo, se genera la “Frontera Eficiente”: el conjunto de carteras que maximizan la rentabilidad para un nivel de riesgo

dado o, de forma equivalente, minimizan la varianza para un retorno objetivo. A través de este concepto, (Markowitz, 1952, 1959) demostró que la diversificación, siempre que los activos no estén perfectamente correlacionados, puede reducir de forma significativa el riesgo total de la cartera.

El principal atractivo del modelo reside en su simplicidad y en su sólido fundamento teórico, al constituir la base para comprender los principios de la diversificación y la toma de decisiones de inversión. En este trabajo, se emplea como primer enfoque de optimización, sirviendo tanto de punto de partida como de referencia comparativa para evaluar el valor añadido de métodos más avanzados.

2.3. CAPM

El Modelo de Valoración de Activos Financieros (CAPM, por sus siglas en inglés), desarrollado por William F. Sharpe en 1964 en su artículo “*Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk*”, supuso un avance decisivo sobre la diversificación eficiente propuesta por Markowitz. Sharpe formalizó cómo, en un mercado en equilibrio, los precios reflejan simultáneamente la tasa libre de riesgo y una prima que compensa al inversor por asumir el riesgo sistemático.

Un mercado en equilibrio es aquel en el que la oferta y la demanda de activos financieros están alineadas, de modo que no existen incentivos para que los inversores cambien sus carteras: todos los activos están correctamente valorados según su nivel de riesgo y rentabilidad esperada. En este contexto, Sharpe (1964) y Lintner (1965) establecen que únicamente el riesgo sistemático, es decir, aquel que afecta al conjunto del mercado y no puede eliminarse mediante diversificación, justifica una prima de rentabilidad, ya que el riesgo específico o idiosincrático puede mitigarse al construir carteras diversificadas.

El CAPM describe la rentabilidad exigida a un activo en equilibrio mediante la expresión:

$$E(R_i) = R_f + \beta_i(E(R_M) - R_f)$$

Donde $E(R_i)$ es la rentabilidad esperada por el activo i ; R_f es la tasa libre de riesgo (rendimiento mínimo esperado sin asumir riesgo); y $E(R_M) - R_f$ es la prima que concede el mercado por asumir riesgo.

El elemento central del CAPM es el coeficiente *beta* (β_i), que cuantifica la sensibilidad de los rendimientos de un activo i frente a las fluctuaciones del mercado y se calcula como:

$$\beta_i = \frac{Cov(R_i, R_M)}{Var(R_M)}$$

siendo $Cov(R_i, R_M)$ la covarianza entre el rendimiento del activo i y el del mercado, y $Var(R_M)$ la varianza del mercado.

Un β superior a 1 indica que el activo tiende a moverse en mayor proporción que el mercado, lo que implica una mayor volatilidad y, por tanto, un riesgo sistemático más elevado. Por el contrario, un β inferior a 1 refleja una menor volatilidad, lo que se traduce en una exposición más reducida al riesgo. Un β igual a 1 señala un comportamiento en línea con el del mercado.

Aunque los modelos de Markowitz y el CAPM constituyen los pilares de la Teoría Moderna de Carteras, presentan limitaciones al aplicarse en contextos de alta volatilidad e incertidumbre. Estas debilidades derivan de los supuestos simplificados y restrictivos sobre los que se construyen, como la estabilidad de varianzas y covarianzas o la racionalidad de los inversores. En particular, el modelo de Media-Varianza muestra una elevada sensibilidad a variaciones en las estimaciones de rentabilidad y riesgo, lo que significa que pequeños cambios en los parámetros de entrada pueden generar asignaciones inestables, es decir, carteras con composiciones muy diferentes (Michaud, 1989).

En el caso del CAPM, numerosos estudios han cuestionado su capacidad explicativa. Fama y French (2004) cuestionan la solidez empírica del modelo al demostrar que la *beta* no logra explicar por completo las diferencias en los rendimientos esperados, lo que indica que existen otros factores relevantes que influyen en la rentabilidad de los activos y que el modelo no considera. Además, investigaciones posteriores señalan que la *beta* es inestable en contextos de alta volatilidad, lo que limita su capacidad predictiva (Jagannathan & Wang, 1996).

2.4. Volatilidad Estocástica

Frente a estas limitaciones, surge la necesidad de enfoques más flexibles que representen mejor el comportamiento real del riesgo en los mercados financieros. En esta

línea, el concepto de Volatilidad Estocástica (VE) se presenta como una alternativa teórica y empírica más realista. A diferencia de los modelos tradicionales, que tratan la volatilidad como un valor fijo o determinista basado en datos históricos, los modelos de VE asumen que ésta evoluciona en el tiempo de manera aleatoria, debido a múltiples factores económicos y de mercado.

Este enfoque reconoce que el riesgo no solo cambia, sino que lo hace de forma dinámica, no lineal y, en muchos casos, impredecible. Al modelar la volatilidad como un proceso estocástico, se logra una representación más fiel de fenómenos observados en los mercados financieros.

Uno de los modelos más influyentes dentro de este contexto es el modelo de Heston (1993) que ofrece una formulación matemática específica para modelar la VE. En este enfoque, el riesgo se modeliza como un proceso dinámico y estocástico, lo que permite capturar de forma más realista dicha naturaleza cambiante e impredecible de los mercados (Ghysels et al., 1996).

Un concepto central del modelo es la reversión a la media, que explica cómo la volatilidad tiende a regresar hacia un nivel medio de largo plazo, aunque pueda desviarse temporalmente debido a eventos extremos o cambios en el entorno económico. Esta propiedad se controla mediante tres parámetros clave:

- Tasa de reversión a la media: indica la velocidad con la que la volatilidad vuelve a su nivel promedio.
- Nivel promedio: representa el valor medio al que tiende la varianza en el largo plazo.
- Volatilidad de la volatilidad: refleja cuánto puede variar la propia volatilidad en el tiempo, añadiendo una capa adicional de incertidumbre al modelo.

Este último parámetro es especialmente relevante, ya que permite reflejar episodios de alta inestabilidad, donde el riesgo no solo se incrementa, sino que lo hace de forma brusca e inesperada.

Además, el modelo incorpora la posibilidad de que exista una correlación negativa entre los retornos de los activos y su volatilidad, fenómeno conocido como “efecto palanca”. Este patrón, observado en la realidad, refleja cómo las caídas de los precios

suelen ir acompañadas de aumentos de la volatilidad, particularmente en situaciones de estrés financiero.

Desde un punto de vista práctico, este modelo ofrece ventajas significativas para la gestión de carteras. Al simular escenarios futuros de riesgo y construir matrices de covarianza dinámicas y adaptativas, el modelo de Heston mejora la calidad de las decisiones de inversión en contextos de incertidumbre. No se basa exclusivamente en promedios históricos, sino que permite anticipar comportamientos futuros más realistas, facilitando tanto la asignación eficiente de activos como la implementación de estrategias de cobertura.

2.5. Optimización Bayesiana

Además del enfoque de Volatilidad Estocástica, la Optimización Bayesiana (OB) se presenta como otra alternativa avanzada dentro de los métodos avanzados de gestión cuantitativa. Se trata de una técnica especialmente útil en entornos donde evaluar la función objetivo resulta costoso, lento o computacionalmente exigente.

Esta situación se da con frecuencia en problemas complejos, como la optimización de carteras, donde cada evaluación implica calcular métricas de rentabilidad y riesgo a partir de distintas combinaciones de activos. Frente a este problema, la OB permite recorrer el espacio de búsqueda —es decir, el conjunto de todas las combinaciones posibles de pesos— de manera eficiente, maximizando el aprendizaje de la información disponible con un número limitado de evaluaciones (Frazier, 2018).

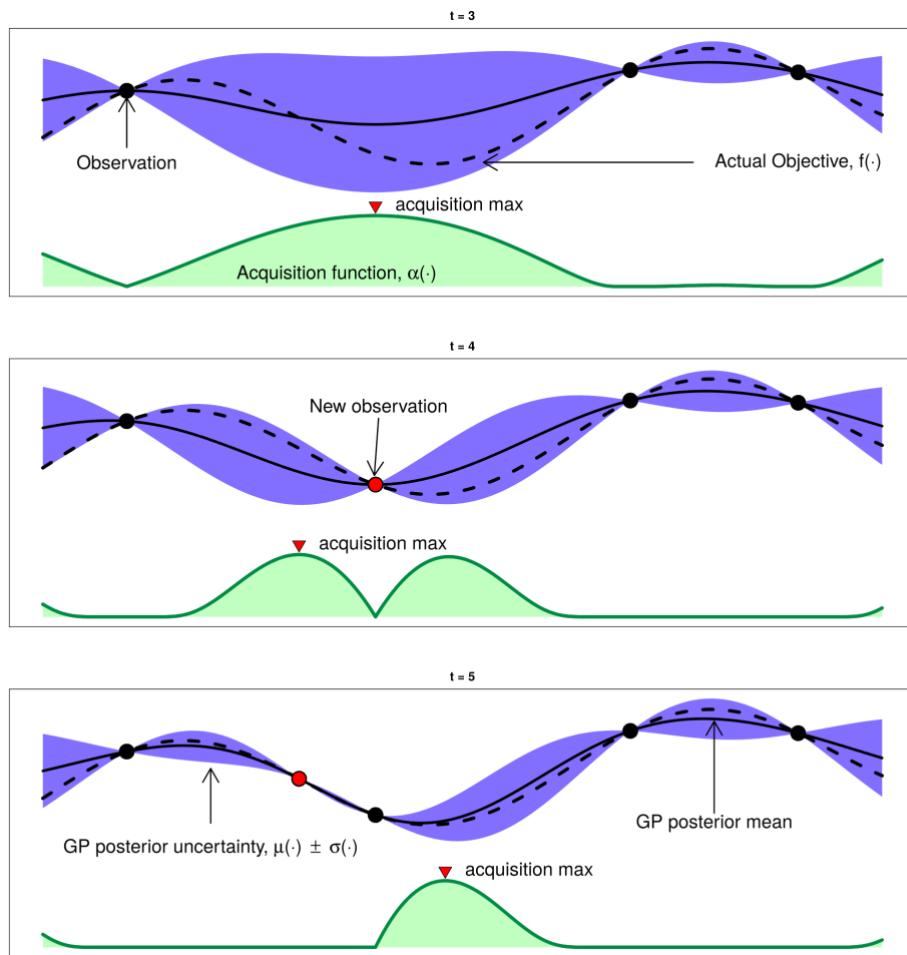
Este enfoque se basa en la construcción de un modelo probabilístico que actúa como aproximación de la función objetivo real. En lugar de tratar los parámetros —como los rendimientos esperados o las covarianzas— como valores fijos, se modelan como variables aleatorias. De este modo, cada punto del espacio de búsqueda, es decir, cada asignación de pesos se asocia no solo a una predicción del valor de la función objetivo, sino también a un grado de incertidumbre respecto a esa predicción. Esto permite representar la información parcial disponible de manera más realista y actualizable.

Este enfoque se ve complementado por los Procesos Gaussianos (GP, por sus siglas en inglés), que permiten inferir el comportamiento de la función en regiones no exploradas a partir de los datos ya observados. Los GP asumen que los valores de la función están correlacionados entre sí, de modo que conocer el resultado en ciertos puntos

permite estimar el valor en puntos cercanos. Por ello, cada nueva observación no solo aporta información local, sino que también mejora la estimación en su entorno (Rasmussen & Williams, 2006).

Este comportamiento se ilustra en la Figura 1, que muestra cómo evolucionan la predicción gaussiana (en azul) y la función de adquisición (en verde) a lo largo del proceso de optimización.

Figura 1: Funcionamiento gráfico del ciclo iterativo de la Optimización Bayesiana basado en Procesos Gaussianos



Fuente: Tomado de Garrido Merchán, E.C. (2023)

La Figura 1 ilustra de forma simplificada el funcionamiento del ciclo iterativo de OB. A partir de combinaciones ya evaluadas (puntos negros), el modelo gaussiano genera una predicción probabilística de la función objetivo desconocida, representada por una curva azul sombreada que indica tanto el valor esperado como su incertidumbre (Garrido Merchán, 2023).

A partir de estas evaluaciones, se construye una función de adquisición (línea verde), que determina cuál debe ser el siguiente punto a evaluar por el modelo (punto rojo). Esta función actúa como guía para el proceso de búsqueda, equilibrando dos objetivos fundamentales:

- Explotación: prioriza el análisis de aquellas regiones del espacio donde se han obtenido buenos resultados.
- Exploración: impulsa la búsqueda hacia zonas menos probadas, donde podrían existir soluciones óptimas aún no descubiertas (Shahriari et al., 2016).

A medida que se realizan nuevas evaluaciones, el modelo se ajusta progresivamente. El proceso gaussiano mejora sus predicciones y la función de adquisición va enfocando la búsqueda hacia las zonas con mayor potencial. En el contexto de este trabajo, donde cada combinación de pesos requiere calcular una Ratio de Sharpe mediante simulaciones, este enfoque permite encontrar soluciones eficientes sin tener que evaluar de forma exhaustiva todas las combinaciones posibles.

3. Implementación del Modelo

3.1. Dataset

Los datos utilizados en el modelo se extraen del archivo “Evolución IBEX.xlsx”, que abarca el periodo comprendido entre el 30 de diciembre de 2003 y el 19 de noviembre de 2024. Este archivo ha sido elaborado a partir de información procedente de *FactSet* y Bolsas y Mercados Españoles (BME). Contiene información sobre la composición histórica del índice, precios diarios y la tasa libre de riesgo, organizados en distintas hojas que se describen a continuación.

La hoja “*Constituents*” recoge la composición histórica del IBEX-35: cada fila corresponde a una empresa y cada columna indica la fecha en la que dicha empresa fue incluida o excluida del índice, lo que permite reconstruir con precisión los componentes vigentes en cada momento.

La hoja “*Index*” contiene los precios de cierre diarios del propio IBEX-35, mientras que la hoja “*Prices*” contiene los precios de cierre diarios de cada uno de los valores que han formado parte del índice.

Finalmente, la hoja “*Risk Free*” contiene la serie diaria del rendimiento (*yield*) del bono español a diez años (*Spain Secondary Market Benchmark Bond – 10 Year*, código TRY2ES10Y-FDS), que representa la tasa libre de riesgo anualizada.

Nota: el modelo completo se encuentra disponible en el Apéndice F.

3.2. Preparación de los datos

Como se ha mencionado anteriormente, todo proceso de optimización comienza con una fase de limpieza y preparación de los datos. El modelo desarrollado en este TFG comienza con la importación de las librerías necesarias para el análisis, así como con la carga del archivo Excel. Durante esta fase, se configuran las hojas estableciendo la columna de fecha como índice temporal, lo que permite estructurar correctamente las series cronológicas y tratar las fechas como eje del análisis.

A continuación, se alinean las series del IBEX-35 y del bono español a diez años, conservando solo los días con datos en ambas fuentes, garantizando así la consistencia. Seguidamente, se preparan los datos relacionados con el IBEX-35 con el objetivo de extraer el máximo de información sobre su evolución histórica. Para ello, se definen funciones que permiten obtener la composición del índice en cualquier fecha. Además,

como algunas compañías han modificado su código bursátil a lo largo del tiempo, como es el caso de “REE”, que pasa a “RED” o “GAS”, a “NTGY”, se homogenizan los códigos utilizando la denominación más reciente para mantener la consistencia. Por último, se definen funciones para calcular los rendimientos del índice y de sus componentes en cualquier intervalo temporal, lo que permite obtener métricas como las rentabilidades anuales o las volatilidades de ambos.

Posteriormente se define una función clave para el *backtesting* del modelo, una práctica esencial en cualquier enfoque cuantitativo. Esta técnica consiste en aplicar una estrategia a datos históricos con el fin de estimar su rendimiento y evaluar su comportamiento antes de implementarla en condiciones reales de mercado. En el modelo, el núcleo de este proceso es la función “rendimiento_año_siguiente”, que recibe una combinación de activos (representada por sus pesos) y un año de inicio. A partir de estos datos, extrae los rendimientos reales del ejercicio siguiente, y calcula la rentabilidad que habría obtenido dicha cartera durante dicho ejercicio.

Finalmente, el bloque de preparación concluye con la definición de varias funciones auxiliares que facilitan el análisis e interpretación de los resultados. Estas funciones permiten visualizar y comparar las rentabilidades obtenidas, así como identificar los pesos óptimos y las Ratios de Sharpe correspondientes para cada estrategia en cada año.

Nota: por simplificación y dado el objetivo de aislar puramente el comportamiento de la optimización, en este modelo no se incorporan costes de transacción ni criterios de liquidez.

3.3. Métricas de rendimiento y riesgo

En el modelo se emplean dos métricas para evaluar la eficiencia de las carteras: la rentabilidad y la volatilidad anualizadas. La rentabilidad anualizada permite comparar de forma homogénea el crecimiento medio esperado de la inversión. Por otro lado, la volatilidad anualizada se emplea como medida de riesgo, ya que mide la variabilidad de los rendimientos en torno a su media, es decir, desviación típica. Una mayor volatilidad implica una mayor incertidumbre sobre los rendimientos, lo que se traduce en un mayor nivel de riesgo.

Para combinar ambas variables en una sola métrica que mida el rendimiento ajustado al riesgo, se emplea la Ratio de Sharpe, que se expresa de la siguiente manera:

$$\text{Ratio de Sharpe} = \frac{R_c - R_f}{\sigma_c}$$

donde R_c es el rendimiento esperado de la cartera, R_f la tasa libre de riesgo, y σ_c la volatilidad de la cartera. Esta ratio permite evaluar si la rentabilidad adicional obtenida por la cartera compensa el riesgo asumido.

Una ratio superior a 1 indica una excelente compensación entre riesgo y rentabilidad, ya que por cada unidad de riesgo asumido se obtiene más de una unidad de rendimiento adicional. Un valor positivo menor a 1 sugiere que la rentabilidad es positiva, pero no excesivamente alta en relación con el riesgo asumido. Aun así, puede considerarse aceptable dependiendo del perfil del inversor. Una ratio negativa refleja que la rentabilidad de la cartera es inferior a la tasa libre de riesgo, lo que indica una mala relación riesgo-rentabilidad. Por lo tanto, cuanto mayor sea el valor de la ratio, mayor será el atractivo para el inversor (Sharpe, 1994).

La elección de estas métricas responde a su amplia aceptación tanto en la literatura como en la práctica financiera. Son herramientas estándar en informes de fondos y estudios académicos, destacando por su claridad y utilidad. Además, para realizar un análisis más completo, el modelo calcula la Ratio de Sharpe *ex ante* y *ex post*. La primera corresponde al valor teórico obtenido en la fase de optimización, mientras que la segunda refleja el rendimiento real tras la implementación. Comparar ambas permite evaluar la precisión y coherencia entre los resultados esperados y los obtenidos.

3.4. Escenarios de restricciones

En este trabajo se han definido tres escenarios de restricciones de pesos para evaluar cómo influyen los límites regulatorios y estratégicos en los resultados de las carteras optimizadas. Cada escenario representa un marco de inversión concreto, desde un caso teórico sin restricciones hasta la aplicación de dos criterios regulatorios distintos a fondos de inversión en Europa y Estados Unidos. Esto permite realizar una comparación de resultados en contextos realistas.

El primer escenario, denominado “Sin límites”, sólo impone la condición de que todos los pesos sean no negativos y sumen uno. Este caso puramente teórico sirve como punto de partida, prohibiendo las posiciones cortas (ventas de activos que no se poseen) y asegurando que se invierta el 100% del capital disponible, sin permitir apalancamiento ni fondos no invertidos.

El segundo escenario aplica las reglas UCITS 5/10/40, derivadas de la Directiva 2009/65/CE de la Unión Europea (Parlamento Europeo y Consejo de la Unión Europea, 2009). Según esta normativa, ningún activo puede superar el 10% del valor de la cartera, mientras que el conjunto de valores que excedan el 5% no puede representar más del 40%. Estas restricciones constituyen el estándar para la mayoría de los fondos de inversión europeos, al proteger al inversor de carteras excesivamente concentradas.

El tercer escenario reproduce la normativa estadounidense RIC 25/50, y establece los requisitos para que un vehículo de inversión colectiva se beneficie del tratamiento fiscal reservado a los *Regulated Investment Companies* (*mutual funds* y *ETFs*). En este escenario, ningún valor puede superar el 25% del valor de la cartera, y la suma de las dos posiciones de mayor ponderación no debe exceder el 50% (26 U.S.C. § 851(b)(3), 1986). Estas restricciones, más laxas que las UCITS, buscan equilibrar la libertad de gestión con la protección del inversor.

A continuación, la Tabla 1 muestra un resumen comparativo de las restricciones de pesos en cada escenario.

Tabla 1: Escenarios de restricciones de pesos

Escenario	Inversión total	Peso mínimo por activo	Peso máximo por activo	Límite agregado
Sin límites	100% del capital	0%	100%	Sin límite
UCITS 5/10/40	100% del capital	0%	10%	Activos \geq 5% suman \leq 40%
RIC 25/50	100% del capital	0%	25%	Dos mayores posiciones suman \leq 50%

Fuente: Elaboración propia

Para simular distintos escenarios de inversión sin necesidad de modificar el código, el modelo define una serie de parámetros configurables:

- “peso_min”: peso mínimo permitido por activo (siempre 0, evitando posiciones cortas).
- “peso_max”: peso máximo permitido por activo.

- “umbral”: peso a partir del cual un activo se considera “concentrado”.
- “peso_conc_max”: límite agregado de esos activos “concentrados”.
- “peso_total”: suma objetivo de todos los pesos. (siempre 1, para invertir el 100% del capital).

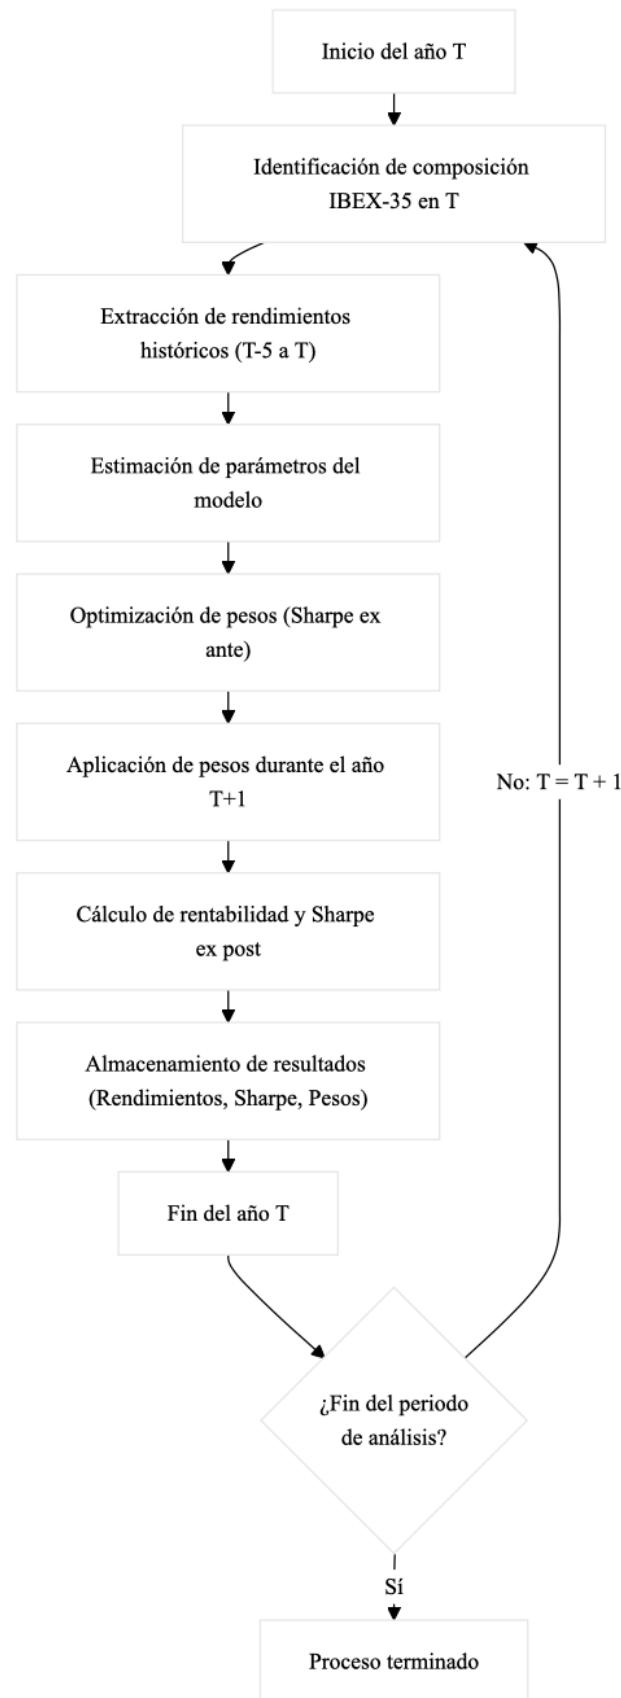
Gracias a este diseño parametrizable, el modelo permite adaptar la optimización a distintos escenarios simplemente ajustando los valores de entrada, sin alterar su lógica interna. Esto garantiza una comparabilidad coherente y facilita la incorporación de futuras normativas, permitiendo explorar con agilidad la influencia de distintas políticas de inversión.

3.5. Flujo general de la optimización

Una vez completadas las etapas de limpieza y preparación descritas en los apartados anteriores, el proceso de optimización propiamente dicho se ejecuta con frecuencia anual. En cada iteración el modelo (i) localiza la última sesión bursátil del ejercicio; (ii) obtiene la composición del IBEX-35 en esa fecha; (iii) obtiene, para cada componente, los rendimientos correspondientes a un horizonte de cinco años (60 meses), definido por el parámetro “años_atras”; (iv) calcula los pesos óptimos de la cartera para ese año; (v) simula el comportamiento de la cartera durante el ejercicio siguiente manteniendo constantes los pesos obtenidos; y (vi) guarda los resultados.

Con el objetivo de facilitar la comprensión del proceso, la Figura 2, presentada a continuación, muestra el diagrama de flujo general aplicado en el modelo. Este esquema resume los pasos comunes a todos los enfoques implementados, y permite visualizar de forma clara la secuencia de cálculo, aplicación y evaluación que se repite a lo largo del periodo analizado.

Figura 2: Diagrama de flujo general de optimización



Fuente: Elaboración propia

La elección de los 5 años del parámetro “años atras” está respaldada tanto por la práctica profesional como por la literatura, pues es un horizonte ampliamente utilizado. Un periodo de cinco años ofrece un equilibrio razonable, ya que es suficientemente amplio como para incluir distintos ciclos económicos (expansión y recesión), pero no tan largo como para que datos demasiado antiguos afecten negativamente a la precisión de las estimaciones.

Esto implica que el modelo aplica una técnica de ventanas móviles (*rolling windows*), que consiste en dividir la serie temporal en tramos consecutivos de una duración fija, llamados "ventanas". En cada ventana, el modelo se entrena y se evalúa de forma independiente. Una vez procesada una ventana, esta se desplaza y el proceso se repite.

Esta metodología permite evaluar el rendimiento del modelo de forma coherente a lo largo del tiempo y garantiza que los distintos enfoques sean comparados bajo las mismas condiciones. Al mismo tiempo, ayuda a reducir el riesgo de sobreajuste, es decir, cuando un modelo aprende demasiado sobre los patrones específicos de los datos con los que fue entrenado, en lugar de capturar las tendencias generales.

Este planteamiento forma parte de las filosofías del tipo *Smart Beta*, ya que modifica sistemáticamente los pesos de un índice para mejorar su perfil riesgo-rendimiento. Sin embargo, a diferencia de las estrategias *Smart Beta* tradicionales basadas en factores como valor, tamaño o *momentum* (tendencia de los activos a mantener su rendimiento reciente), la optimización en este trabajo se centra directamente en la maximización de la Ratio de Sharpe.

En los apartados siguientes se detallan los dos grandes ejes que realizan el flujo de optimización.

3.5.1. Eje I – Análisis individual por enfoque

Este primer eje desarrolla la lógica de cada enfoque de manera independiente, y se organiza internamente en dos bloques funcionales: el Bloque I, centrado en la optimización puntual, y el Bloque II, encargado del análisis histórico a través de *backtesting*. A continuación, se describen en detalle estos bloques.

Bloque I – Funciones auxiliares y optimización puntual

El Bloque I representa la base operativa de cada enfoque. En él se implementan de forma independiente todas las funciones necesarias para preparar los datos, calcular los

parámetros necesarios y resolver el problema de optimización correspondiente a un periodo específico. Para asegurar la calidad y consistencia de la información, se requiere que cada activo disponga de al menos el 80 % de los datos dentro del intervalo temporal considerado.

La función principal de este bloque toma como entrada un año de referencia y el parámetro “años_atras”, junto con los rendimientos diarios de la ventana. Antes de ejecutar el proceso, se anualizan los datos de rentabilidad y riesgo, de modo que las métricas calculadas sean comparables entre activos. Como resultado, la función devuelve un vector con los pesos óptimos de la cartera y el valor de la Ratio de Sharpe *ex ante* correspondiente a ese periodo. Esta modularidad permite introducir ajustes específicos en cada enfoque sin alterar la arquitectura global del código.

Bloque II – Iteración anual y *backtesting*

El Bloque II complementa al anterior y automatiza el proceso de evaluación histórica, ejecutando de forma iterativa la optimización anual. Para cada ejercicio, se ejecuta la función principal desarrollada en el Bloque I, encargada de calcular los pesos óptimos para cada enfoque a partir de la información histórica disponible en la ventana definida. Una vez obtenidos, se aplica la función “rendimiento_año_siguiente”, responsable de estimar la rentabilidad anual que habría obtenido la cartera bajo condiciones reales de mercado.

A continuación, esta rentabilidad se compara con la del IBEX-35 en el mismo intervalo, y se calcula el *alfa*, entendido como la diferencia entre la rentabilidad de la estrategia y la del índice. Todos los resultados relevantes, como las Ratio de Sharpe, los pesos óptimos, la rentabilidad y el *alfa* generado, se almacenan de forma estructurada. Esto facilita su análisis permitiendo evaluar los resultados de cada enfoque a lo largo del tiempo.

Una vez definidos y ejecutados ambos bloques para cada enfoque, el análisis se amplía con el segundo eje del modelo, enfocado en la comparativa entre estrategias bajo distintos escenarios.

3.5.2. Eje II – Comparativa de escenarios

Este segundo eje se apoya directamente en los resultados obtenidos en el Eje I y permite evaluar conjuntamente los distintos enfoques bajo diferentes restricciones de

inversión. A partir de los dos bloques anteriores se construye una función general que permite comparar los distintos enfoques a lo largo del tiempo y en distintos escenarios. Esta función recibe como argumentos el año inicial, el año final y el valor del parámetro “años_atras”, que define la longitud de la ventana histórica utilizada para la optimización. Previo a cada iteración, se ajustan los límites sobre los pesos con el objetivo de generar los distintos escenarios de inversión.

Durante cada iteración anual, la función utiliza la lógica definida en el Bloque II, que automatiza todo el proceso: primero calcula los pesos óptimos, las rentabilidades teóricas y la Ratio de Sharpe *ex ante* a partir de los datos históricos (Bloque I) y después aplica esos pesos para medir la rentabilidad real y la Ratio de Sharpe *ex post*. De este modo, se integran ambos bloques dentro de un mismo flujo de trabajo, permitiendo evaluar los cuatro enfoques de forma coherente en cada escenario.

La función devuelve cinco estructuras de datos:

- Resultados *ex ante*: recogen, para cada año y método, la rentabilidad esperada y la Ratio de Sharpe teórica calculada durante la fase de optimización.
- Resultados *ex post*: contienen los rendimientos reales obtenidos tras aplicar los pesos optimizados sobre el año siguiente, junto con las Ratios de Sharpe observadas. Permiten evaluar el rendimiento efectivo de cada estrategia.
- Tabla comparativa: incluye el *alfa* de cada enfoque (diferencia frente al IBEX-35) y la variación entre el Sharpe *ex post* y *ex ante* ($\Delta\text{Sharpe} = \text{Sharpe ex post} - \text{Sharpe ex ante}$, expresada en puntos de la Ratio de Sharpe), ofreciendo una visión clara de la precisión de las estimaciones y la coherencia entre teoría y práctica. También incorpora una fila de promedio para facilitar la comparación global entre métodos.
- Rentabilidades anuales: muestra la evolución año a año de la rentabilidad de cada estrategia junto con la del IBEX-35.
- Evolución del capital invertido: refleja cómo habría crecido una inversión inicial de 100€ a lo largo del tiempo bajo cada enfoque, considerando la reinversión anual de beneficios.

3.5.3. Parámetros y decisiones comunes

A lo largo de todos los enfoques y escenarios se mantienen una serie de decisiones y parámetros comunes que garantizan la homogeneidad del análisis, su validez comparativa y la posibilidad de evaluar de forma objetiva el rendimiento relativo de cada enfoque. A modo de resumen, se recogen a continuación las principales decisiones metodológicas, ya justificadas en apartados anteriores:

- Ventana: cinco años (60 meses).
- Cobertura mínima de datos: al menos el 80% de observaciones por activo.
- Restricción *long-only*: se excluye cualquier tipo de venta en corto.
- Tasa libre de riesgo: media aritmética del rendimiento libre de riesgo de la ventana analizada.
- Pesos iniciales de la cartera: con distribución equiponderada (por igual entre los activos), ya que es compatible con los requisitos de los tres escenarios analizados.

3.6. Implementación de cada enfoque

3.6.1. Modelo de Media-Varianza

Como se ha detallado con anterioridad, el Modelo de Media-Varianza se estructura en torno a tres componentes esenciales: los rendimientos esperados, la matriz de covarianzas y un vector de pesos. Todos ellos pueden estimarse a partir de los rendimientos históricos. Para ilustrar su aplicación, se analiza el caso de optimización correspondiente al ejercicio 2022, bajo el Escenario 1, denominado “Sin límites”.

El proceso comienza con la identificación de la composición de la cartera al cierre del último día hábil de 2022. A continuación se extraen los rendimientos diarios de cada componente durante los cinco años previos (desde el 02/01/2018 hasta el 30/12/2022). Se construye la matriz de covarianzas y, para estimar los rendimientos esperados, se calcula el promedio aritmético de los rendimientos históricos de cada activo. Además, se incorpora la media de la tasa libre de riesgo durante la ventana.

Una vez definidos los parámetros del modelo, se procede a anualizar tanto el promedio de rendimientos como la matriz de covarianzas. A continuación, estos valores se introducen en el optimizador para calcular la asignación óptima de activos. El resultado para el ejercicio 2022 es el siguiente:

Tabla 2: Distribución óptima de pesos según el Modelo de Media-Varianza (2022, Escenario 1)

Ticker	Pesos
ANA	21,82%
CLNX	9,90%
LOG	1,41%
ROVI	30,18%
SLR	36,69%

Fuente: Elaboración propia

La Ratio de Sharpe *ex ante* obtenida por esta cartera es de 1,21. Posteriormente, su rendimiento se evalúa durante el año 2023, obteniendo una rentabilidad anual del 16,53%, y una Sharpe *ex post* de 0,68.

3.6.2. CAPM

El proceso de optimización del CAPM sigue una lógica muy similar a la del Modelo de Media-Varianza. Mientras que este último estima los rendimientos esperados a partir de promedios históricos, el CAPM propone un enfoque diferente. Según este método, los rendimientos esperados no deben depender exclusivamente de datos pasados, sino que deben explicarse en función del riesgo sistemático de cada activo.

Para calcular dicho riesgo, se define una función denominada “*betas*” que recibe tanto los rendimientos diarios de los activos como los del IBEX-35. Esta función alinea las fechas comunes entre ambos conjuntos de datos y calcula, a partir de ellas, la sensibilidad de cada activo al mercado, es decir, su *beta*.

A continuación, se implementa la función “*betas_periodo*”, encargada de seleccionar la ventana histórica correspondiente (siguiendo las decisiones previamente definidas en cuanto a horizonte temporal y cobertura mínima de datos) y que ejecuta internamente la función anterior para obtener el vector de *betas*.

A modo de ejemplo, las *betas* calculadas para el mismo periodo que en el enfoque anterior (02/01/2018 - 30/12/2022) son:

Tabla 3: Estimación de *betas* del IBEX-35 a cierre de 2022 (datos de 2018-2022)

ACS	1.1731	AMS	0.9666	COL	0.7713
ACX	0.8855	ANA	0.8174	ELE	0.6083
AENA	0.8914	BBVA	1.4631	ENG	0.6025
ALM	0.4851	BKIA	1.3160	FER	0.8515
BKT	1.0858	CABK	1.3327	GRF	0.5004
CIE	0.8564	CLNX	0.5392	IAG	1.5459
IBE	0.6871	IDR	0.8903	ITX	0.8842
MAP	1.0549	MEL	1.1884	MRL	0.7798
MTS	1.4691	NTGY	0.7691	PHM	0.8548
RED	0.4553	REP	1.1823	SAB	1.5800
SAN	1.5337	SGRE	0.8176	SLR	0.8363
TEF	1.1092	VIS	0.3495		

Fuente: Elaboración propia

Una vez obtenido el vector de *betas*, se procede al cálculo de los rendimientos esperados mediante la ecuación del CAPM, tal y como se explicó en el apartado 2.3. Para ello, se implementa la función “rendimiento_esperado_CAPM”, que recibe como parámetros las *betas*, la tasa libre de riesgo (1,08% para el periodo) y el rendimiento anualizado esperado del mercado (-0,97%). Este último se obtiene a partir del promedio de los rendimientos diarios del IBEX-35 durante la ventana analizada, y se anualiza para asegurar la consistencia con la tasa libre de riesgo, que ya se expresa en términos anuales.

Aplicando la fórmula del CAPM, la función devuelve el rendimiento esperado de cada activo en función de su exposición al riesgo sistemático. Por ejemplo, en el caso de ACS:

$$E(ACS) = 1,08\% + 1.1731 \times (-0,97\% - 1,08\%) = -1,33\%$$

Una vez calculados los rendimientos esperados, el proceso de optimización procede exactamente igual que en el Modelo de Media-Varianza. Con los retornos esperados definidos a través del CAPM y la matriz de covarianzas calculada a partir de los rendimientos históricos, se introducen todos los parámetros en el optimizador, manteniendo las restricciones previamente establecidas. El algoritmo parte de una cartera inicial euiponderada y ajusta iterativamente los pesos hasta maximizar la Ratio de Sharpe.

La cartera óptima según el CAPM para el año 2022 asigna el 100% del capital a Solaria (SLR). La Ratio de Sharpe asociada a esta cartera es de -0,0439. A pesar de este bajo desempeño esperado, la cartera habría obtenido una rentabilidad del 7,54% durante

el año 2023 y una Ratio *ex post* de 0,27. Para un estudio similar de comparación de modelos, véase Pástor & Stambaugh (2000).

3.6.3. Volatilidad Estocástica

La implementación del modelo de Volatilidad Estocástica requiere una preparación adicional respecto a los enfoques anteriores, ya que el modelo de Heston introduce una mayor complejidad en el tratamiento del riesgo. La integración en el proceso de optimización se estructura en cuatro etapas principales.

1. Estimación de los parámetros del modelo de Heston

El primer paso consiste en definir una función que, a partir de una serie de rendimientos del índice, estima los cuatro parámetros característicos del modelo de Heston. Aplicando esta función sobre el conjunto completo de rendimientos del IBEX-35, se obtienen los siguientes valores:

- Velocidad de reversión o *Kappa* ($\kappa \approx 0,8427$): un valor cercano a 1 indica que, tras movimientos bruscos, el mercado tiende a estabilizarse rápidamente.
- Varianza de equilibrio o *Theta* ($\theta \approx 0,0001871$): un valor reducido sugiere que, pese fluctuaciones puntuales, la varianza tiende a estabilizarse en niveles bajos.
- Volatilidad de la volatilidad o *Sigma* ($\sigma \approx 0,0008508$): un valor bajo implica que los cambios en la volatilidad son graduales, lo que reduce la incertidumbre sobre el riesgo futuro y facilita la gestión de carteras.
- Correlación retornos-varianza o *Rho* ($\rho \approx -0,0607$): un valor ligeramente negativo sugiere un “efecto palanca” o *leverage effect*, donde las caídas de precio suelen ir acompañadas de aumentos de volatilidad. Aunque la relación es débil, sugiere que periodos de estrés el riesgo podría amplificarse.

2. Simulación de volatilidades dinámicas

El segundo paso consiste en definir una función que, utilizando los parámetros estimados (κ , θ , σ y ρ), simula la evolución diaria de la varianza para cada activo. Estas simulaciones se realizan individualmente y generan series temporales de varianzas estrictamente positivas. A continuación, estas se transforman en desviaciones típicas (volatilidades), lo que facilita su interpretación y posterior uso en la estimación del riesgo.

3. Estimación del riesgo conjunto

En la tercera etapa se definen dos funciones para, a partir de las volatilidades simuladas, estimar el riesgo conjunto entre activos a lo largo del tiempo:

La función “covarianza_dinamica” calcula una matriz de covarianzas diaria. Para cada día del periodo analizado, extrae las volatilidades de los activos y las combina con la matriz histórica de correlaciones. El resultado se anualiza, generando una secuencia de matrices que capturan la evolución dinámica del riesgo.

Posteriormente, la función “covarianza_dinamica_promedio” recibe esta secuencia y calcula una única matriz representativa para el periodo en cuestión. Dicha matriz resume el comportamiento conjunto del riesgo durante la ventana y se ajusta a la composición real del índice en ese momento.

4. Generación de matrices específicas por año

Finalmente, se introduce una función adicional, “volatilidades_dinamicas”, que permite aplicar este enfoque sobre una ventana concreta, en lugar de sobre todo el histórico. Esta función recibe los parámetros estimados del modelo de Heston y una serie de rendimientos diarios de los componentes, y simula la evolución de la varianza para cada activo. Los resultados se almacenan como matrices de varianzas simuladas, que luego se emplean para calcular matrices de covarianza anuales.

Una vez generada la matriz de riesgo para un año concreto, se procede con la optimización de pesos. El esquema sigue la lógica común al resto de enfoques: se calculan los rendimientos esperados como el promedio histórico anualizado, y se optimizan los pesos buscando maximizar la Ratio de Sharpe. La principal diferencia reside en que la matriz de covarianzas no se obtiene a partir de los retornos históricos, sino que se deriva de simulaciones estocásticas de volatilidad.

En cada iteración anual del modelo se sigue un procedimiento estructurado. En primer lugar, se fija una semilla aleatoria específica para el año correspondiente, lo que garantiza la reproducibilidad de los resultados. A continuación, se extraen los rendimientos diarios tanto de los componentes del índice como del propio IBEX-35. A partir de los rendimientos del índice, se estiman los parámetros del modelo de Heston para ese periodo.

Utilizando dichos parámetros, se generan 500 simulaciones independientes de volatilidad, un número seleccionado por su equilibrio entre variabilidad estadística y

eficiencia computacional. En cada simulación, se calcula la matriz de covarianza promedio para el año, siguiendo los mecanismos previamente descritos. Por último, esta matriz se introduce en el optimizador, junto con los rendimientos esperados de cada activo, para obtener la asignación óptima de la cartera.

En el marco del escenario “Sin límites”, la optimización para el año 2022 asignó los siguientes pesos óptimos:

Tabla 4: Distribución óptima de pesos según el Modelo de Heston (2022, Escenario 1)

Ticker	Pesos
ANA	13,44%
ROVI	5,49%
SLR	81,07%

Fuente: Elaboración propia

La cartera resultante presenta una Ratio de Sharpe *ex ante* de 1,85 y un rendimiento esperado del 55,98%. Al evaluar su comportamiento durante el año 2023, habría alcanzado una rentabilidad real del 6,03%, con un Sharpe *ex post* de 0,23.

3.6.4. Optimización Bayesiana

La implementación de la Optimización Bayesiana sigue una lógica muy similar a la del Modelo de Media-Varianza, ya que mantiene la misma función de iteración anual, y el principal cambio es la manera de calcular los pesos óptimos. Sin embargo, la estructura original no es compatible con este tipo de optimización, ya que la función objetivo y las restricciones no están diseñadas para interactuar adecuadamente con el algoritmo bayesiano.

Por este motivo, se define una nueva función objetivo específica para este enfoque. Esta función incluye penalizaciones severas cuando no se cumplen las restricciones, lo que fuerza al algoritmo a evitar soluciones no válidas. Gracias a esta reformulación, es posible aplicar la Optimización Bayesiana de forma efectiva dentro del mismo esquema general.

Además, una característica relevante de la implementación es que se ha definido un doble criterio de convergencia con el objetivo de hacer el proceso más eficiente. Por un lado, se establece un número máximo de iteraciones (`n_calls = 400`), lo que limita el número total de evaluaciones de la función objetivo. Este valor se ha seleccionado por

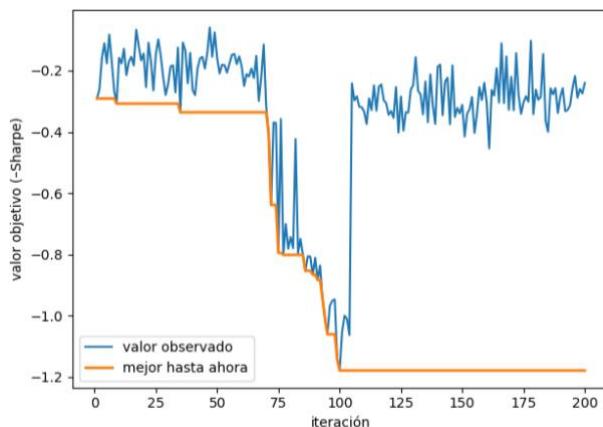
equilibrar adecuadamente precisión y tiempo de cómputo, tras realizar varias pruebas preliminares.

Por otro lado, el optimizador se inicia con 70 puntos iniciales (`n_initial_points = 70`), que son soluciones generadas de forma aleatoria al principio del proceso. Estos puntos permiten explorar bien el espacio de búsqueda antes de que el modelo comience a explotar las zonas más prometedoras. El número 70 se ha escogido teniendo en cuenta que las carteras están compuestas por un máximo de 35 activos, y, por tanto, el espacio de soluciones es relativamente acotado. Es importante que el algoritmo tenga suficiente variabilidad inicial para no quedar atrapado en óptimos locales. En otras palabras, se ha priorizado una exploración inicial amplia para garantizar que el modelo tenga buena información sobre distintas regiones del espacio de búsqueda desde el principio.

Sin embargo, para evitar gastar recursos innecesarios en años donde el modelo converge rápidamente, se ha añadido un segundo criterio de parada anticipada. Si durante 100 iteraciones consecutivas no se mejora el valor óptimo en al menos un 0,01 %, se considera que el modelo ha llegado a una solución suficientemente buena y se detiene. En resumen, cada año puede tener como máximo 400 iteraciones, pero si el progreso se estanca antes, el proceso se corta automáticamente.

En el caso del año 2022 (para el escenario “Sin límites”), el modelo se detuvo tras 200 iteraciones, lo que indica que se alcanzó la convergencia antes del límite máximo. La evolución del proceso de búsqueda se muestra en la siguiente figura:

Figura 3: Evolución del valor objetivo durante la Optimización Bayesiana (2022, Escenario 1)



Fuente: Elaboración propia

La Figura 3 muestra la evolución del valor objetivo (Ratio de Sharpe) a lo largo de las iteraciones. Se observa una primera fase de exploración con valores inestables,

seguida de un descenso abrupto en torno a la iteración 70, donde el modelo encuentra una región óptima, y comienza a explotarla. A partir de la iteración 100, la línea naranja (que representa el mejor valor encontrado hasta el momento) se estabiliza, lo que confirma que la solución convergió antes de agotar el límite de iteraciones.

En el marco del escenario “Sin límites”, la Optimización Bayesiana aplicada al ejercicio 2022 asignó los siguientes pesos óptimos:

Tabla 5: Distribución óptima de pesos según el Modelo de Optimización Bayesiana (2022, Escenario 1)

Ticker	Pesos
ANA	25%
CLNX	25%
ROVI	25%
SLR	25%

Fuente: Elaboración propia

La cartera resultante presenta una Ratio de Sharpe *ex ante* de 1,18 y un rendimiento esperado del 31,62%. Durante el año 2023, esta asignación habría alcanzado una rentabilidad real del 13,86%, con un Sharpe *ex post* de 0,59.

4. Resultados

4.1. Escenario 1: Sin límites

En el Escenario 1, caracterizado por un entorno puramente teórico sin restricciones, no se imponen límites a los pesos de los activos ni requisitos de diversificación. El objetivo es analizar el comportamiento “natural” de cada enfoque cuando opera con total libertad. En estas condiciones, cada enfoque adopta una forma muy distinta de repartir el capital.

Nota: el desglose completo de pesos por activo y por año para cada enfoque, así como las tablas con los resultados *ex ante* y *ex post* de cada escenario, puede consultarse en el Apéndice.

La Tabla 6, presentada a continuación, muestra para cada método el *alfa* y la variación absoluta de la Ratio de Sharpe a lo largo del periodo, lo que permite comparar de forma directa su rendimiento teórico y real. El *alfa* se expresa en puntos porcentuales, y la variación de la Ratio de Sharpe ($\Delta \text{Sharpe} = \text{Sharpe ex post} - \text{Sharpe ex ante}$) se mide en puntos de Ratio de Sharpe. Por ejemplo, un Δ Sharpe de 0,50 significa que el Sharpe observado fue 0,50 unidades superior al estimado.

Tabla 6: Comparativa *ex post*: *alfa* y desviación de la Ratio de Sharpe (Escenario 1)

Año	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe
2011	11,30%	-1,539	26,31%	3,001	9,46%	-2,625	15,60%	0,107
2012	86,37%	2,148	-51,96%	-0,694	78,57%	1,749	92,21%	2,359
2013	-3,50%	0,097	108,14%	2,253	-6,47%	-0,156	0,89%	0,766
2014	11,31%	-0,580	2,26%	0,252	7,19%	-1,113	-0,50%	-1,175
2015	18,02%	-0,179	-38,32%	-0,512	14,87%	-0,323	19,96%	-0,123
2016	-1,57%	-1,391	-4,98%	0,060	-0,01%	-1,549	0,17%	-0,892
2017	13,14%	1,769	2,39%	1,336	7,76%	0,614	11,05%	1,697
2018	27,79%	-0,142	8,88%	-0,973	17,42%	-1,573	22,75%	-0,421
2019	1,61%	-0,299	-23,41%	-0,004	-1,73%	-0,549	3,49%	0,030
2020	23,92%	-0,826	4,84%	0,067	49,12%	-0,321	23,47%	-0,683
2021	-26,30%	-3,493	21,36%	2,102	-25,37%	-3,925	-10,55%	-1,563
2022	-35,63%	-3,792	20,84%	0,492	-27,76%	-4,044	-17,91%	-2,612
2023	-6,24%	-0,533	-15,22%	0,321	-16,73%	-1,621	-8,90%	-0,587
Promedio	9,25%	-0,674	4,70%	0,592	8,18%	-1,187	11,67%	-0,238

Fuente: Elaboración propia con datos extraídos de *FactSet*

Comenzando con el Modelo de Media-Varianza, este se caracteriza por carteras altamente concentradas: durante los primeros años, por ejemplo, Grifols (GRF) e Inditex (ITX) llegaron a acumular más del 50% de la cartera entre 2011 y 2014. Esta

concentración contribuye a generar Ratios de Sharpe *ex ante* elevadas, con un promedio de 1,19 en el conjunto del periodo.

No obstante, la limitada diversificación también se traduce en una mayor exposición a errores de estimación y a eventos inesperados, lo que reduce notablemente la consistencia de los resultados reales (diferencia de Sharpe promedio de -0,67, como se observa en la Tabla 6). Aun así, la fuerte concentración hace que los *alfas* obtenidos sean extremos —positivos en algunos casos y negativos en otros—, pero en conjunto, logra un *alfa* medio del 9,25%.

Por su parte, el CAPM lleva esta concentración al extremo: en varios ejercicios invierte el 100% del capital en un único activo (por ejemplo, en 2011 en Grifols, y en 2012–2013 en Sacyr), y en los años en los que diversifica, lo hace o de forma mínima o extrema. Esta asignación refleja la dependencia total del modelo respecto a una única variable explicativa: la *beta*. En consecuencia, las estimaciones *ex ante* son poco realistas, con rendimientos esperados negativos en seis de los trece años analizados, y un Sharpe medio de -0,04.

A pesar de estas previsiones poco prometedoras, los resultados reales son mucho más favorables. El modelo logra obtener un Sharpe *ex post* medio de 0,55, y un *alfa* promedio positivo del 4,70%, lo que indica que, aunque el modelo no es fiable como estimador de riesgo, ha logrado superar al índice en términos absolutos. Esta contradicción se explica por el bajo rendimiento esperado del mercado —calculado como el promedio histórico del IBEX-35—, que arrastra las estimaciones del CAPM a valores excesivamente conservadores. Sin embargo, durante el proceso de optimización, el modelo selecciona activos con *betas* elevadas que, en la práctica, han ofrecido rentabilidades superiores al índice, lo que permite obtener resultados razonables a pesar de unas previsiones poco prometedoras.

El modelo de Volatilidad Estocástica suaviza parcialmente la concentración observada en los enfoques anteriores. Aunque mantiene un sesgo hacia valores recurrentes como Grifols, Amadeus o Inditex, suele repartir el capital entre más activos, lo que permite mitigar parte del riesgo idiosincrático. Esta diversificación algo mayor, unida a una estimación más sofisticada de la volatilidad, se traduce en previsiones muy optimistas: el modelo alcanza un Sharpe *ex ante* medio de 1,53, el más alto entre los cuatro enfoques analizados.

Sin embargo, esta aparente solidez teórica se ve diluida cuando se evalúa el comportamiento real de las carteras. El Sharpe *ex post* promedio cae hasta 0,34, con una diferencia media de -1,19 respecto a las previsiones, la mayor desviación del conjunto. Este resultado sugiere que, aunque el modelo captura bien el riesgo desde un punto de vista técnico, es muy sensible a las condiciones específicas del mercado y a la aleatoriedad de las simulaciones anuales. Aun así, la estrategia logra un *alfa* medio positivo del 8,18%, lo que confirma su capacidad para generar valor, especialmente en ejercicios donde las condiciones del mercado se alinean con las hipótesis del modelo.

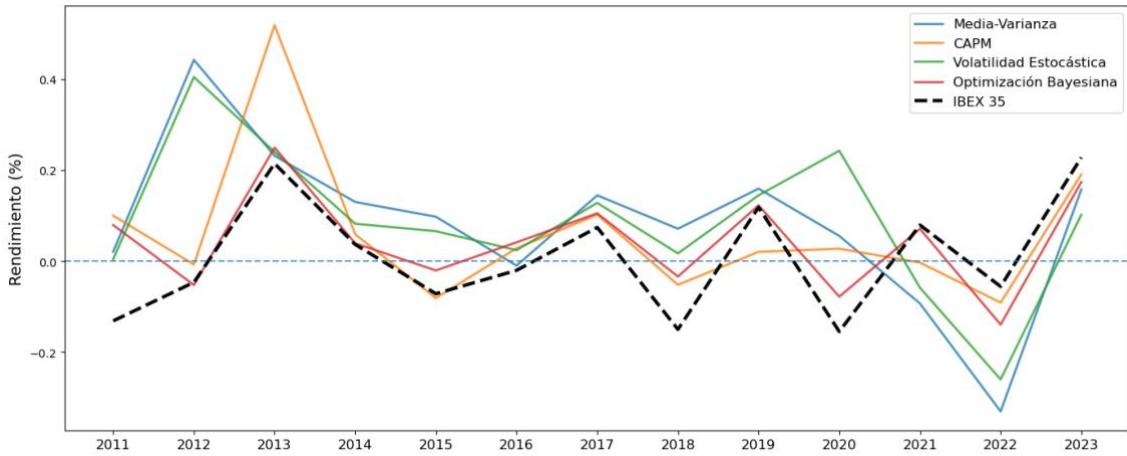
La Optimización Bayesiana se desmarca del resto de enfoques por construir carteras mucho más diversificadas y equilibradas. Frente a las fuertes concentraciones de otros enfoques, este asigna el capital entre siete y nueve activos cada año, con pesos bastante homogéneos. Esta estrategia favorece una mayor robustez frente a errores de estimación y permite explotar más eficazmente el conjunto del universo invertible.

En términos de previsión, el modelo bayesiano presenta un Sharpe *ex ante* medio de 1,00 (el más conservador de los cuatro), y al mismo tiempo es el que muestra la mayor coherencia con los resultados reales, ya que la diferencia media entre Sharpe *ex ante* y *ex post* es de tan solo -0,24, la más baja del conjunto. Su *alfa* promedio (11,67 %) es también el más elevado de los cuatro enfoques, y destaca por su consistencia, ya que en la mayoría de los años supera al índice sin necesidad de concentrar excesivamente las carteras.

En definitiva, su comportamiento demuestra que una diversificación bien calibrada, unida a un enfoque de búsqueda más flexible e iterativo, puede resultar especialmente eficaz en entornos inciertos, como los que caracterizan al IBEX-35 durante el periodo analizado.

Para complementar el análisis anterior, a continuación se presentan dos gráficos que ilustran la evolución de cada enfoque respecto al índice.

Figura 4: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 1)



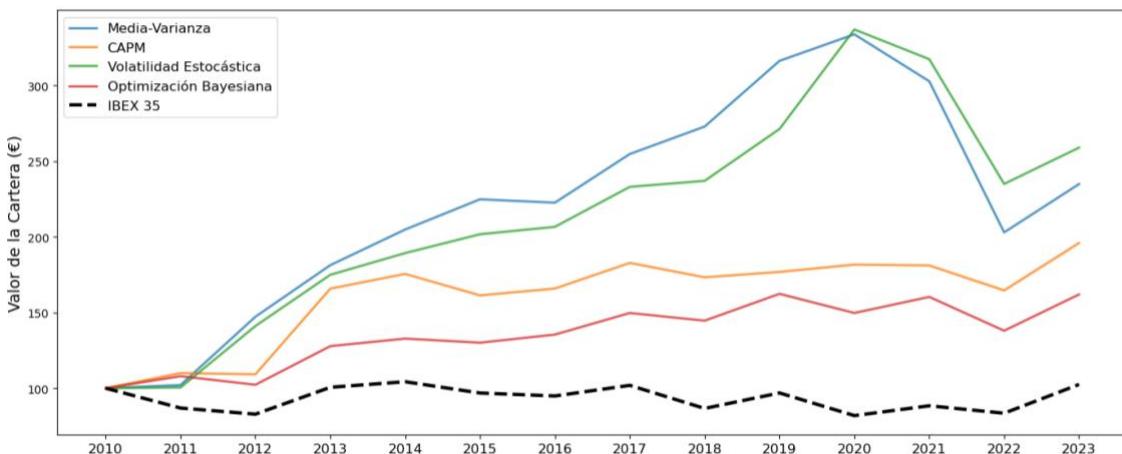
Fuente: Elaboración propia con datos extraídos de *FactSet*

La Figura 4 permite observar la evolución anual de los rendimientos de cada enfoque frente al índice. A lo largo del periodo, el índice ha mostrado un comportamiento irregular, con varios años de rentabilidad negativa y recuperaciones puntuales. En este contexto, los modelos de optimización han sido capaces, en general, de superar al índice en un número significativo de ejercicios, aunque con grados de volatilidad muy distintos. Se aprecia cómo los enfoques más concentrados (Media-Varianza) tienden a amplificar tanto los años positivos como los negativos, mientras que los enfoques más diversificados logran resultados más estables.

En términos generales, la evolución de los distintos métodos tiende a seguir la misma dirección que el IBEX-35, lo que refleja su exposición compartida a factores sistemáticos del mercado. No obstante, existen años, como 2022, en los que las estrategias optimizadas sufren caídas especialmente pronunciadas. Esto se explica, en parte, por su mayor sensibilidad a shocks repentinos o a errores de estimación en contextos de elevada incertidumbre, como el repunte de inflación, la subida de tipos y la corrección de los mercados bursátiles tras el rebote post-COVID. A pesar de estas caídas, los modelos presentan un mejor desempeño relativo en la mayoría de los ejercicios, mostrando que incluso en entornos adversos pueden aportar valor.

Para comprender mejor los resultados de cada enfoque, la Figura 5, presentada a continuación, visualiza cómo habría evolucionado una inversión inicial de 100€. Esta perspectiva permite evaluar no solo la rentabilidad generada por cada método, sino también su capacidad para sostener el crecimiento del capital a lo largo del tiempo.

Figura 5: Evolución acumulada del valor de las carteras (Escenario 1)



Fuente: Elaboración propia con datos extraídos de *FactSet*

La figura muestra con claridad cómo los distintos enfoques de optimización han sido capaces de generar una rentabilidad acumulada superior a la del IBEX-35. Mientras que el índice apenas logra mantener el capital inicial tras trece años, con una trayectoria marcada por caídas y recuperaciones parciales, todos los métodos terminan con un valor final significativamente superior a los 100€.

Entre ellos, destaca la Volatilidad Estocástica como la estrategia que alcanza el mayor valor acumulado al final del periodo. Le sigue de cerca el Modelo de Media-Varianza, que mantiene una trayectoria ascendente hasta 2021, pero, al igual que la Volatilidad Estocástica, sufre una corrección especialmente pronunciada en 2022. Por el contrario, el CAPM y la Optimización Bayesiana presentan una evolución mucho más estable con un crecimiento más contenido pero sostenido en el tiempo.

En conjunto, el gráfico confirma que, incluso bajo un enfoque puramente teórico y sin restricciones, las estrategias de optimización analizadas habrían superado al IBEX-35 en términos de rentabilidad acumulada, subrayando su potencial como herramientas de generación de valor en el largo plazo.

4.2. Escenario 2: UCITS 5/10/40

En el segundo escenario, como se ha explicado anteriormente, se introducen restricciones inspiradas en la normativa europea UCITS, particularmente la regla 5/10/40. Esta configuración busca garantizar una diversificación mínima sin imponer una distribución completamente equitativa, permitiendo cierta concentración siempre que se mantenga dentro de márgenes razonables.

La Tabla 7 muestra los resultados obtenidos por cada método a lo largo del periodo, permitiendo comparar directamente su rendimiento teórico y real bajo estas nuevas condiciones regulatorias.

Tabla 7: Comparativa *ex post*: *alfa* y desviación de la Ratio de Sharpe (Escenario 2)

	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
Año	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe
2011	17,37%	1,087	23,33%	3,405	16,96%	0,620	21,03%	2,156
2012	17,54%	0,387	-0,05%	0,014	14,70%	0,312	4,80%	0,164
2013	0,18%	1,034	18,86%	1,949	0,71%	1,085	10,32%	1,709
2014	5,17%	-0,473	2,89%	0,285	1,59%	-0,860	0,25%	-0,242
2015	11,71%	-0,312	4,21%	-0,016	9,85%	-0,627	7,92%	-0,101
2016	-1,97%	-1,038	6,38%	0,308	2,20%	-1,059	7,80%	0,014
2017	4,19%	1,195	2,78%	1,483	4,26%	0,861	2,59%	1,070
2018	18,09%	-0,714	10,73%	-0,775	16,92%	-1,082	11,60%	-1,218
2019	3,78%	0,446	-5,66%	0,518	1,55%	0,109	-1,81%	0,362
2020	16,49%	-0,773	13,35%	0,147	17,37%	-0,842	4,06%	-0,605
2021	-8,57%	-1,132	-7,08%	0,354	-7,53%	-1,327	-1,43%	1,146
2022	-15,58%	-2,498	-9,61%	-0,733	-12,28%	-2,645	-3,33%	-1,134
2023	-11,81%	-0,235	-5,92%	0,991	-8,77%	-0,215	-5,40%	0,625
Promedio	4,35%	-0,233	4,17%	0,610	4,43%	-0,436	4,49%	0,304

Fuente: Elaboración propia con datos extraídos de *FactSet*

Con las restricciones UCITS, el modelo Media-Varianza se ve obligado a limitar significativamente sus asignaciones más concentradas. Aunque la diversificación es mucho mayor, sigue asignando los mayores pesos a los mismos activos. Esta mayor dispersión reduce la exposición a errores extremos observada en el Escenario 1, pero también modera los resultados más agresivos: el *alfa* promedio cae hasta el 4,35%, mientras que la diferencia entre Sharpe *ex ante* y *ex post* se reduce ligeramente a -0,23. El comportamiento es más controlado, pero también más predecible. No obstante, el modelo sigue mostrando Ratios de Sharpe *ex ante* relativamente elevadas en comparación con lo que finalmente se obtiene, lo que refleja una sobreestimación persistente del rendimiento ajustado al riesgo.

El CAPM, que en el escenario anterior estaba marcado por una concentración excesiva, experimenta una mejora significativa al estar obligado a diversificar. El Sharpe *ex ante* sigue siendo bajo, pero el *ex post* mejora sensiblemente hasta una media de 0,52, lo que representa un comportamiento mucho más coherente. El *alfa* promedio de 4,17% es casi idéntico al del Media-Varianza, pero obtenido con menos dispersión y menos

dependencia de resultados extremos. Aun así, el modelo continúa generando rendimientos esperados negativos en varios ejercicios, lo demuestra la rigidez estructural de su lógica de estimación, centrada únicamente en la *beta*. Las restricciones actúan como un corrector natural del sesgo estructural del CAPM hacia una sobreconcentración, pero no resuelven del todo sus limitaciones como estimador del rendimiento esperado.

El modelo de Volatilidad Estocástica mantiene una estructura de asignación similar, pero reduce aún más su exposición a activos recurrentes como Grifols, Amadeus o Inditex, lo que limita ligeramente su capacidad de capturar rentabilidades extremas, pero mejora la consistencia interanual. El Sharpe *ex ante* sigue siendo elevado, pero el *ex post* mejora marginalmente respecto al escenario anterior, con una desviación media de -0,44 (frente a -1,19 antes). El *alfa* medio alcanza el 4,43%, lo que confirma que el modelo sigue aportando valor incluso con restricciones. Sin embargo, persiste cierta brecha entre estimación y resultado real, especialmente en años con alta volatilidad, lo que indica que, aunque más estable, el modelo sigue teniendo margen de mejora en condiciones de mercado cambiantes.

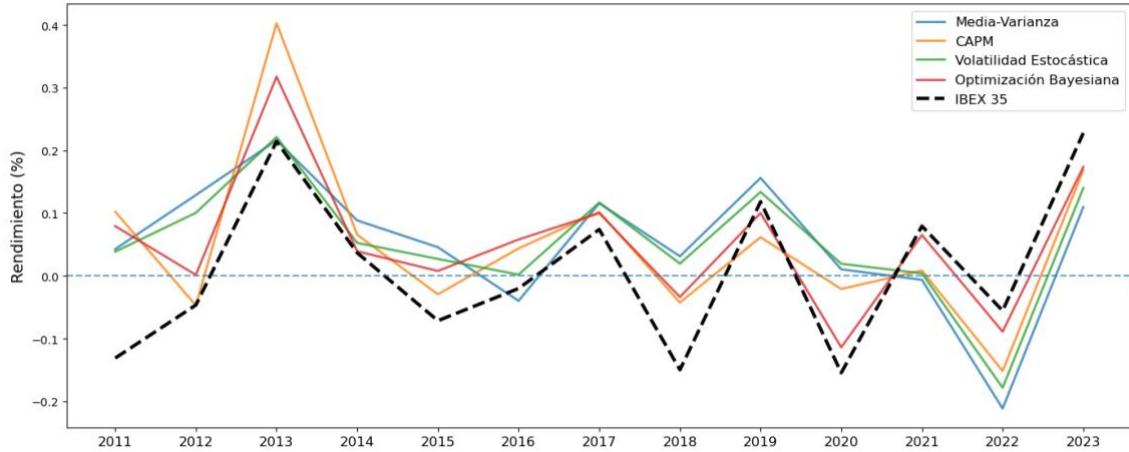
La Optimización Bayesiana, apenas se ve afectada por las limitaciones impuestas. Algunas de sus carteras ya cumplían en la práctica con los criterios 5/10/40, por lo que los resultados se mantienen estables: el *alfa* medio es de 4,49% y la diferencia entre Sharpe *ex ante* y *ex post* es la menor del conjunto, con solo 0,30 de desviación. Este comportamiento consistente refuerza la idea de que el enfoque bayesiano es más robusto. Aun así, aunque sus resultados reales sean más estables, no están exentos de variabilidad interanual, especialmente en contextos de estrés del mercado.

En conjunto, los cuatro modelos experimentan una mejora general en términos de estabilidad y coherencia bajo el marco UCITS. Aunque se reducen las rentabilidades extremas, también lo hacen las desviaciones entre estimaciones y resultados reales. Las restricciones actúan como un mecanismo de estabilización, especialmente beneficioso para enfoques propensos a la concentración como CAPM o Media-Varianza. Este escenario demuestra que imponer criterios regulatorios mínimos no solo limita el riesgo, sino que también puede mejorar la calidad del ajuste entre teoría y realidad.

El análisis visual de los rendimientos anuales (Figura 6) refleja un comportamiento más homogéneo entre los cuatro enfoques. Las diferencias con respecto al IBEX-35 se estrechan en la mayoría de los ejercicios, y se reduce la dispersión entre modelos. Esto

sugiere que las restricciones actúan como un mecanismo de contención que limita tanto los errores como los aciertos extremos, reforzando la estabilidad interanual.

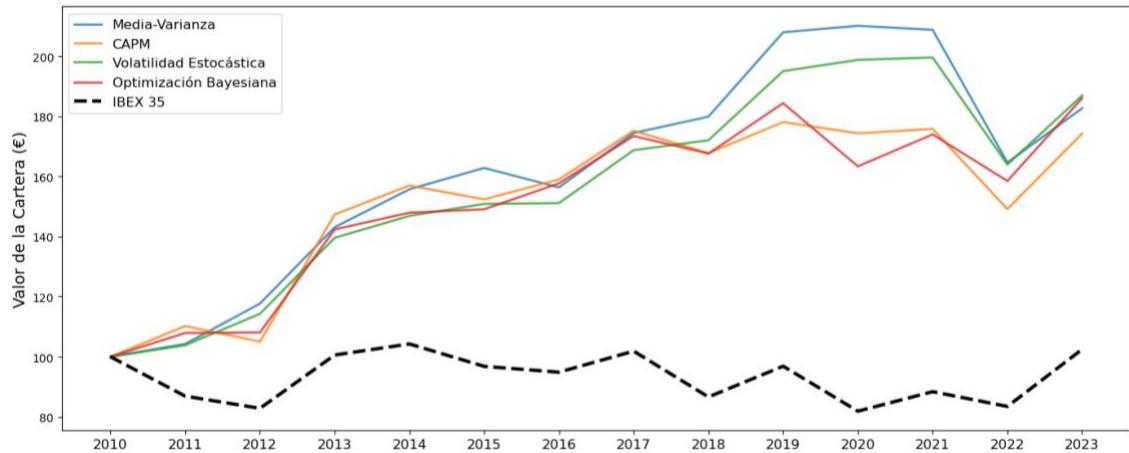
Figura 6: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 2)



Fuente: Elaboración propia con datos extraídos de *FactSet*

Por su parte, la Figura 7 muestra que la evolución acumulada del valor de las carteras mantiene una trayectoria creciente, aunque menos pronunciada que en el Escenario 1. Las curvas de Media-Varianza y CAPM, que antes destacaban por sus picos más agresivos, se ven suavizadas por el efecto de la diversificación forzada, mientras que Volatilidad Estocástica y Optimización Bayesiana mantienen una progresión estable, sin grandes desviaciones entre sí.

Figura 7: Evolución acumulada del valor de las carteras (Escenario 2)



Fuente: Elaboración propia con datos extraídos de *FactSet*

A lo largo del periodo, las cuatro estrategias superan al IBEX-35 en valor final, lo que refuerza la idea de que incluso bajo restricciones estructurales es posible obtener un *alfa* positivo mediante una selección sistemática de activos.

4.3. Escenario 3: RIC 25/50

En este tercer escenario se aplican las restricciones propias del régimen fiscal estadounidense RIC (Regulated Investment Company), concretamente la regla 25/50. En la práctica, esta regulación es menos estricta que UCITS en cuanto a concentración máxima por activo, pero introduce una penalización a la acumulación de varios activos grandes, favoreciendo así una diversificación controlada pero más flexible.

La Tabla 8, resume la comparativa de los resultados obtenidos por cada enfoque bajo este nuevo marco.

Tabla 8: Comparativa *ex post*: *alfa* y desviación de la Ratio de Sharpe (Escenario 3)

	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
Año	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe	Alfa (%)	Δ Sharpe
2011	15,18%	-0,088	23,10%	3,364	13,56%	-1,083	21,03%	2,156
2012	48,83%	1,455	3,91%	0,206	45,06%	1,258	-0,59%	-0,042
2013	1,71%	0,769	30,37%	2,281	2,54%	0,642	3,50%	1,426
2014	9,33%	-0,549	2,22%	0,249	4,55%	-1,095	0,25%	-0,260
2015	16,90%	-0,211	-0,94%	-0,183	13,73%	-0,531	5,11%	-0,277
2016	1,02%	-1,111	4,83%	0,214	4,43%	-1,273	6,14%	-0,044
2017	7,05%	1,429	2,80%	1,440	5,40%	0,684	3,11%	1,324
2018	22,09%	-0,531	9,78%	-0,879	16,67%	-1,467	11,60%	-1,218
2019	4,10%	0,211	-9,78%	0,286	2,64%	-0,037	0,44%	0,507
2020	20,99%	-0,846	18,19%	0,291	39,68%	-0,468	7,65%	-0,568
2021	-17,21%	-2,929	-8,25%	0,145	-13,75%	-2,942	-0,83%	1,180
2022	-27,41%	-3,456	-3,54%	-0,349	-20,40%	-3,535	-8,37%	-1,518
2023	-7,03%	-0,329	-3,73%	0,938	-12,57%	-0,965	-5,40%	0,625
Promedio	7,35%	-0,476	5,30%	0,616	7,81%	-0,832	3,36%	0,253

Fuente: Elaboración propia con datos extraídos de *FactSet*

El Modelo de Media-Varianza continua su tendencia a generar estimaciones optimistas, ya que presenta un Sharpe *ex ante* medio de 1,06, el segundo más alto del conjunto, pero su diferencia media con el desempeño real crece hasta -0,48. Aun así, el método consigue un *alfa* promedio del 7,35%, destacando especialmente en 2012 y 2020, aunque con una notable penalización en 2022. Estas oscilaciones reflejan que, si bien el modelo puede capturar rentabilidades elevadas, lo hace asumiendo una fuerte exposición al riesgo.

Por su parte, el CAPM mantiene el patrón ya observado, con rendimientos esperados negativos en la mayoría de los ejercicios, pero resultados *ex post* razonables. El modelo alcanza un Sharpe real medio de 0,54, muy por encima de sus previsiones, y un *alfa* medio

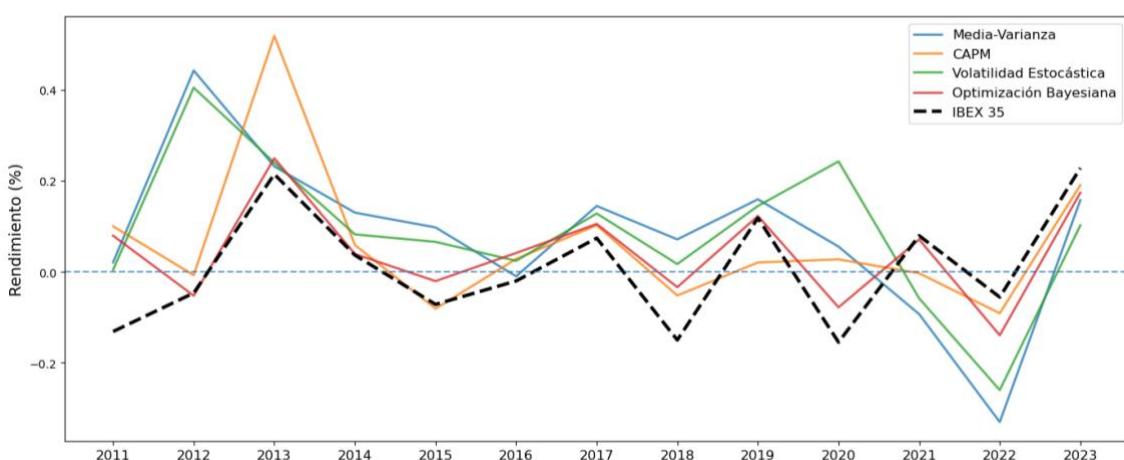
del 5,30%. La diferencia entre expectativas y resultados se mantiene, pero en este escenario se modera ligeramente frente a los anteriores, en parte gracias a la mayor dispersión forzada por las restricciones.

El modelo de Volatilidad Estocástica se consolida como el más rentable del conjunto, con un *alfa* promedio del 7,81% y una mejora notable en su consistencia respecto a escenarios anteriores. Aunque su Sharpe *ex ante* sigue siendo alto (1,33), la diferencia con el valor real se reduce a -0,83. El modelo logra resultados especialmente buenos en los años de mayor tendencia, como 2012, 2017 y 2020, aunque sufre correcciones en períodos más laterales. En conjunto, demuestra una capacidad robusta para capturar rentabilidad, especialmente en entornos definidos.

La Optimización Bayesiana, en línea con lo observado en los escenarios anteriores, se mantiene como el enfoque más estable y menos volátil. Con un *alfa* medio del 3,36% y la menor desviación de Sharpe del conjunto (solo +0,25), su comportamiento destaca por su regularidad. Aunque no obtiene los picos de rentabilidad de Media-Varianza o VE, evita las caídas más pronunciadas y presenta una evolución más predecible.

El análisis gráfico de los rendimientos anuales (Figura 8) muestra una evolución más parecida entre enfoques, aunque siguen apareciendo diferencias importantes en algunos años. En ejercicios como 2012, 2017 o 2022, cada enfoque reacciona de forma distinta, lo que refleja que las restricciones no eliminan del todo el contraste entre estrategias.

Figura 8: Rendimientos anuales de las carteras optimizadas frente al IBEX-35 (Escenario 3)

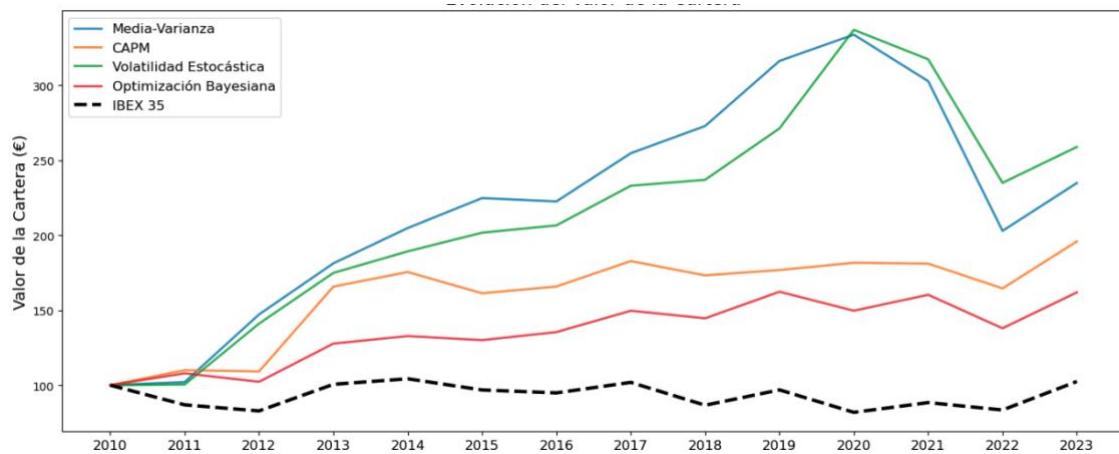


Fuente: Elaboración propia con datos extraídos de *FactSet*

En cuanto a la evolución acumulada del valor de las carteras (Figura 9), se aprecia una separación clara entre las estrategias. Media-Varianza y VE lideran el crecimiento

agregado, alcanzando valores finales muy por encima del índice de referencia, aunque con caídas pronunciadas en los años más volátiles. Por otro lado, CAPM y OB presentan trayectorias también más estables, evitando los retrocesos extremos. Esta visualización confirma que, bajo restricciones intermedias, los modelos con capacidad de capturar tendencias (como VE) se benefician especialmente, mientras que enfoques más conservadores como el bayesiano ofrecen menor rendimiento, pero mayor control de riesgo.

Figura 9: Evolución acumulada del valor de las carteras (Escenario 3)



Fuente: Elaboración propia con datos extraídos de *FactSet*

En resumen, el Escenario 3 confirma que una relajación parcial de las restricciones, como la que propone el marco RIC 25/50, permite a los modelos conservar parte de su capacidad predictiva sin caer en excesos. Aunque la variabilidad entre enfoques persiste, se observa una mejora general en términos de equilibrio entre rentabilidad y control del riesgo. Esta última simulación refuerza la idea de que la elección del marco regulatorio influye no solo en los resultados obtenidos, sino también en la estabilidad de cada estrategia.

4.4. Comparativa global de métodos

Una vez analizados los resultados individuales en cada entorno, este apartado presenta una visión global del comportamiento de los cuatro enfoques bajo los tres escenarios definidos. Esta comparación permite evaluar la sensibilidad de cada modelo ante distintos marcos regulatorios, así como su capacidad para mantener un rendimiento coherente cuando se introducen restricciones.

En el caso del Modelo de Media-Varianza, se observa una elevada dependencia de la concentración para generar valor. En el escenario sin límites, logra *alfas* muy elevados en años concretos, como 86,37% en 2012 o 27,79% en 2018. Sin embargo, también registra caídas intensas, como en 2022, donde pierde más de un 35%. Al imponer restricciones, el modelo pierde parte de su capacidad para concentrar la inversión, lo que reduce tanto los máximos como los mínimos. A pesar de ello, sigue mostrando un comportamiento muy irregular, con diferencias importantes entre la rentabilidad esperada y la real, especialmente en entornos volátiles como 2022.

El CAPM sigue un patrón similar. En el escenario sin restricciones, su comportamiento es extremo, con años muy positivos como 2013 (108,14%) y otros con caídas o rendimientos modestos. En muchos ejercicios invierte el 100 % en un único activo, lo que acentúa la volatilidad de los resultados. Al introducir límites, los resultados se moderan. En 2013, el *alfa* cae a 18,86% bajo UCITS, y a 30,37% bajo RIC. En general, la incorporación de restricciones reduce la dispersión de resultados y mejora la coherencia entre lo previsto y lo obtenido, aunque el modelo sigue siendo poco estable como estimador.

La Volatilidad Estocástica mantiene un perfil intermedio entre los dos enfoques anteriores y los modelos más diversificados. En los tres escenarios consigue *alfas* positivos en varios años, destacando 2020 con rentabilidades cercanas al 50% en el escenario sin límites y por encima del 39% en el escenario RIC. No obstante, también muestra caídas relevantes, como en 2022, donde registra pérdidas superiores al 27% tanto en el escenario sin restricciones como en los escenarios con límites. Aunque reduce parcialmente la volatilidad al aplicar restricciones, sigue mostrando una cierta sobreestimación del rendimiento en años desfavorables.

Por su parte, la Optimización Bayesiana se mantiene como el enfoque más regular. En los tres escenarios presenta resultados positivos de forma constante, sin picos extremos, pero también sin caídas pronunciadas. En 2012 logra un *alfa* del 92% en el escenario sin límites, aunque con menor exposición en otros años. Incluso en ejercicios negativos como 2022, logra minimizar las pérdidas, con resultados por debajo del -4% en UCITS y del -1% en RIC. Además, es el único modelo que logra mantener una relación coherente entre los valores estimados y los observados, independientemente del marco de restricciones.

En conjunto, los resultados muestran que todos los enfoques superan al IBEX-35 en términos acumulados. La introducción de restricciones regulatorias permite estabilizar los resultados, reducir la exposición a errores de estimación y mejorar la coherencia entre expectativas y resultados reales. Mientras que los modelos clásicos obtienen mejores resultados en términos de rentabilidad bruta cuando no existen restricciones, esta ventaja aparente conlleva una fuerte inestabilidad y una alta sensibilidad a errores de estimación. En cambio, los enfoques más diversificados y adaptativos, como la Volatilidad Estocástica y la Optimización Bayesiana, logran un mejor equilibrio entre rentabilidad y riesgo en marcos de inversión más realistas.

5. Conclusiones

5.1. Resumen de los hallazgos

A lo largo del presente TFG se han analizado cuatro enfoques distintos de optimización de carteras —Media-Varianza, CAPM, Volatilidad Estocástica y Optimización Bayesiana— bajo tres escenarios: Sin Límites, UCITS 5/10/40 y con el marco RIC 25/50. Esta estructura ha permitido evaluar el comportamiento de cada modelo en condiciones ideales, regulatorias europeas y restricciones de tipo estadounidense, proporcionando una visión amplia sobre su desempeño relativo.

Los resultados muestran que todos los métodos logran superar al IBEX-35 en el largo plazo, aunque lo hacen a través de estrategias muy distintas. La Optimización Bayesiana destaca por su regularidad y por obtener el mayor *alfa* promedio *ex post* en los escenarios Sin Límites y UCITS 5/10/40, con la menor desviación entre previsiones y resultados, lo que la convierte en la opción más estable del conjunto. La Volatilidad Estocástica lidera el *alfa* en el escenario RIC 25/50 y destaca por capturar tendencias, aunque con mayor sensibilidad a las condiciones del mercado y diferencias más amplias entre Sharpes. El modelo de Media-Varianza también logra buenos resultados, pero con más variabilidad y una tendencia a sobreestimar el rendimiento esperado. Por último, el CAPM, a pesar de sus previsiones más conservadoras, consigue resultados positivos gracias a su exposición sistemática a activos con betas elevadas.

Asimismo, se ha observado que la introducción de restricciones regulatorias tiende a mejorar la coherencia y reducir la volatilidad de los resultados, especialmente en los enfoques más propensos a la concentración. Sin embargo, estas limitaciones también pueden disminuir el potencial alcista de los modelos más agresivos.

En conjunto, el estudio evidencia que no hay un enfoque mejor. Cada método presenta fortalezas y limitaciones que lo hacen más adecuado según el perfil del inversor, el tipo de restricciones regulatorias o el horizonte temporal considerado. Por tanto, la elección del modelo óptimo dependerá del equilibrio que se busque entre rentabilidad potencial, control del riesgo y consistencia a lo largo del tiempo.

5.2. Limitaciones del trabajo

Como en todo trabajo empírico, el presente estudio presenta una serie de limitaciones que conviene destacar, tanto para contextualizar los resultados obtenidos como para orientar futuras líneas de investigación.

En primer lugar, el análisis se ha llevado a cabo en un entorno simplificado en el que no se han incorporado elementos propios de la operativa real, como los costes de transacción, las comisiones o las fricciones asociadas a la ejecución en mercado. La omisión de estos factores permite centrarse en la lógica de los modelos, pero al mismo tiempo puede generar una visión idealizada de su rentabilidad.

Por otro lado, el universo de inversión se ha restringido al IBEX-35, lo que facilita la homogeneidad del análisis pero reduce la capacidad de extrapolar los resultados a mercados más amplios, líquidos o diversificados. Además, la implementación de los modelos se ha planteado de forma estática, sin incorporar rebalanceos periódicos ni mecanismos adaptativos de gestión del riesgo, lo que limita su capacidad de respuesta ante eventos inesperados o cambios de régimen.

A nivel metodológico, debido al volumen de información existente y a los límites propios de un Trabajo Fin de Grado, no ha sido posible incluir todos los enfoques relevantes en la literatura sobre optimización de carteras. Asimismo, se ha intentado traducir conceptos matemáticos complejos a un lenguaje accesible, lo que ha exigido simplificaciones que, si bien facilitan la comprensión, pueden restar profundidad técnica en ciertos apartados.

5.3. Recomendaciones para futuros trabajos e investigaciones

A partir de las limitaciones identificadas, surgen varias líneas de desarrollo que podrían enriquecer y ampliar el presente TFG. Una primera recomendación sería incorporar costes de transacción, comisiones y restricciones operativas reales, con el fin de evaluar la viabilidad práctica de las carteras generadas y aproximarse mejor a las condiciones de mercado.

Por otro lado, extender el análisis a otros mercados o índices internacionales permitiría comprobar la robustez de los modelos en diferentes entornos. Esta ampliación podría también incluir clases de activos adicionales, como renta fija, materias primas o activos alternativos, lo que abriría la puerta a estrategias de asignación más complejas.

Por último, futuras investigaciones podrían profundizar en comparativas más amplias de modelos, incluyendo enfoques no considerados aquí, así como evaluar la sensibilidad de los resultados a diferentes configuraciones temporales, como el tamaño de las ventanas temporales o la frecuencia de rebalanceo. Analizar cómo varían los resultados permitiría entender mejor la estabilidad y adaptabilidad de cada enfoque. Todo ello contribuiría a desarrollar marcos de optimización más flexibles, robustos y alineados con los retos actuales de la gestión cuantitativa de carteras.

5.4. Conclusión final

En definitiva, este trabajo demuestra que la optimización cuantitativa de carteras, incluso bajo enfoques diversos y marcos regulatorios distintos, puede generar valor frente a estrategias pasivas. Al combinar el análisis empírico con los fundamentos teóricos desarrollados en el TFG previo de ADE, se construye una visión más completa que permite entender tanto la lógica de los enfoques como su comportamiento en condiciones reales de mercado. Los resultados obtenidos refuerzan la principal conclusión de aquel estudio: no existe un enfoque universalmente superior. Además, permiten observar en la práctica las fortalezas y limitaciones descritas desde una perspectiva teórica. De este modo, ambos trabajos se complementan y ofrecen al lector una base más sólida para analizar y comparar distintas estrategias de optimización de carteras.

6. Declaración de uso de herramientas de inteligencia artificial generativa en Trabajos Fin de Grado

Por la presente, yo, Santiago Collazo Fontes, estudiante de Doble Grado en Administración y Dirección de Empresas y Business Analytics (E-2 + Analytics) de la Universidad Pontificia Comillas al presentar mi Trabajo Fin de Grado titulado “Comparativa de Modelos de Optimización de Carteras Aplicados al IBEX-35: Implementación en Python”, declaro que he utilizado la herramienta de Inteligencia Artificial Generativa *ChatGPT* u otras similares de IAG de código sólo en el contexto de las actividades descritas a continuación:

1. **Brainstorming de ideas de investigación:** Utilizado para idear y esbozar posibles áreas de investigación.
2. **Referencias:** Usado conjuntamente con otras herramientas, como Science, para identificar referencias preliminares que luego he contrastado y validado.
3. **Interpretador de código:** Para realizar análisis de datos preliminares.
4. **Corrector de estilo literario y de lenguaje:** Para mejorar la calidad lingüística y estilística del texto.
5. **Sintetizador y divulgador de libros complicados:** Para resumir y comprender literatura compleja.
6. **Revisor:** Para recibir sugerencias sobre cómo mejorar y perfeccionar el trabajo con diferentes niveles de exigencia.
7. **Traductor:** Para traducir textos de un lenguaje a otro.

Afirmo que toda la información y contenido presentados en este trabajo son producto de mi investigación y esfuerzo individual, excepto donde se ha indicado lo contrario y se han dado los créditos correspondientes (he incluido las referencias adecuadas en el TFG y he explicitado para que se ha usado *ChatGPT* u otras herramientas similares). Soy consciente de las implicaciones académicas y éticas de presentar un trabajo no original y acepto las consecuencias de cualquier violación a esta declaración.

Fecha: 10/06/2025

Firma: Santiago Collazo Fontes

7. Bibliografía

- Adame-García, V. M., Fernández-Rodríguez, F., & Sosvilla-Rivero, S. (2015). Portfolios in the Ibex 35 index: Alternative methods to the traditional framework, a comparative with the naive diversification in a pre- and post- crisis context. *Instituto Complutense de Análisis Económico*.
- Amenc, N., & Martellini, L. (2011). In Diversification we Trust? *Journal of Portfolio Management*, 37(2).
- Amenc, N., Goltz, F., Lodh, A., & Martellini, L. (2012). Diversifying the Diversifiers and Tracking the Tracking Error: Outperforming Cap-Weighted Indices with Limited Risk of Underperformance. *The Journal of Portfolio Management*, 38(3), 72-88.
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22, 1915-1953.
- Fama, E. F., & French, K. R. (2004). The capital asset pricing model: theory and evidence. *Journal of Economic Perspectives*, 18(3), 25-46.
- Frazier, P. I. (2018). *A tutorial on Bayesian optimization*. arXiv preprint arXiv:1807.02811.
- Garrido Merchán, E. C. (2023). La evolución de la gestión de carteras: del modelo de Markowitz al deep reinforcement learning y la optimización bayesiana. *Ex Post*.
- Ghysels, E., Harvey, A. C., & Renault, E. (1996). Stochastic volatility. En G. S. Maddala, & C. Rao (Edits.), *Handbook of Statistics* (Vol. 14, págs. 119-191). Elsevier.
- Heston, S. L. (1993). A closed-form solution for options with stochastic volatility with applications to bond and currency options. *The Review of Financial Studies*, 6(2), 327-343.
- Jagannathan, R., & Wang, Z. (1996). The conditional CAPM and the cross-section of expected returns. *The Journal of Finance*, 51(1), 3-53.
- Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *The Review of Economics and Statistics*, 47(1), 13-37.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77-91.
- Markowitz, H. M. (1959). Portfolio Selection: Efficient Diversification of Investments. *Yale University Press*.
- Michaud, R. O. (1989). The Markowitz optimization enigma: is 'optimized' optimal? *Financial Analysts Journal*, 31-42.
- Pástor, L., & Stambaugh, R. F. (2000). Comparing asset pricing models: an investment perspective. *Journal of Financial Economics*, 56(3), 335-381.
- Parlamento Europeo y Consejo de la Unión Europea. (2009). *Directiva 2009/65/CE de 13 de julio de 2009 relativa a la coordinación de las disposiciones legales*,

reglamentarias y administrativas relativas a los organismos de inversión colectiva en valores mobiliarios (UCITS). Diario Oficial de la Unión Europea. L 302.

Rasmussen, C. E., & Williams, C. K. (2006). Gaussian processes for machine learning. *MIT Press*.

Shahriari, B., Swersky, K., Wang, Z., Prescott, R. A., & de Freitas, N. (2016). Taking the human out of the loop: A review of Bayesian optimization. *Proceedings of the IEEE*, 104(1), 148-175.

Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425-442.

Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21, 49-58.

United States Congress. (1986). *Internal Revenue Code of 1986 § 851(b)(3)*. 26 U.S.C.

8. Apéndice

8.1. Apéndice A: Pesos de las carteras optimizadas en el Escenario 1

A.1 Modelo de Media-Varianza

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
AENA	-	-	-	-	-	-	-	-	-	24.53%	-	-	-
AMS	-	-	-	-	28.67%	19.51%	51.50%	52.11%	23.67%	14.18%	-	-	-
ANA	-	-	-	-	-	-	-	-	-	-	-	-	21.82%
BKT	-	-	-	-	-	-	-	20.39%	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	43.91%	4.81%	-	-	-
CLNX	-	-	-	-	-	-	-	-	-	35.03%	45.48%	26.63%	9.90%
COL	-	-	-	-	-	-	-	4.69%	26.28%	14.21%	-	-	-
ENC	-	-	-	-	-	-	-	-	4.38%	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	25.89%	-
FER	-	-	-	-	-	11.43%	-	-	-	-	-	-	-
GRF	33.16%	37.12%	35.40%	19.21%	21.46%	54.15%	21.28%	-	-	1.44%	-	-	-
ITX	19.99%	62.88%	64.60%	26.92%	15.18%	14.14%	-	-	-	-	-	-	-
JAZ	-	-	-	23.22%	34.70%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	1.41%
MEL	-	-	-	-	-	6.15%	-	-	-	-	-	-	-
MTS	-	-	-	-	-	-	-	-	-	-	2.53%	-	-
RED	-	-	-	-	-	4.07%	-	1.77%	-	-	-	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	-	31.85%	30.18%
SGRE	-	-	-	-	-	-	16.51%	22.81%	-	5.81%	6.66%	-	-
SLR	-	-	-	-	-	-	-	-	-	44.36%	15.63%	36.69%	-
TRE	46.85%	-	-	-	-	-	-	-	-	-	-	-	-
VIS	-	-	-	30.65%	-	-	-	-	-	-	-	-	-

A.2 CAPM

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	-	-	-	3.00%	-	-	3.18%	3.39%	-	-	-	-	-
ABG.P	-	-	-	-	100.00%	-	-	-	-	-	-	-	-
ACS	-	-	-	1.32%	-	-	1.37%	1.75%	-	-	-	-	-
AMS	-	-	-	-	-	-	3.21%	3.44%	-	-	-	-	-
ANA	-	-	-	-	-	-	1.20%	1.18%	-	-	-	-	-
BBVA	-	-	-	12.83%	-	-	11.48%	10.08%	-	-	-	-	-
BKIA	-	-	-	-	-	100.00%	-	-	-	-	-	-	-
BKT	-	-	-	2.60%	-	-	1.78%	2.17%	-	-	-	-	-
CABK	-	-	-	-	-	-	2.66%	3.49%	-	-	-	-	-
EBRO	-	-	-	1.42%	-	-	-	-	-	-	-	-	-
ELE	-	-	-	-	-	-	1.50%	1.37%	-	-	-	-	-
ENC	-	-	-	-	-	-	-	-	100.00%	-	-	-	-
ENG	-	-	-	2.98%	-	-	1.30%	1.11%	-	-	-	-	-
FER	-	-	-	1.79%	-	-	3.72%	3.34%	-	-	-	-	-
GRF	100.00%	-	-	-	-	-	1.70%	2.00%	-	-	-	-	-
IAG	-	-	-	-	-	-	2.00%	2.23%	-	-	-	-	-
IBE	-	-	-	9.32%	-	-	9.76%	9.47%	-	-	-	-	-
ITX	-	-	-	7.19%	-	-	11.75%	11.78%	-	-	-	-	-
MAP	-	-	-	1.46%	-	-	-	-	100.00%	-	-	-	-
MTS	-	-	-	-	-	-	-	-	100.00%	-	-	-	-
NTGY	-	-	-	3.44%	-	-	2.14%	2.16%	-	-	-	-	-
OHLA	-	-	-	1.24%	-	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	100.00%	100.00%	-	-
POP	-	-	-	4.37%	-	-	1.22%	-	-	-	-	-	-
RED	-	-	-	2.91%	-	-	1.83%	2.16%	-	-	-	-	-
REP	-	-	-	-	7.95%	-	5.10%	3.51%	-	-	-	-	-
SAB	-	-	-	2.86%	-	-	1.41%	2.14%	-	-	-	-	-
SAN	-	-	-	14.89%	-	-	14.46%	15.49%	-	-	-	-	-
SCYR	-	100.00%	100.00%	-	-	-	-	-	-	-	-	-	-
SGRE	-	-	-	-	-	-	1.10%	-	-	-	-	-	-
SLR	-	-	-	-	-	-	-	-	-	-	-	-	100.00%
TEF	-	-	-	11.77%	-	-	12.41%	10.93%	-	-	-	-	-
TLS	-	-	-	1.39%	-	-	-	-	-	-	-	-	-

A.3 Volatilidad Estocástica

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	-	-	-	2.73%	-	-	-	4.41%	-	-	-	-	-
ACS	-	-	-	-	-	-	-	-	4.88%	-	-	-	-
AENA	-	-	-	-	-	-	-	-	22.51%	-	-	-	-
AMS	-	-	-	-	28.17%	4.59%	22.50%	14.47%	7.79%	5.72%	-	-	-
ANA	-	-	-	-	-	-	-	-	-	-	-	-	13.44%
BKT	-	-	-	-	-	-	-	17.07%	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	36.02%	-	-	-	-
CLNX	-	-	-	-	-	-	-	-	33.09%	18.64%	12.07%	-	-
COL	-	-	-	-	-	-	-	-	37.17%	-	-	-	-
ENC	-	-	-	-	-	-	-	-	17.56%	6.10%	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	26.29%	-
FER	-	-	-	-	-	9.51%	-	-	-	-	-	-	-
GRF	17.58%	20.34%	22.55%	15.66%	10.77%	38.63%	-	-	-	-	-	-	-
IAG	-	-	-	-	-	9.25%	7.62%	3.95%	-	-	-	-	-
ITX	26.58%	79.66%	77.45%	17.98%	5.14%	19.41%	-	-	-	-	-	-	-
JAZ	-	-	-	32.90%	55.92%	-	-	-	-	-	-	-	-
MEL	-	-	-	-	-	-	18.21%	4.59%	-	-	-	-	-
MRL	-	-	-	-	-	-	-	-	1.46%	-	-	-	-
MTS	3.55%	-	-	-	-	-	-	-	-	-	-	-	-
OHLA	6.18%	-	-	15.75%	-	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	15.26%	6.48%	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	25.75%	5.49%	-
SGRE	-	-	-	-	-	18.61%	36.07%	50.70%	-	27.70%	3.32%	-	-
SLR	-	-	-	-	-	-	-	-	-	62.78%	29.42%	81.07%	-
TLS	-	-	-	-	-	-	15.59%	4.81%	-	-	-	-	-
TRE	46.11%	-	-	5.14%	-	-	-	-	-	-	-	-	-
VIS	-	-	-	9.85%	-	-	-	-	-	-	-	-	-

A.4 Optimización Bayesiana

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABG.P	14.29%	-	-	-	-	-	-	-	-	-	-	-	-
AENA	-	-	-	-	-	-	-	-	13.17%	-	-	-	-
AMS	-	-	-	-	25.00%	7.76%	15.66%	19.91%	13.73%	13.17%	-	-	-
ANA	-	-	-	-	-	6.87%	-	-	13.73%	-	-	16.67%	25.00%
BKT	-	-	-	-	-	7.76%	-	19.91%	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	13.73%	13.17%	-	-	-
CLNX	-	-	-	-	-	-	-	-	-	13.17%	16.67%	16.67%	25.00%
COL	-	-	-	-	-	-	-	19.91%	13.73%	13.17%	-	-	-
DIA	-	-	-	-	-	7.76%	-	-	-	-	-	-	-
ELE	-	-	-	-	-	7.76%	-	-	-	-	-	-	-
ENC	-	-	-	-	-	-	-	-	13.73%	13.17%	-	-	-
ENG	-	-	-	-	-	7.76%	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	16.67%	-
FER	-	-	16.67%	-	-	7.76%	-	-	-	-	-	-	-
GRF	14.29%	50.00%	16.67%	20.00%	25.00%	7.76%	15.66%	-	-	7.83%	-	-	-
IAG	-	-	-	-	-	7.76%	15.66%	19.91%	13.73%	-	-	-	-
IBE	-	-	-	-	-	-	-	-	-	-	16.67%	-	-
IBLA	14.29%	-	-	-	-	-	-	-	-	-	-	-	-
ITX	14.29%	50.00%	16.67%	20.00%	25.00%	7.76%	15.66%	-	-	-	-	-	-
JAZ	-	-	-	20.00%	25.00%	-	-	-	-	-	-	-	-
MAP	-	-	16.67%	-	-	-	-	-	-	-	-	-	-
MEL	-	-	-	-	-	-	15.66%	-	-	-	-	-	-
MTS	14.29%	-	-	-	-	-	-	-	-	-	16.67%	-	-
NTGY	-	-	-	-	-	7.76%	-	-	-	-	-	-	-
OHLA	14.29%	-	16.67%	20.00%	-	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	16.67%	16.67%	-
RED	-	-	-	-	-	7.76%	6.06%	-	3.88%	-	-	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	-	16.67%	25.00%
SGRE	-	-	-	-	-	7.76%	15.66%	19.91%	13.73%	13.17%	13.17%	16.67%	-
SLR	-	-	-	-	-	-	-	-	-	-	-	16.67%	16.67%
TRE	14.29%	-	16.67%	-	-	-	-	-	-	-	-	-	25.00%
VIS	-	-	-	20.00%	-	-	-	-	-	-	-	-	-

8.2. Apéndice B: Pesos de las carteras optimizadas en el Escenario 2

B.1 Modelo de Media-Varianza

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	-	2.18%	5.00%	5.00%	6.72%	5.00%	2.88%	6.38%	-	-	-	-	-
ABG_P	5.43%	5.00%	3.09%	-	-	-	-	-	-	-	-	-	-
ACS	4.62%	-	3.76%	-	-	-	-	2.39%	1.82%	1.05%	-	-	-
ACX	5.21%	-	2.27%	-	-	-	2.42%	2.97%	-	-	2.98%	-	-
AENA	-	-	-	-	-	-	-	-	10.00%	4.26%	-	-	-
ALM	-	-	-	-	-	-	-	-	-	-	2.30%	-	-
AMS	-	-	-	-	10.00%	9.99%	10.00%	10.00%	9.65%	6.67%	4.50%	4.96%	-
ANA	-	-	-	-	-	3.69%	-	-	5.40%	5.00%	4.76%	5.00%	9.99%
BBVA	-	-	3.50%	-	-	-	-	-	-	-	-	-	-
BKT	-	-	-	1.24%	5.00%	5.00%	5.00%	8.80%	5.00%	-	-	-	4.67%
BME	-	-	-	5.00%	5.00%	-	-	-	-	-	-	-	-
CABK	-	2.70%	2.85%	5.00%	5.00%	-	-	-	-	-	-	-	4.73%
CIE	-	-	-	-	-	-	-	-	10.00%	4.98%	5.05%	4.86%	-
CLNX	-	-	-	-	-	-	-	-	-	10.00%	10.00%	10.00%	9.87%
COL	-	-	-	-	-	-	-	6.56%	10.00%	8.22%	5.00%	4.01%	-
DIA	-	-	-	-	9.65%	1.96%	-	-	-	-	-	-	-
E BRO	5.00%	4.99%	-	7.28%	-	-	-	-	-	-	-	-	-
ELE	4.69%	-	1.87%	-	4.58%	-	5.48%	4.96%	5.00%	4.76%	5.00%	2.56%	4.98%
ENC	-	-	-	-	-	-	-	-	5.61%	4.60%	-	-	-
ENG	5.00%	7.82%	5.00%	3.75%	6.98%	5.00%	4.89%	4.99%	4.77%	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	10.00%	5.00%
FER	3.45%	7.82%	9.99%	7.52%	7.20%	9.90%	4.94%	4.72%	4.26%	5.75%	3.04%	4.33%	4.04%
GRF	10.00%	10.00%	10.00%	9.98%	10.00%	10.00%	10.00%	-	-	4.85%	5.90%	4.65%	3.90%
IAG	-	-	-	-	-	9.67%	7.36%	6.37%	4.60%	1.09%	-	-	-
IBE	4.97%	-	1.17%	-	-	-	-	5.00%	4.98%	5.00%	4.92%	4.97%	-
IBLA	6.68%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	1.63%	-	2.93%	-	-	-	-	-	-	5.00%	1.01%	-	4.42%
ITX	9.99%	10.00%	10.00%	10.00%	10.00%	9.97%	10.00%	4.99%	-	-	5.24%	-	-
JAZ	-	-	-	10.00%	10.00%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	4.98%
MAP	-	5.00%	6.14%	1.57%	-	-	-	-	-	-	-	-	-
MEL	-	-	-	-	-	-	-	5.00%	5.48%	-	-	-	-
MRL	-	-	-	-	-	-	-	-	4.72%	5.00%	-	4.40%	-
MTS	5.00%	1.90%	1.85%	-	-	-	-	-	-	-	5.72%	2.08%	2.29%
NTGY	-	-	-	1.60%	6.11%	5.00%	1.61%	1.72%	3.78%	-	2.97%	5.00%	4.60%
OHLA	5.48%	10.00%	9.44%	7.52%	2.46%	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	8.88%	4.54%	-
RED	5.39%	7.82%	5.98%	5.00%	5.00%	8.38%	5.00%	4.90%	5.00%	-	3.06%	4.10%	4.68%
REP	1.95%	5.00%	4.09%	1.19%	-	-	-	-	-	-	-	-	4.74%
ROVI	-	-	-	-	-	-	-	-	-	-	-	10.00%	10.00%
SAN	-	-	4.84%	-	-	-	-	-	-	-	-	-	-
SCYR	-	-	-	-	-	-	-	-	-	-	-	-	3.95%
SGRE	-	-	-	-	-	5.00%	10.00%	10.00%	5.57%	7.06%	9.37%	2.56%	-
SLR	-	-	-	-	-	-	-	-	-	-	10.00%	10.00%	10.00%
TEF	4.75%	7.82%	-	-	-	-	-	-	-	-	-	-	-
TL5	-	-	-	1.13%	3.03%	3.21%	7.35%	5.00%	-	-	-	-	-
TRE	10.00%	10.00%	6.05%	7.21%	2.17%	-	5.00%	-	-	-	-	-	-
UNI	-	-	-	-	-	-	-	-	-	-	-	-	1.73%
VIS	-	-	-	10.00%	-	-	6.12%	5.00%	5.00%	3.98%	4.72%	-	-

B.2 CAPM

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	2.32%	-	8.77%	3.30%	3.26%	5.00%	3.72%	3.84%	-	-	-	-	-
ABG.P	5.22%	4.29%	8.86%	-	10.00%	-	-	-	-	-	-	-	-
ACS	3.64%	-	1.61%	2.54%	6.22%	3.02%	2.03%	2.39%	2.01%	2.80%	-	-	-
ACX	5.85%	4.44%	5.00%	-	-	3.29%	-	-	10.00%	5.39%	1.93%	-	-
AENA	-	-	-	-	-	-	-	-	-	4.67%	2.27%	-	-
ALM	-	-	-	-	-	-	-	-	-	6.55%	5.71%	-	-
AMS	-	-	-	-	5.00%	5.66%	3.81%	3.97%	-	5.24%	1.03%	-	-
ANA	5.00%	2.75%	4.25%	1.94%	5.46%	2.82%	1.69%	1.57%	2.13%	3.16%	6.01%	5.69%	5.00%
BBVA	-	-	-	7.88%	-	8.34%	8.43%	-	-	-	-	-	-
BKIA	-	-	-	-	-	10.00%	-	-	-	-	-	-	-
BKT	-	-	-	3.69%	-	-	3.13%	3.39%	-	-	-	-	-
BME	5.19%	4.79%	3.49%	2.25%	3.26%	-	-	-	-	-	-	-	-
CABK	-	9.87%	8.17%	2.63%	2.39%	3.41%	4.28%	4.51%	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	9.19%	5.62%	2.22%	3.79%	-
CLNX	-	-	-	-	-	-	-	-	-	4.81%	9.47%	6.25%	10.00%
COL	-	-	-	-	-	-	-	-	-	4.02%	4.64%	1.11%	3.33%
DIA	-	-	-	-	-	6.27%	1.61%	1.50%	-	-	-	-	-
EBRO	5.30%	9.86%	-	2.55%	-	-	-	-	-	-	-	-	-
ELE	4.13%	8.72%	-	-	1.97%	3.53%	3.39%	2.79%	5.00%	2.79%	4.52%	5.74%	6.56%
ENC	-	-	-	-	-	-	-	-	10.00%	9.88%	-	-	-
ENG	3.94%	4.18%	-	3.38%	2.04%	5.79%	3.33%	2.53%	4.99%	3.62%	4.60%	3.79%	5.65%
FCC	4.77%	-	9.13%	1.44%	7.55%	3.76%	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	5.94%	4.96%
FER	3.73%	-	1.10%	2.77%	4.99%	3.47%	4.19%	3.63%	1.99%	2.90%	2.87%	-	1.67%
GRF	6.02%	10.00%	8.29%	2.08%	5.00%	5.77%	2.24%	2.22%	-	4.95%	5.50%	6.77%	9.97%
IAG	-	-	-	-	-	2.58%	2.80%	2.89%	-	1.40%	-	-	-
IBE	-	-	-	6.09%	-	6.12%	5.30%	1.17%	-	-	4.91%	3.53%	-
IBLA	4.06%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	4.96%	1.81%	6.05%	2.14%	4.15%	3.53%	-	1.03%	-	4.30%	4.94%	2.34%	2.95%
ITX	-	-	-	5.03%	-	1.68%	7.03%	7.84%	-	-	1.21%	-	-
JAZ	-	-	-	1.39%	5.00%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	3.55%
MAP	-	-	-	2.97%	-	-	3.00%	2.52%	-	-	-	-	-
MEL	-	-	-	-	-	-	-	1.35%	9.05%	4.99%	-	-	-
MRL	-	-	-	-	-	-	-	-	-	3.85%	4.99%	2.30%	2.26%
MTS	4.58%	4.66%	3.82%	1.93%	2.13%	1.54%	-	-	10.00%	5.77%	-	-	-
NTGY	-	-	-	3.68%	-	2.42%	4.30%	3.54%	1.89%	1.81%	1.06%	4.39%	5.00%
OHLA	4.82%	-	4.98%	2.50%	2.02%	3.75%	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	10.00%	10.00%	-
POP	-	-	-	4.73%	-	-	1.19%	-	-	-	-	-	-
RED	3.30%	3.79%	-	3.30%	4.31%	5.00%	3.19%	2.90%	5.00%	3.06%	5.00%	6.10%	7.62%
REP	-	-	-	5.45%	-	-	4.69%	4.98%	1.22%	-	-	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	-	7.39%	9.96%
SAB	-	-	-	3.79%	-	2.78%	1.67%	2.61%	-	-	-	-	-
SAN	-	-	-	8.66%	-	-	9.98%	10.00%	-	-	-	-	-
SCYR	4.92%	10.00%	10.00%	-	9.88%	4.32%	-	-	-	-	-	-	2.05%
SGRE	4.79%	4.79%	3.59%	-	5.83%	1.42%	-	-	9.06%	4.64%	5.00%	4.83%	-
SLR	-	-	-	-	-	-	-	-	-	-	10.00%	10.00%	10.00%
TEF	-	-	-	6.89%	-	-	8.54%	8.44%	-	-	-	-	3.18%
TLS	5.00%	8.69%	4.57%	-	4.23%	3.08%	-	-	4.08%	5.40%	-	-	-
TRE	7.73%	7.01%	6.08%	2.10%	3.81%	6.10%	-	-	9.45%	-	-	-	-
VIS	-	-	-	2.06%	-	-	2.12%	1.70%	-	4.92%	5.18%	-	-

B.3 Volatilidad Estocástica

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	3.23%	3.55%	4.86%	4.89%	7.91%	6.60%	5.00%	5.00%	—	—	—	—	—
ABG.P	5.00%	5.06%	4.74%	—	—	—	—	—	—	—	—	—	—
ACS	5.00%	—	2.31%	—	—	—	4.60%	6.10%	5.06%	6.77%	5.00%	5.00%	—
ACX	5.01%	—	4.27%	—	—	—	2.02%	2.00%	—	—	—	—	—
AENA	—	—	—	—	—	—	—	—	10.00%	5.75%	4.89%	—	—
AMS	—	—	—	—	10.00%	5.00%	8.77%	9.03%	8.08%	7.89%	5.00%	2.07%	1.14%
ANA	—	1.41%	—	—	—	4.91%	—	—	5.00%	4.62%	4.87%	5.17%	10.00%
BBVA	—	—	4.97%	1.35%	—	—	—	—	—	—	—	—	—
BKT	—	—	—	4.89%	7.22%	5.00%	5.00%	10.00%	4.08%	—	—	—	4.39%
BME	—	4.61%	—	4.99%	4.89%	—	—	—	—	—	—	—	—
CABK	—	5.00%	4.74%	4.64%	5.00%	—	—	—	—	—	—	—	2.22%
CIE	—	—	—	—	—	—	—	—	10.00%	5.00%	6.22%	2.07%	—
CLNX	—	—	—	—	—	—	—	—	—	10.00%	10.00%	7.93%	9.21%
COL	—	—	—	—	—	—	—	4.98%	10.00%	4.83%	3.21%	5.25%	—
DIA	—	—	—	—	—	4.41%	—	—	—	—	—	—	—
E BRO	5.00%	4.97%	—	—	5.00%	—	—	—	—	—	—	—	—
ELE	—	—	2.92%	—	—	4.31%	3.14%	4.33%	2.81%	3.49%	5.00%	—	—
ENC	—	—	—	—	—	—	—	—	10.00%	5.25%	—	—	—
ENG	—	4.94%	4.93%	—	5.00%	4.89%	4.16%	—	2.64%	—	—	—	—
FDR	—	—	—	—	—	—	—	—	—	—	—	10.00%	3.51%
FER	4.35%	5.00%	10.00%	5.00%	5.00%	8.10%	3.76%	4.04%	4.38%	4.89%	—	4.84%	5.00%
GRF	10.00%	10.00%	10.00%	7.97%	10.00%	10.00%	5.00%	4.35%	5.00%	5.00%	2.27%	—	—
IAG	—	—	—	—	—	7.19%	8.93%	9.27%	4.67%	3.83%	—	—	—
IBE	4.37%	3.09%	—	—	—	—	—	3.79%	4.69%	5.00%	5.00%	4.83%	5.00%
IBLA	5.86%	—	—	—	—	—	—	—	—	—	—	—	—
IDR	—	—	4.69%	—	—	—	—	—	—	1.62%	—	—	5.00%
ITX	10.00%	10.00%	10.00%	9.23%	9.89%	9.97%	5.00%	—	—	4.87%	2.91%	4.95%	—
JAZ	—	—	—	10.00%	10.00%	—	—	—	—	—	—	—	—
LOG	—	—	—	—	—	—	—	—	—	—	—	—	3.74%
MAP	2.17%	5.00%	5.10%	5.00%	2.37%	5.00%	4.12%	4.65%	—	—	—	—	—
MEL	—	—	—	—	—	—	10.00%	5.06%	—	—	—	—	—
MRL	—	—	—	—	—	—	—	—	5.00%	5.00%	—	—	—
MTS	7.96%	3.19%	—	—	—	—	—	—	—	—	8.41%	3.95%	3.96%
NTGY	—	—	—	—	4.75%	4.98%	3.72%	4.97%	1.80%	—	—	5.00%	8.28%
OHLA	7.83%	8.24%	8.91%	10.00%	—	—	—	—	—	—	—	—	—
PHM	—	—	—	—	—	—	—	—	—	—	10.00%	8.08%	—
RED	5.00%	5.12%	4.93%	1.93%	6.15%	7.27%	4.30%	5.00%	5.33%	3.65%	—	—	—
REP	3.49%	5.00%	4.86%	3.23%	—	—	—	—	—	—	—	—	8.41%
ROVI	—	—	—	—	—	—	—	—	—	—	—	10.00%	10.00%
SAB	—	—	—	—	4.94%	—	—	—	—	—	—	—	—
SAN	—	—	2.77%	—	—	—	—	3.73%	—	—	—	—	5.00%
SCYR	—	—	—	4.54%	—	—	—	—	—	—	—	—	—
SGRE	—	—	—	—	—	10.00%	10.00%	10.00%	5.00%	10.00%	8.36%	5.00%	—
SLR	—	—	—	—	—	—	—	—	—	—	10.00%	10.00%	10.00%
TEF	4.89%	4.89%	—	—	—	—	—	—	—	—	—	—	—
TLS	—	—	—	1.77%	5.00%	1.68%	8.42%	5.00%	—	—	—	—	—
TRE	10.00%	9.67%	5.00%	5.00%	—	—	5.00%	—	—	—	—	—	—
VIS	—	—	—	8.53%	—	—	3.25%	—	4.96%	—	5.00%	—	—

B.4 Optimización Bayesiana

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	3.05%	-	3.75%	3.44%	3.01%	4.25%	2.83%	4.87%	-	-	-	-	-
ABG, P	6.07%	1.07%	4.81%	-	1.10%	-	-	-	-	-	-	-	-
ACS	4.08%	5.80%	-	-	4.73%	-	5.85%	-	2.62%	3.80%	4.85%	-	3.66%
ACX	1.69%	3.29%	5.47%	-	-	1.95%	2.82%	4.83%	1.76%	4.82%	4.57%	1.94%	3.44%
AENA	-	-	-	-	-	-	-	-	-	4.77%	2.87%	1.63%	3.16%
ALM	-	-	-	-	-	-	-	-	-	-	4.81%	-	-
AMS	-	-	-	-	1.89%	3.81%	4.36%	2.71%	3.55%	5.40%	3.63%	3.19%	2.32%
ANA	3.99%	6.21%	1.47%	6.38%	-	3.44%	-	3.31%	2.97%	3.87%	5.06%	1.94%	5.00%
BBVA	1.50%	4.64%	4.01%	3.70%	4.35%	2.01%	4.11%	-	-	1.27%	2.39%	4.22%	3.47%
BKIA	-	-	-	-	-	-	-	2.54%	-	-	-	-	-
BKT	3.98%	2.05%	4.27%	3.94%	1.40%	3.54%	5.08%	3.42%	4.20%	5.57%	3.13%	1.52%	2.62%
BME	-	4.80%	4.77%	1.85%	3.67%	-	-	-	-	-	-	-	-
BTO	2.19%	-	-	-	-	-	-	-	-	-	-	-	-
CABK	-	2.44%	5.94%	4.66%	5.07%	1.22%	5.34%	2.65%	2.52%	3.62%	1.75%	-	1.53%
CIE	-	-	-	-	-	-	-	-	4.87%	2.23%	3.99%	5.04%	-
CLNX	-	-	-	-	-	-	-	-	-	1.51%	3.66%	5.07%	4.75%
COL	-	-	-	-	-	-	-	5.02%	5.63%	6.14%	1.37%	4.08%	1.83%
DIA	-	-	-	-	-	3.79%	-	5.04%	-	-	-	-	-
EBRO	3.28%	5.89%	-	6.85%	-	-	-	-	-	-	-	-	-
ELE	-	1.33%	1.89%	-	5.42%	3.13%	5.85%	2.69%	2.91%	4.48%	4.41%	-	-
ENC	-	-	-	-	-	-	-	-	4.22%	6.14%	-	-	-
ENG	3.34%	4.41%	-	-	4.36%	1.36%	1.55%	2.21%	5.63%	-	2.36%	2.76%	-
FCC	2.22%	-	3.47%	1.82%	2.31%	1.16%	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	-	4.34%
FER	3.20%	4.35%	1.11%	7.40%	3.25%	3.89%	1.40%	4.37%	-	1.79%	3.49%	4.66%	2.51%
GRF	5.22%	5.90%	6.18%	1.64%	5.13%	4.71%	4.49%	2.64%	1.41%	4.62%	-	2.48%	2.77%
IAG	-	-	-	-	-	4.26%	4.28%	4.69%	4.94%	2.08%	1.58%	5.07%	4.23%
IBE	1.51%	3.09%	-	-	-	5.19%	2.31%	4.84%	5.63%	1.91%	1.43%	5.34%	2.09%
IBLA	5.63%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	5.07%	-	4.97%	6.61%	3.41%	3.52%	3.88%	-	1.67%	4.48%	2.53%	4.41%	2.94%
ITX	2.29%	5.50%	5.32%	4.63%	5.23%	4.76%	2.07%	3.93%	3.07%	1.16%	1.82%	3.11%	4.94%
JAZ	-	-	-	5.71%	6.29%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	3.78%
MAP	2.55%	2.20%	6.00%	1.34%	1.85%	3.93%	1.16%	3.04%	5.56%	-	1.57%	1.81%	1.74%
MEL	-	-	-	-	-	-	4.32%	4.80%	-	5.80%	2.65%	2.52%	1.26%
MRL	-	-	-	-	-	-	-	-	1.79%	2.28%	3.10%	-	4.23%
MTS	6.13%	3.31%	5.76%	-	3.22%	1.95%	5.54%	1.70%	5.04%	2.13%	3.04%	6.83%	4.58%
NTGY	5.62%	2.86%	-	1.02%	2.34%	5.10%	2.35%	2.78%	2.85%	3.35%	-	4.78%	2.92%
OHLA	-	2.46%	3.91%	7.48%	1.33%	2.11%	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	4.10%	2.38%	-	-
POP	-	-	-	1.29%	1.05%	-	1.80%	-	-	-	-	-	-
RED	-	3.59%	2.12%	1.86%	4.65%	2.50%	3.55%	4.06%	3.80%	-	5.63%	2.37%	1.07%
REP	-	1.16%	4.90%	4.46%	-	-	-	1.50%	2.14%	2.77%	1.91%	-	4.19%
ROVI	-	-	-	-	-	-	-	-	-	-	3.38%	3.31%	-
SAB	4.61%	3.72%	1.15%	1.05%	4.59%	1.85%	-	-	1.33%	1.34%	4.83%	2.95%	-
SAN	4.07%	2.84%	1.13%	2.50%	-	2.68%	5.15%	1.22%	-	3.93%	-	2.49%	-
SCYR	3.00%	1.87%	4.57%	2.74%	4.46%	3.07%	-	-	-	-	-	-	4.65%
SGRE	1.32%	-	1.43%	1.53%	4.59%	4.23%	5.71%	4.17%	4.43%	4.67%	5.58%	-	-
SLR	-	-	-	-	-	-	-	-	-	5.16%	6.83%	4.98%	-
TEF	2.46%	5.85%	4.53%	-	2.09%	4.90%	2.33%	4.24%	2.87%	-	2.08%	-	2.43%
TL5	2.67%	-	-	4.53%	2.74%	5.19%	2.34%	3.50%	3.70%	2.01%	-	-	-
TRE	5.37%	5.29%	3.85%	3.42%	4.15%	4.50%	1.81%	1.66%	4.56%	-	-	-	-
UNI	-	-	-	-	-	-	-	-	-	-	-	-	3.74%
VIS	-	-	-	4.90%	-	-	4.94%	5.37%	3.16%	1.04%	3.52%	-	-

8.3. Apéndice C: Pesos de las carteras optimizadas en el Escenario 3

C.1 Modelo de Media-Varianza

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	-	-	4.97%	2.14%	-	-	-	4.67%	-	-	-	-	-
ABG_P	4.77%	-	-	-	-	-	-	-	-	-	-	-	-
ACS	2.70%	-	-	-	-	-	-	-	-	-	-	-	-
AENA	-	-	-	-	-	-	-	-	22.60%	1.95%	-	-	-
AMS	-	-	-	-	22.31%	18.96%	23.75%	24.14%	5.00%	5.00%	5.00%	-	-
ANA	-	-	-	-	-	-	-	-	5.00%	2.33%	1.09%	5.00%	11.18%
BKT	-	-	-	-	-	5.00%	4.30%	17.82%	3.69%	-	-	-	5.00%
BME	-	-	-	3.65%	4.82%	-	-	-	-	-	-	-	-
CABK	-	-	-	-	1.67%	-	-	-	-	-	-	-	3.79%
CIE	-	-	-	-	-	-	-	-	25.00%	7.40%	5.00%	5.00%	-
CLNX	-	-	-	-	-	-	-	-	25.00%	24.58%	17.46%	5.00%	-
COL	-	-	-	-	-	-	-	5.00%	22.54%	10.26%	4.74%	4.26%	-
DIA	-	-	-	-	-	4.46%	-	-	-	-	-	-	-
EBRO	5.00%	-	-	5.00%	-	-	-	-	-	-	-	-	-
ELE	-	-	-	-	-	3.87%	5.00%	6.67%	4.68%	3.63%	1.22%	-	-
ENC	-	-	-	-	-	-	-	-	5.66%	3.07%	-	-	-
ENG	-	-	5.00%	-	5.00%	5.00%	5.00%	-	2.87%	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	19.46%	4.47%	-
FER	-	5.00%	15.02%	5.00%	5.00%	5.90%	2.93%	-	-	1.63%	-	1.70%	4.29%
GRF	21.51%	25.00%	24.38%	17.34%	17.13%	25.00%	14.56%	2.87%	4.17%	5.00%	2.07%	-	-
IAG	-	-	-	-	-	5.94%	5.28%	5.00%	-	-	-	-	-
IBE	-	-	-	-	-	-	-	-	5.00%	4.30%	11.13%	4.99%	5.00%
IBLA	6.88%	-	-	-	-	-	-	-	-	-	-	-	-
ITX	9.13%	25.00%	25.00%	10.58%	12.44%	12.15%	6.11%	-	-	-	-	-	-
JAZ	-	-	-	22.63%	24.84%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	5.00%
MAP	-	4.99%	5.00%	-	-	-	-	-	-	-	-	-	-
MEL	-	-	-	-	-	-	5.00%	5.00%	-	-	-	-	-
MRL	-	-	-	-	-	-	-	-	5.00%	4.79%	-	-	-
MTS	5.00%	-	-	-	-	-	-	-	-	-	4.65%	-	-
NTGY	-	-	-	-	1.71%	3.71%	-	-	-	-	-	5.00%	4.79%
OHLA	10.38%	5.00%	9.37%	5.00%	-	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	4.10%	-	-
RED	5.00%	13.81%	5.00%	2.19%	5.00%	5.00%	4.57%	4.97%	5.00%	-	-	-	2.39%
REP	-	5.00%	1.27%	-	-	-	-	-	-	-	-	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	-	23.69%	19.34%
SCYR	-	-	-	-	-	-	-	-	-	-	-	-	2.00%
SGRE	-	-	-	-	-	5.00%	11.90%	23.82%	4.66%	5.00%	5.00%	-	-
SLR	-	-	-	-	-	-	-	-	-	-	25.00%	12.72%	25.00%
TEF	4.45%	-	-	-	-	-	-	-	-	-	-	-	-
TL5	-	-	-	-	-	-	-	5.00%	-	-	-	-	-
TRE	24.90%	15.12%	5.00%	5.00%	-	-	-	1.67%	-	-	-	-	-
VIS	-	-	-	21.38%	-	-	4.93%	-	1.53%	-	4.49%	-	-

C.2 CAPM

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	1.41%	2.57%	5.00%	3.20%	2.10%	4.89%	3.50%	3.77%	-	-	-	-	-
ABG.P	6.09%	-	5.00%	-	25.00%	-	-	-	-	-	-	-	-
ACS	2.82%	4.09%	3.84%	2.06%	3.50%	-	1.47%	1.79%	-	1.09%	-	-	-
ACX	5.00%	2.83%	1.68%	-	-	5.00%	-	-	6.94%	8.90%	2.51%	2.52%	-
AENA	-	-	-	-	-	-	-	-	-	4.75%	-	-	-
ALM	-	-	-	-	-	-	-	-	-	4.80%	5.53%	-	-
AMS	-	-	-	-	4.92%	10.29%	3.81%	3.94%	11.93%	7.76%	-	-	-
ANA	5.14%	-	-	1.13%	3.87%	-	1.09%	1.37%	-	-	3.58%	3.62%	3.99%
BBVA	-	-	-	10.03%	-	-	10.04%	8.70%	-	-	-	-	-
BKIA	-	-	-	-	-	25.00%	-	-	-	-	-	-	-
BKT	-	-	-	3.46%	-	-	2.40%	2.65%	-	-	-	-	-
BME	6.09%	2.59%	5.00%	1.59%	5.00%	-	-	-	-	-	-	-	-
CABK	-	1.41%	2.18%	2.06%	-	-	3.64%	4.01%	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	4.77%	4.67%	-	3.83%	-
CLNX	-	-	-	-	-	-	-	-	-	8.27%	4.90%	5.00%	6.47%
COL	-	-	-	-	-	-	-	-	4.08%	1.69%	2.14%	2.04%	-
DIA	-	-	-	-	-	5.00%	-	1.13%	-	-	-	-	-
EBRO	5.86%	5.00%	-	2.10%	-	-	-	-	-	-	-	-	-
ELE	3.39%	-	4.94%	-	1.79%	7.60%	2.44%	2.08%	5.46%	-	3.60%	2.13%	3.89%
ENC	-	-	-	-	-	-	-	-	25.00%	23.77%	-	-	-
ENG	3.17%	9.13%	4.58%	3.27%	1.50%	-	2.28%	1.74%	5.00%	-	4.11%	3.08%	8.22%
FCC	4.32%	5.00%	3.22%	-	-	-	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	5.00%	8.55%
FER	2.82%	-	-	2.39%	2.18%	8.30%	4.07%	3.66%	-	-	-	-	-
GRF	7.06%	24.41%	22.73%	1.46%	5.48%	10.59%	1.99%	2.08%	4.23%	5.00%	4.93%	4.60%	14.14%
IAG	-	-	-	-	-	-	-	2.30%	2.50%	-	-	-	-
IBE	-	-	-	7.45%	-	-	7.56%	6.97%	-	-	3.65%	-	5.00%
IBLA	5.69%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	4.28%	5.00%	4.59%	1.48%	2.75%	5.00%	-	-	5.91%	5.00%	3.15%	3.55%	-
ITX	-	-	-	5.91%	-	6.93%	9.35%	10.24%	-	-	-	-	-
JAZ	-	-	-	-	5.00%	-	-	-	-	-	-	-	-
MAP	-	2.14%	-	2.49%	-	-	1.70%	1.22%	-	-	-	-	-
MEL	-	-	-	-	-	-	-	-	5.75%	3.98%	-	-	-
MRL	-	-	-	-	-	-	-	-	4.31%	-	-	2.35%	-
MTS	4.99%	-	-	1.20%	-	-	-	-	-	8.85%	-	-	-
NTGY	-	-	-	3.67%	-	-	3.34%	2.76%	-	-	1.31%	2.26%	4.97%
OHLA	4.95%	-	-	1.99%	1.80%	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	24.53%	25.00%	-
POP	-	-	-	4.89%	-	-	1.04%	-	-	-	-	-	-
RED	2.49%	5.00%	2.99%	3.18%	2.27%	6.79%	2.35%	2.62%	2.65%	-	3.93%	4.96%	6.05%
REP	-	-	-	6.51%	-	-	4.93%	4.61%	-	-	-	-	-
ROVI	-	-	-	-	-	-	-	-	-	-	-	5.75%	12.57%
SAB	-	-	-	3.62%	-	-	1.27%	2.16%	-	-	-	-	-
SAN	-	-	-	11.28%	-	-	12.44%	14.38%	-	-	-	-	-
SCYR	4.96%	25.00%	25.00%	-	18.88%	-	-	-	-	-	-	-	-
SGRE	5.00%	-	-	-	4.32%	-	-	-	-	4.65%	4.07%	4.61%	-
SLR	-	-	-	-	-	-	-	-	-	-	23.81%	13.37%	25.00%
TEF	-	-	-	8.82%	-	-	10.61%	9.70%	-	-	-	-	-
TL5	4.35%	3.21%	2.53%	-	3.10%	-	-	-	4.24%	4.61%	-	-	-
TRE	9.76%	1.21%	4.88%	1.51%	5.00%	3.53%	-	-	4.99%	-	-	-	-
VIS	-	-	-	1.44%	-	-	1.24%	1.01%	4.91%	4.88%	3.96%	-	-

C.3 Volatilidad Estocástica

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	-	-	5.00%	5.00%	4.71%	5.09%	4.86%	8.96%	-	-	-	-	-
ABG, P	8.39%	-	-	-	-	-	-	-	-	-	-	-	-
ACS	5.00%	-	-	-	-	-	-	-	5.00%	7.68%	5.00%	-	5.00%
AENA	-	-	-	-	-	-	-	-	-	14.35%	2.30%	-	-
AMS	-	-	-	-	20.89%	5.00%	14.10%	11.89%	6.36%	6.14%	-	-	-
ANA	-	-	-	-	-	-	-	-	5.00%	2.70%	-	2.50%	18.52%
BKT	-	-	-	-	2.97%	4.48%	5.08%	5.00%	14.03%	1.92%	-	-	1.44%
CABK	-	-	-	-	1.29%	-	-	-	-	-	-	-	-
CIE	-	-	-	-	-	-	-	-	21.92%	5.00%	5.00%	-	-
CLNX	-	-	-	-	-	-	-	-	-	22.50%	20.72%	4.96%	5.00%
COL	-	-	-	-	-	-	-	-	21.04%	4.77%	-	5.00%	-
EBRO	-	-	-	-	4.93%	-	-	-	-	-	-	-	-
ELE	-	-	-	-	-	-	1.87%	1.57%	-	-	-	-	-
ENC	-	-	-	-	-	-	-	-	9.55%	4.70%	-	-	-
ENG	-	-	1.70%	-	3.64%	2.94%	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	19.31%	3.41%
FER	-	5.00%	9.87%	5.00%	5.00%	5.00%	-	5.00%	-	-	-	2.97%	4.11%
GRF	14.32%	24.91%	25.00%	10.84%	12.42%	25.00%	5.00%	-	5.00%	5.00%	-	-	-
IAG	-	-	-	-	-	-	5.00%	5.00%	7.72%	1.83%	-	-	-
IBE	-	-	-	-	-	-	-	1.72%	4.27%	-	4.99%	2.55%	4.95%
IBLA	5.00%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	-	-	-	-	-	-	-	-	-	-	-	-	4.95%
ITX	18.06%	25.00%	25.00%	13.14%	8.24%	21.69%	5.00%	-	-	3.26%	1.85%	5.00%	-
JAZ	-	-	-	25.00%	25.00%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	2.58%
MAP	-	2.99%	5.00%	-	1.25%	-	-	-	1.84%	-	-	-	-
MEL	-	-	-	-	-	-	12.99%	7.64%	-	-	-	-	-
MRL	-	-	-	-	-	-	-	-	4.83%	-	-	-	-
MTS	5.00%	-	-	-	-	-	-	-	-	-	5.00%	-	-
NTGY	-	-	-	-	5.00%	-	-	4.15%	-	-	-	3.27%	5.00%
OHLA	5.89%	4.91%	18.14%	13.61%	-	-	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	-	-	16.12%	5.00%
RED	3.57%	5.00%	4.99%	-	5.00%	5.00%	5.42%	5.00%	5.00%	-	-	-	-
REP	1.91%	5.00%	-	-	-	-	-	-	-	-	-	-	7.10%
ROVI	-	-	-	-	-	-	-	-	-	-	-	18.69%	7.93%
SCYR	-	-	-	4.93%	-	-	-	-	-	-	-	-	5.00%
SGRE	-	-	-	-	-	20.20%	25.00%	25.00%	4.90%	23.90%	7.69%	4.69%	-
SLR	-	-	-	-	-	-	-	-	-	-	25.00%	24.92%	25.00%
TEF	7.04%	7.58%	-	-	-	-	-	-	-	-	-	-	-
TL5	-	-	-	-	4.29%	-	11.48%	5.00%	-	-	-	-	-
TRE	25.00%	17.63%	5.00%	5.00%	-	-	3.81%	-	-	-	-	-	-
VIS	-	-	-	7.97%	-	-	-	-	3.22%	-	5.00%	-	-

C.4 Optimización Bayesiana

Ticker	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023
ABE	3.05%	2.46%	2.35%	3.44%	1.97%	3.41%	6.54%	4.87%	-	-	-	-	-
ABG_P	6.07%	4.30%	5.28%	-	1.17%	-	-	-	-	-	-	-	-
ACS	4.08%	1.86%	4.58%	-	1.52%	5.84%	3.93%	-	3.61%	4.45%	2.32%	3.31%	3.66%
ACX	1.69%	4.58%	4.36%	-	-	1.83%	2.81%	4.83%	-	3.22%	5.47%	5.31%	3.44%
AENA	-	-	-	-	-	-	-	-	-	2.82%	-	2.39%	3.16%
ALM	-	-	-	-	-	-	-	-	-	-	-	3.97%	-
AMS	-	-	-	-	4.34%	6.00%	3.48%	2.71%	4.25%	5.87%	-	3.53%	2.32%
ANA	3.99%	-	4.18%	6.38%	1.39%	3.46%	5.71%	3.31%	2.02%	5.12%	5.55%	6.06%	5.00%
BBVA	1.50%	-	-	3.70%	2.01%	2.76%	-	-	5.96%	1.12%	-	2.99%	3.47%
BKIA	-	-	-	-	-	-	-	2.54%	1.73%	-	1.65%	-	-
BKT	3.98%	3.09%	-	3.94%	6.20%	-	6.54%	3.42%	-	4.92%	3.67%	1.78%	2.62%
BME	-	2.52%	-	1.85%	1.91%	-	-	-	-	-	-	-	-
BTO	2.19%	-	-	-	-	-	-	-	-	-	-	-	-
CABK	-	5.84%	1.36%	4.66%	3.88%	-	-	2.65%	1.90%	1.62%	-	-	1.53%
CIE	-	-	-	-	-	-	-	-	6.48%	5.87%	2.87%	1.68%	-
CLNX	-	-	-	-	-	-	-	-	-	3.34%	-	5.54%	4.75%
COL	-	-	-	-	-	-	-	5.02%	4.47%	5.69%	5.00%	1.49%	1.83%
DIA	-	-	-	-	-	6.00%	4.83%	5.04%	-	-	-	-	-
EBRO	3.28%	-	-	6.85%	-	-	-	-	-	-	-	-	-
ELE	-	1.32%	5.03%	-	2.37%	5.16%	-	2.69%	2.35%	2.50%	4.87%	2.52%	-
ENC	-	-	-	-	-	-	-	-	5.53%	2.85%	-	-	-
ENG	3.34%	5.41%	-	-	4.16%	-	4.78%	2.21%	2.63%	-	2.11%	2.36%	-
FCC	2.22%	4.52%	-	1.82%	-	-	-	-	-	-	-	-	-
FDR	-	-	-	-	-	-	-	-	-	-	-	-	-
FER	3.20%	5.39%	5.89%	7.40%	2.26%	4.25%	-	4.37%	-	4.45%	4.28%	3.37%	2.51%
GRF	5.22%	5.84%	5.93%	1.64%	2.53%	5.58%	-	2.64%	6.56%	3.01%	3.82%	3.73%	2.77%
IAG	-	-	-	-	-	4.52%	4.14%	4.69%	4.05%	4.84%	2.87%	3.88%	4.23%
IBE	1.51%	4.50%	2.29%	-	1.35%	2.65%	2.46%	4.84%	3.23%	4.49%	6.55%	-	2.09%
IBLA	5.63%	-	-	-	-	-	-	-	-	-	-	-	-
IDR	5.07%	4.20%	-	6.61%	4.54%	-	5.77%	-	2.93%	4.58%	1.14%	-	2.94%
ITX	2.29%	4.39%	3.25%	4.63%	3.92%	6.01%	5.16%	3.93%	5.65%	-	2.41%	2.19%	4.94%
JAZ	-	-	-	5.71%	5.71%	-	-	-	-	-	-	-	-
LOG	-	-	-	-	-	-	-	-	-	-	-	-	3.78%
MAP	2.55%	3.93%	1.92%	1.34%	1.10%	6.01%	-	3.04%	-	-	1.84%	-	1.74%
MEL	-	-	-	-	-	-	5.40%	4.80%	1.36%	-	-	2.58%	1.26%
MRL	-	-	-	-	-	-	-	-	6.35%	3.09%	3.79%	3.74%	4.23%
MTS	6.13%	2.57%	5.20%	-	3.82%	-	-	1.70%	-	5.87%	3.84%	4.23%	4.58%
NTGY	5.62%	4.01%	3.69%	1.02%	4.80%	1.53%	6.48%	2.78%	4.50%	-	-	3.53%	2.92%
OHLA	-	2.33%	5.80%	7.48%	2.31%	4.40%	-	-	-	-	-	-	-
PHM	-	-	-	-	-	-	-	-	-	6.03%	1.59%	-	-
POP	-	-	-	1.29%	3.18%	-	-	-	-	-	-	-	-
RED	-	1.52%	5.18%	1.86%	5.64%	-	1.22%	4.06%	2.66%	2.11%	5.11%	1.63%	1.07%
REP	-	5.67%	4.91%	4.46%	1.27%	5.31%	-	1.50%	2.77%	2.76%	4.21%	-	4.19%
ROVI	-	-	-	-	-	-	-	-	-	-	6.26%	3.31%	-
SAB	4.61%	1.62%	4.30%	1.05%	6.17%	3.38%	4.30%	-	-	-	-	-	-
SAN	4.07%	4.80%	4.06%	2.50%	4.11%	-	-	1.22%	1.17%	1.37%	-	3.86%	-
SCYR	3.00%	2.73%	5.85%	2.74%	2.76%	4.96%	-	-	-	-	-	-	4.65%
SGRE	1.32%	-	1.02%	1.53%	4.42%	3.90%	4.94%	4.17%	4.43%	2.35%	6.17%	5.37%	-
SLR	-	-	-	-	-	-	-	-	-	-	5.95%	6.29%	4.98%
TEF	2.46%	3.39%	1.47%	-	-	2.86%	4.52%	4.24%	1.45%	-	4.67%	-	2.43%
TL5	2.67%	-	3.00%	4.53%	3.81%	4.46%	3.73%	3.50%	3.27%	3.42%	-	-	-
TRE	5.37%	5.00%	5.79%	3.42%	4.73%	1.51%	4.83%	1.66%	-	-	-	-	-
UNI	-	-	-	-	-	-	-	-	-	-	-	-	3.74%
VIS	-	-	-	4.90%	-	-	6.54%	5.37%	6.02%	5.66%	-	-	-

8.4. Apéndice D: Resultados *ex ante* por enfoque

D.1 Escenario 1: Sin límites

Año	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
	Rendimiento Esperado (%)	Ratio de Sharpe						
2011	25,32%	0,722	3,01%	-0,032	25,20%	1,100	21,20%	0,571
2012	13,32%	0,322	-6,83%	-0,211	13,68%	0,369	13,05%	0,317
2013	21,64%	0,613	-9,53%	-0,241	22,40%	0,721	11,74%	0,240
2014	30,90%	1,377	4,93%	0,004	32,49%	1,635	30,91%	1,283
2015	28,32%	1,214	-0,18%	-0,090	30,67%	1,311	27,15%	1,195
2016	28,65%	1,235	2,25%	-0,015	28,85%	1,505	20,75%	0,824
2017	29,06%	1,287	4,33%	0,047	33,06%	1,679	28,23%	1,176
2018	31,76%	1,457	6,07%	0,185	37,57%	1,806	32,15%	1,294
2019	23,64%	1,076	-1,77%	-0,082	25,22%	1,155	19,29%	0,862
2020	21,10%	1,223	0,08%	-0,032	22,20%	1,327	19,89%	1,072
2021	53,67%	1,639	-0,68%	-0,028	65,66%	2,627	36,35%	1,308
2022	46,89%	2,097	0,62%	-0,004	52,31%	2,820	42,39%	1,694
2023	36,92%	1,211	-1,57%	-0,044	55,98%	1,847	31,62%	1,178

D.2 Escenario 2: UCITS

Año	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
	Rendimiento Esperado (%)	Ratio de Sharpe						
2011	14,11%	0,415	2,21%	-0,076	14,95%	0,665	5,53%	0,054
2012	4,65%	0,007	-3,77%	-0,314	3,82%	-0,038	-2,28%	-0,278
2013	4,29%	-0,018	-6,13%	-0,365	3,97%	-0,046	-5,34%	-0,351
2014	22,38%	0,919	4,92%	0,004	21,69%	1,083	14,37%	0,393
2015	17,66%	0,681	0,69%	-0,153	17,44%	0,835	8,23%	0,162
2016	21,09%	0,873	2,43%	-0,068	20,51%	1,100	10,26%	0,284
2017	22,37%	1,019	4,26%	0,047	22,18%	1,304	13,95%	0,507
2018	21,28%	1,094	5,92%	0,184	21,40%	1,291	14,22%	0,670
2019	14,62%	0,781	-0,70%	-0,130	15,12%	0,886	8,17%	0,370
2020	15,72%	0,950	0,42%	-0,056	15,90%	1,053	9,08%	0,458
2021	23,24%	1,075	-0,36%	-0,074	24,32%	1,501	10,53%	0,453
2022	27,22%	1,463	0,64%	-0,012	27,63%	1,778	14,51%	0,685
2023	16,82%	0,824	-0,91%	-0,104	17,17%	1,014	8,07%	0,336

D.3 Escenario 3: RIC

Año	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
	Rendimiento Esperado (%)	Ratio de Sharpe						
2011	20,62%	0,625	2,20%	-0,075	20,36%	0,964	5,53%	0,054
2012	9,17%	0,186	-3,26%	-0,288	8,92%	0,231	-2,50%	-0,260
2013	13,13%	0,325	-5,03%	-0,335	13,56%	0,470	-4,98%	-0,332
2014	28,32%	1,245	4,92%	0,004	28,35%	1,478	14,37%	0,411
2015	24,71%	1,100	0,47%	-0,139	23,33%	1,140	7,73%	0,136
2016	24,22%	1,082	2,62%	-0,041	26,28%	1,424	10,13%	0,274
2017	25,21%	1,176	4,30%	0,047	28,34%	1,577	14,40%	0,562
2018	29,73%	1,362	6,01%	0,185	27,78%	1,638	14,22%	0,670
2019	19,46%	0,969	-0,49%	-0,121	19,34%	1,054	8,55%	0,397
2020	19,18%	1,163	0,33%	-0,051	20,09%	1,283	9,71%	0,508
2021	36,47%	1,501	-0,43%	-0,054	38,98%	2,207	12,14%	0,541
2022	38,78%	1,964	0,63%	-0,010	42,42%	2,484	16,13%	0,800
2023	26,83%	1,104	-0,89%	-0,080	26,23%	1,426	8,07%	0,336

8.5. Apéndice E: Resultados *ex post* por enfoque

E.1 Escenario 1: Sin límites

Año	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe
2011	-1,81%	-0,817	13,20%	2,968	-3,65%	-1,525	2,49%	0,678
2012	81,72%	2,470	-56,61%	-0,905	73,91%	2,118	87,56%	2,676
2013	17,92%	0,710	129,56%	2,011	14,94%	0,564	22,30%	1,005
2014	14,96%	0,797	5,92%	0,257	10,85%	0,521	3,16%	0,107
2015	10,87%	1,035	-45,47%	-0,602	7,71%	0,989	12,81%	1,072
2016	-3,59%	-0,156	-6,99%	0,045	-2,02%	-0,044	-1,84%	-0,068
2017	20,54%	3,055	9,78%	1,383	15,16%	2,293	18,45%	2,873
2018	12,82%	1,315	-6,10%	-0,788	2,45%	0,233	7,78%	0,873
2019	13,43%	0,777	-11,59%	-0,087	10,09%	0,606	15,30%	0,892
2020	8,47%	0,398	-10,61%	0,035	33,67%	1,006	8,02%	0,389
2021	-18,37%	-1,854	29,29%	2,074	-17,44%	-1,297	-2,63%	-0,255
2022	-41,19%	-1,695	15,27%	0,488	-33,33%	-1,224	-23,48%	-0,918
2023	16,53%	0,678	7,54%	0,277	6,03%	0,225	13,86%	0,591

E.2 Escenario 2: UCITS

	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
Año	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe
2011	4,26%	1,502	10,22%	3,330	3,85%	1,285	7,92%	2,210
2012	12,88%	0,394	-4,70%	-0,299	10,04%	0,274	0,14%	-0,114
2013	21,60%	1,016	40,27%	1,584	22,13%	1,039	31,74%	1,358
2014	8,82%	0,446	6,54%	0,289	5,24%	0,224	3,91%	0,151
2015	4,56%	0,369	-2,94%	-0,170	2,69%	0,208	0,77%	0,061
2016	-3,98%	-0,165	4,37%	0,240	0,19%	0,040	5,78%	0,298
2017	11,58%	2,215	10,18%	1,530	11,65%	2,165	9,99%	1,577
2018	3,16%	0,380	-4,25%	-0,591	1,95%	0,209	-3,38%	-0,547
2019	15,60%	1,228	6,16%	0,388	13,37%	0,994	10,01%	0,731
2020	1,04%	0,176	-2,10%	0,091	1,92%	0,211	-11,40%	-0,147
2021	-0,64%	-0,057	0,84%	0,280	0,40%	0,174	6,50%	1,599
2022	-21,14%	-1,034	-15,18%	-0,745	-17,84%	-0,867	-8,90%	-0,449
2023	10,96%	0,589	16,84%	0,887	13,99%	0,800	17,36%	0,961

E.3 Escenario 3: RIC

	Media-Varianza		CAPM		Volatilidad Estocástica		Optimización Bayesiana	
Año	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe	Rendimiento Real (%)	Ratio de Sharpe
2011	2,07%	0,537	9,98%	3,289	0,45%	-0,119	7,92%	2,210
2012	44,18%	1,641	-0,75%	-0,082	40,41%	1,490	-5,24%	-0,302
2013	23,13%	1,094	51,78%	1,946	23,96%	1,112	24,92%	1,093
2014	12,99%	0,695	5,88%	0,254	8,21%	0,384	3,91%	0,151
2015	9,75%	0,889	-8,09%	-0,322	6,57%	0,608	-2,04%	-0,141
2016	-0,99%	-0,029	2,82%	0,173	2,42%	0,151	4,13%	0,230
2017	14,44%	2,605	10,20%	1,487	12,79%	2,255	10,51%	1,886
2018	7,15%	0,831	-5,20%	-0,694	1,70%	0,172	-3,38%	-0,547
2019	15,91%	1,180	2,04%	0,165	14,46%	1,018	12,26%	0,904
2020	5,54%	0,317	2,74%	0,240	24,23%	0,816	-7,80%	-0,060
2021	-9,29%	-1,429	-0,32%	0,091	-5,82%	-0,736	7,10%	1,722
2022	-32,97%	-1,492	-9,11%	-0,358	-25,96%	-1,051	-13,93%	-0,719
2023	15,73%	0,775	19,03%	0,858	10,19%	0,461	17,36%	0,961

8.6. Apéndice F: Modelo

El código completo utilizado para la implementación de los métodos presentados en este Trabajo de Fin de Grado se encuentra disponible en el siguiente repositorio de GitHub: https://github.com/SCollazoFontes/TFG-BA-Santiago_Collazo